보도 없는 생활도로에서 근거를 대고 판단하는 VLM과 그 채점 기준

Korean Local-road VLM: 통합 기획안

윤유경 문혜승 고연오 하경흠 한태문

실전SW프로젝트 팀1 · 카카오모빌리티 한국형 주행 VLM

2026년 11월

요약

우리가 하려는 일. 보도와 차도가 나뉘지 않은 국내 생활도로의 전방 사진 한 장을 보고, ① 사진에서 무엇이 보이는지, ② 그래서 어떤 위험 관계가 성립하는지, ③ 무엇이 가려져서 판단할 수 없는지, ④ 그렇다면 어떤 조건에서 어떻게 대응해야 하는지를 **근거 위치와 함께** 답하는 VLM(Vision-Language Model, 사진과 글을 함께 입력받아 글로 답하는 AI 모델)을 만든다. 그리고 그 답이 사진 속 근거와 실제로 맞는지 채점하는 시험지와 채점 기준, 즉 Benchmark를 함께 만든다.

이 두 가지를 함께 만드는 이유는, 기존 주행 VLM 평가에서 모델이 사진을 보지 않고도 높은 점수를 받는 사례가 보고되었기 때문이다(§1). 정답률 하나만으로는 모델이 실제로 장면을 보고 판단했는지 확인할 수 없으므로, 우리는 판단의 **근거**까지 채점하는 기준을 먼저 정하고, 그 기준으로 소규모 추가 학습(Fine-tuning)의 효과를 측정한다. 아래 표는 이 문서 전체의 결론을 미리 모은 것이며, 각 줄의 상세 근거는 오른쪽 열의 절에 있다.

질문	답	상세
무엇을 입력하는가	전방 카메라 사진 한 장과 "보이는 도로를 따라 앞으로 간다"는 진행 가정 하나를 입력한다.	§3
무엇을 출력하는가	근거가 되는 Object·Region의 위치, 네 가지 위험 관계(R1–R4) 각각의 Present/Absent/Unknown 판정, 조건이 붙은 대응 Code를 하나의 JSON으로 출력한다.	§3, §4
어떤 데이터를 쓰는가	AI Hub 생활도로 객체인식 데이터(71784)에서 독립 장면 약 400개를 골라 Train 150 / Dev 50 / Test 200으로 나눈다. 정확한 수는 1주차 검수 후 확정한다.	§5
어떤 모델을 쓰는가	Gemma 4 E2B-it를 우선 시험하고, 장비에서 돌지 않으면 Gemma 3 4B-it로 바꾼다. 추가 학습은 QLoRA 한 가지 방법만 쓴다.	§6
무엇과 비교하는가	같은 모델의 학습 전(Base), 상용 대형 VLM(Commercial), 학습 후(Tuned) 세 조건을 같은 시험지와 같은 채점 Code로 비교한다.	§6
무엇으로 판정하는가	대표 점수는 Relation Macro-F1(관계 판정의 정확성)과 Action Pass Rate(대응 규칙 충족률) 두 개이며, 모든 점수에 표본 수와 95% 신뢰구간을 붙인다.	§7
추가로 무엇을 시험하는가	보행자 위치만 바꾼 편집 사진으로 "위치가 바뀌면 판단도 맞게 바뀌는가"를 검사하고, 편집 사진을 학습에 더했을 때 실제 사진 성능이 오르는지 확인한다.	§8
한 달 뒤 무엇을 내는가	고정된 Test와 Annotation Guideline, 채점 Code, 학습 전후 모델, 세 조건의 비교 결과와 신뢰구간, 오류 분석 Report, 같은 결과를 다시 만들 수 있는 Demo와 실행 기록을 낸다.	§2

이 문서를 읽는 순서. §1는 왜 이 문제를 고르고 왜 근거까지 채점해야 하는지를 설명하고, §2은 한 달 동안 어디까지 할지와 무엇을 제출할지를 정한다. §3와 §4는 한 장의 예시 사진을 따라가며 모델의 입력·출력과 정답 규칙을 정의한다. 이 규칙을 바탕으로 §5에서 데이터를 만들고, §6에서 모델을 학습하고, §7에서 채점하며, §8에서 편집 사진으로 판단을 진단한다. §9는 결과를 다시 만들 수 있게 하는 기록과 Demo를, §10은 주별 일정과 계획이 틀어졌을 때의 대응을, §11은 결과를 어떤 기준으로 해석할지를 정한다. AI

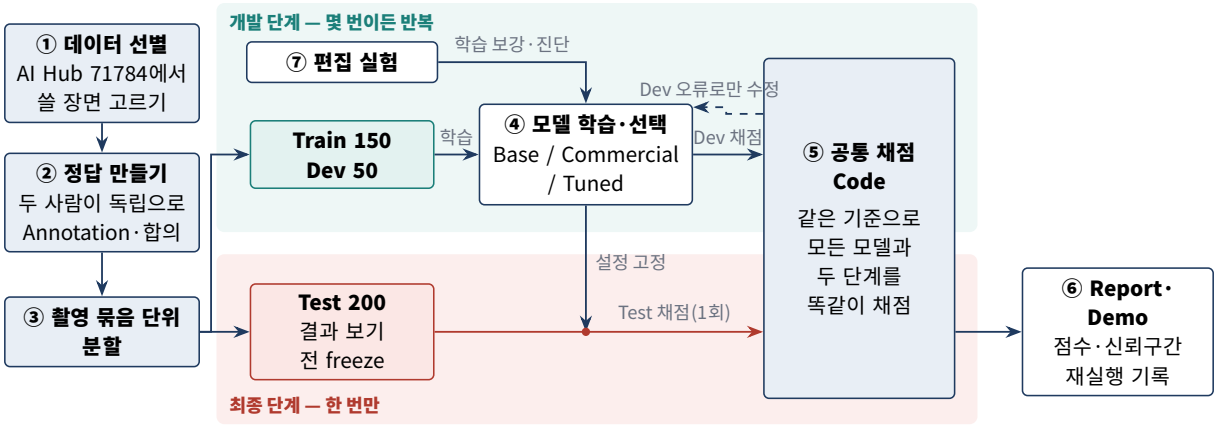


그림 1. 전체 흐름. 파란 상자는 모든 모델이 공유하는 데이터와 기준이다. 모델 개발(④)은 Train과 Dev만 보고 수정하며, Test(빨간 상자)는 설정을 모두 고정한 뒤 마지막에 한 번만 채점한다. 이렇게 나누어야 Test 점수가 "본 적 없는 장면에서의 성능"을 뜻하게 된다.

나 통계 용어가 낯설다면 부록 B의 용어 설명을 먼저 보면 된다. 모든 점수의 식과 분모는 부록 A에 한 표로 모았고, 아직 확정하지 않은 값은 (1주차 확정) 표시와 함께 부록 C에 모았다.

1 왜 이 문제이고, 왜 근거까지 채점하는가

생활도로에서는 보행자·차량·이륜차가 같은 노면을 쓰기 때문에 "무엇이 어디에 있고 무엇이 가려졌는가"가 판단의 출발점이다. 그런데 기존 평가처럼 최종 행동의 정답률만 보면, 모델이 사진을 보지 않고 흔한 답을 골라도 점수가 높게 나올 수 있다. 그래서 우리는 행동뿐 아니라 그 행동의 근거가 된 관계와 위치까지 채점한다.

1.1 생활도로 판단이 어려운 이유

보도와 차도가 분리되지 않은 도로에서는 보행자가 차량 진행 공간을 직접 지나가고, 주차 차량이 골목 입구나 건물 출입구를 가리며, 남은 통행 폭이 좁아진다. 경찰청·도로교통공단의 2017–2021년 자료를 인용한 보도에 따르면, 보행자와 차량이 함께 쓰는 보차혼용도로의 보행 사망자 수는 보도가 있는 도로의 약 3배였고 보행 사망자 10명 중 7명이 이런 도로에서 발생했다[2]. 이 수치는 사망자 **수**의 비교이며, 도로별 통행량을 반영한 위험도 비교는 아니라는 점을 밝혀 둔다. 그래도 이 수치는 생활도로가 주행 판단을 검증할 가치가 있는 환경이라는 점을 보여 준다.

1.2 기존 평가로는 "사진을 보고 판단했는가"를 알 수 없다

DriveBench 연구는 12개 VLM을 19,200개 Frame, 20,498개 질문–답 쌍으로 평가하면서, 정상 사진과 15가지로 손상시킨 사진, 그리고 사진을 완전히 검은 화면으로 바꾼 조건을 비교했다[3]. 그 결과 여러 모델이 시각 정보가 없는 조건에서도 그럴듯한 답을 내었고, 연구진은 이런 답이 사진이 아니라 일반 상식이나 질문 문장의 단서에서 나온다고 보았다. 또한 이 연구가 분석한 원본 데이터(DriveLM-nuScenes)의 행동 객관식 문항은 약 78.6%가 "직진"이 정답이어서, 사진을 보지 않고 직진만 골라도 70% 이상을 맞힐 수 있었다[3].

이 결과가 우리 설계에 주는 결론은 하나다. 전체 정답률이라는 하나의 숫자로는 모델이 장면을 근거로 답했는지, 답의 분포를 외워서 맞혔는지 구분할 수 없다. 따라서 평가는 **장면마다** "어떤 관계가 성립하는가"와 "그 판단의 근거가 사진의 어느 부분인가"를 따로 물어야 한다.

1.3 그래서 이 프로젝트는 평가를 세 가지 점에서 바꾼다

첫째, 행동 하나를 맞히는지가 아니라 진행 공간 점유, 출입구 주변 Road User, 가림, 통행 폭 제한이라는 네 가지 관계를 **모든 장면에 똑같이** 묻는다. 모든 장면에 같은 질문을 하면 "있다"만 반복하는 모델과 실제로 구분하는 모델이 점수에서 갈린다. 둘째, "모름(Unknown)"을 정답의 하나로 둔다. 사진 한 장으로는 가려진 곳에 사람이 있는지 알 수 없으므로, 그런 경우에 있다거나 없다고 단정하는 답을 오류로 센다. 셋째,

"정지하라" 같은 단정 대신 "가려진 출입구 앞에서는 확인한 뒤 진행하라"처럼 조건이 붙은 대응을 채점한다. 속도와 거리를 모르는 사진 한 장에서 정당화할 수 있는 대응은 이런 조건부 대응이기 때문이다.

1.4 과제 제공 기업의 요구와 우리 설계의 대응

카카오모빌리티는 질의응답에서 다음 네 가지를 전달했고[1], 아래 표는 각 요구가 어떤 설계 결정으로 이어졌는지를 보여 준다. 핵심은 "팀이 정해도 되는 것(분류 체계)"은 이 프로젝트의 기여로 삼고, "일정상 위험한 것(시간 정보 모델링)"은 조건이 맞을 때만 작게 시험한다는 점이다.

전달받은 내용	우리 설계의 결정
보도 없는 골목에 대한 기존 Taxonomy가 없으므로 팀이 정해도 된다.	사진에서 확인할 수 있는 관계를 중심으로 분류 체계와 Annotation Guideline을 직접 만들고, 이를 핵심 기여로 삼는다(§4).
Tracking을 쓰고 있어 시간 정보 모델링에 긍정적이지만 일정이 걱정된다.	사진 한 장 판단을 먼저 완성하고, 1주차에 조건을 충족하는 영상 Clip이 확보될 때만 여러 Frame 입력을 작게 비교한다(§6.6).
현재는 AI Hub처럼 접근 가능한 데이터를 쓴다.	학습·검증·시험 데이터를 모두 AI Hub에서 구축한다(§5).
AIOps/MLOps 구성에 긍정적이다.	데이터·모델·채점 Code의 Version을 실행 기록 하나로 묶어, 같은 결과를 다시 만들 수 있게 한다(§9).

2 목표, 범위, 연구 질문

한 달의 목표는 "성능이 오른다"를 미리 약속하는 것이 아니라, 성능이 올랐는지 아닌지를 **비교 가능한 증거로** 보여 주는 Prototype을 완성하는 것이다. 개선이 확인되지 않더라도 어떤 관계와 어떤 데이터 조건이 병목인지를 결과로 남기면 목표를 달성한 것으로 본다.

2.1 제출물

제출물은 서로 의존하는 세 덩어리로 이루어진다. **Benchmark**는 판단 기준과 채점 방법을 정하고, **학습한 VLM**은 그 기준에서 추가 학습의 효과를 보여 주며, **재현 Workflow**는 이 결과를 다른 사람이 같은 조건으로 다시 실행하고 다음 개선으로 이어 가게 한다. 구체적인 목록은 다음과 같다.

덩어리	구체적인 제출물	필수 여부
Benchmark	선정 장면 목록과 선정 이유, Annotation Guideline, freeze한 Test와 정답, 채점 Code	필수
학습한 VLM	같은 모델의 학습 전·후 Checkpoint, 학습 설정, Base·Commercial·Tuned 세 조건의 Test 결과	필수
재현 Workflow	실행 기록(Run ID), 재실행 Script, 사진별 결과를 보여 주는 Web Demo	필수
Report	점수·표본 수·95% 신뢰구간, 오류 사례 분석, 개선이 없을 때의 병목 분석, Model Card와 Dataset Card	필수
확장 실험	편집 사진 진단과 학습 보강 결과, 여러 Frame 입력 비교 결과	1주차 Gate 통과 시

2.2 연구 질문과 각 질문에 답하는 방법

세 가지 연구 질문(Research Question, RQ)은 순서대로 쌓인다. RQ1이 "현재 모델이 근거를 보고 판단하는가"를 측정하면, RQ2는 "소규모 학습으로 그 판단이 나아지는가"를 묻고, RQ3은 "나아졌다면 정말 위치 변화에 반응하게 되었는가"를 통제된 사진으로 확인한다.

연구 질문	답을 내는 방법
RQ1 Grounding. VLM은 사진 속 Object와 공간 관계를 근거로 위험을 구분하고, 정보가 부족할 때 이를 "모름"으로 표시하는가?	Base와 Commercial을 Test에서 채점하여 관계 판정(V5–V9), 근거 위치 대조(V3, V4), 사실과 다른 진술(V13, V14)을 측정한다.
RQ2 Adaptation. 같은 입력과 같은 채점 기준에서, 소규모 추가 학습이 Base의 관계 판정과 조건부 대응 오류를 줄이는가?	같은 모델의 Base와 Tuned를 Test에서 비교하고, 대표 점수 두 개(V5, V10)의 차이를 촬영 묶음 단위 Paired Bootstrap 신뢰구간과 함께 보고한다.
RQ3 Diagnosis. 보행자 위치만 바꾼 사진에서 판단이 정답에 맞게 바뀌는가? 그 오류를 편집 사진으로 보강하면 실제 사진 성능도 오르는가?	원본·원위치 재합성·위치 이동 세 사진의 Pair Accuracy(E3, E4)를 측정하고, 실제 사진만 학습한 모델과 편집 사진을 더한 모델을 실제 사진 Test에서 비교한다.

2.3 하는 것과 하지 않는 것

범위는 "사진 한 장으로 확인할 수 있는 것"을 기준으로 정했다. 사진 한 장에는 속도, 거리, 다음 순간의 움직임이 들어 있지 않으므로, 이 정보가 필요한 판단은 이번 범위에서 빼고 후속 과제로 넘긴다.

구분	내용
반드시 함	전방 사진 한 장 입력, 네 가지 관계(R1–R4)의 P/A/U 판정, 일곱 가지 대응 Code, QLoRA 한 가지 학습 방법, 세 가지 비교 조건, 보행자 위치 이동 편집과 원위치 재합성 대조, 공통 채점 Code, 실행 기록과 Web Demo
조건부로 함	여러 Frame 입력 비교(§6.6의 Gate 통과 시), 객체 제거·가림·배경 편집, 대체 편집기 AnyDoor 비교, Gemma 4 E4B 추가 시험, 학습 Seed 3회 반복(장비 여유 시)
하지 않음	속도·거리·충돌 확률 계산, 실시간 처리·차량 탑재·차량 제어 출력, 모델 전체를 다시 학습하는 Full Fine-tuning, LiDAR·열화상 입력, Tracking 모델 개발, 국가 간 성능 비교, 실제 도로의 사고 빈도를 대표한다는 주장

"한국형"이 뜻하는 것. 좁은 도로, 혼재 통행, 주차 차량에 의한 가림은 다른 나라에도 있다. 따라서 이 프로젝트에서 "한국형(Korean)"은 상황이 한국에만 있다는 주장이 아니라, **검증에 쓰는 데이터와 도로 환경이 국내 생활도로**라는 범위 표시다. 우리가 내세우는 기여는 이 범위에서 재현되는 실패 유형과 개선 결과이며, 국가 간 차이를 주장하려면 같은 조건의 해외 표본으로 별도 비교 평가를 해야 한다.

3 모델은 무엇을 보고 무엇을 답하는가

모델은 사진 한 장과 진행 가정 하나만 받는다. 모델의 답은 "무엇이 어디에 보였는가 → 그래서 어떤 관계가 성립하는가 → 그래서 어떤 조건에서 무엇을 하는가"의 세 층으로 이루어지며, 각 층은 ID로 아래층을 가리킨다. 이 연결 덕분에 대응이 틀렸을 때 Object를 잘못 찾은 것인지, 관계를 잘못 해석한 것인지, 대응 규칙을 잘못 적용한 것인지를 나누어 볼 수 있다.

3.1 입력: 주는 것과 주지 않는 것

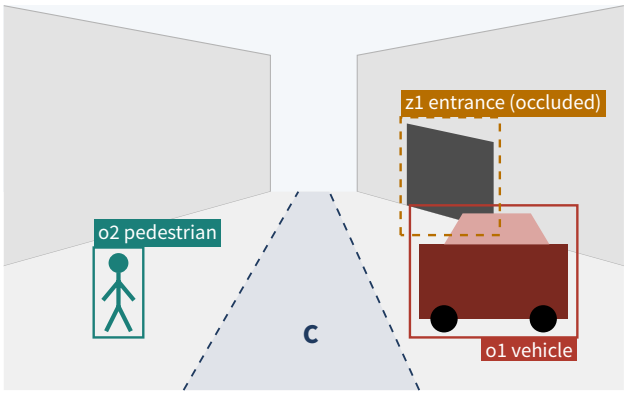
모델에 주는 정보는 판단 시점 t의 전방 카메라 RGB 사진 한 장과, 진행 가정 `follow_visible_road_forward`(보이는 도로를 따라 앞으로 진행하려 한다) 두 가지뿐이다. 진행 가정은 운전자의 실제 의도나 현재 속도가 아니라 "어느 방향으로 가려 하는가"를 정해 주는 조건이다. 사진만으로는 진행 방향을 알 수 없으므로 이 조건을 Prompt에 명시하며, 갈림길처럼 진행 방향이 여러 갈래로 해석되는 장면은 기본 Benchmark에서 제외한다.

반대로 다음 정보는 모델에 주지 않는다. 사람이 그린 정답 Box와 진행 공간은 채점에만 쓰므로 주지 않는

다. 이것을 주면 모델이 스스로 찾았는지 평가할 수 없기 때문이다. AI Hub Metadata의 시나리오 설명(예: “보행자 횡단 중”)도 주지 않는다. 이 설명은 사진 한 장에서 확인할 수 없는 움직임을 정답처럼 알려 주기 때문이다. 사고 이후의 요약이나 실제 운전자가 한 행동도 주지 않는다. 이것은 판단 시점 이후의 정보이며, 실제 운전자의 행동이 항상 적절한 대응이라는 보장도 없기 때문이다.

3.2 예시 장면

아래 그림은 이 문서 전체에서 계속 사용할 예시 장면이다. 오른쪽에 주차 차량(o1)이 있고, 그 뒤의 건물 출입구(z1)가 차량에 가려져 있으며, 왼쪽 벽 쪽에 보행자(o2)가 서 있다. 파란 영역 C는 Annotator가 “보이는 도로를 따라 앞으로 갈 때 지나갈 공간”으로 표시한 Driving Area다.



이 장면의 정답

R1 A o2의 발이 C 밖에 있다.

R2 A z1 주변에 보이는 Road User가 없다.

R3 P o1이 z1의 시야를 가린다.

R4 U o1 옆 통행 폭이 충분한지 판정 불가.

가림 뒤 Actor 존재: U

필요한 대응

· z1 앞에 들어서기 전 확인

· o1 옆을 지나기 전 통행 가능성 확인

그림 2. 예시 장면과 정답. 그림의 Box와 C는 사람이 그린 정답(Annotation)이며, 모델에는 사진만 주어지고 모델은 자신의 Box를 따로 출력한다. R1–R4와 P/A/U의 정의는 §4에 있다.

3.3 출력: 세 층을 ID로 잇는 JSON

모델은 정해진 형식(Output Schema)의 JSON으로 답한다. JSON은 이름–값 쌍으로 이루어진 텍스트 형식이며, 형식을 고정하면 사람의 해석 없이 Code가 바로 채점할 수 있다. 그림 3은 예시 장면의 답이 세 층으로 연결되는 모습이고, 그 아래는 실제 JSON이다.

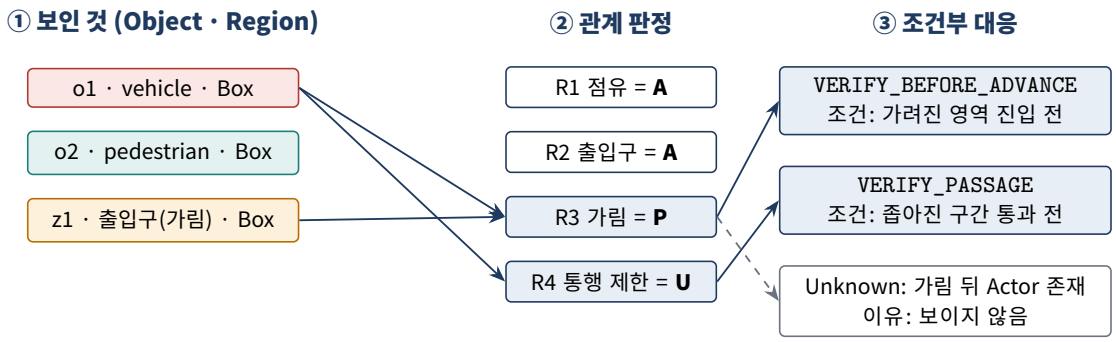


그림 3. 출력의 세 층. 화살표는 JSON 안의 `evidence`와 `based_on` 필드가 가리키는 ID이다. 예를 들어 R3=P의 근거는 o1과 z1이며, 확인 후 진행이라는 대응은 R3에 근거한다.

```
{
  "intent": "follow_visible_road_forward",
  "objects": [ {"id": "o1", "class": "vehicle",    "bbox": [0.61, 0.52, 0.87, 0.86]},
               {"id": "o2", "class": "pedestrian", "bbox": [0.15, 0.62, 0.23, 0.86]} ],
  "regions": [ {"id": "z1", "class": "occluded_entrance", "bbox": [0.63, 0.32, 0.78, 0.68]} ],
  "relations": [ {"code": "R1", "state": "A", "evidence": []},
                 {"code": "R2", "state": "A", "evidence": []},
                 {"code": "R3", "state": "P", "evidence": ["o1", "z1"]},
                 {"code": "R4", "state": "U", "evidence": ["o1"]} ],
  "unknowns":  [ {"claim": "actor_behind_occlusion", "reason": "not_visible"} ],
  "actions":   [ {"code": "VERIFY_BEFORE_ADVANCE", "condition": "before_entering_occluded_area",
                  "based_on": ["R3"]},
                 {"code": "VERIFY_PASSAGE", "condition": "before_passing_restricted_section",
                  "based_on": ["R4"]} ]
}
```

각 필드의 뜻은 다음과 같다. `objects`는 실제 사물(보행자, 차량, 자전거·이륜차 등)이고, `regions`는 사물이 아닌 공간의 일부(출입구, 가려진 영역 등)다. `bbox`는 그 대상을 둘러싸는 직사각형(Bounding Box)이며, 사진 왼쪽 위를 $(0,0)$, 오른쪽 아래를 $(1,1)$로 둔 정규화 좌표 $[x_1, y_1, x_2, y_2]$로 쓴다. 정규화 좌표를 쓰면 사진 크기가 달라도 같은 방식으로 비교할 수 있다. `relations`는 네 관계 각각의 판정과 그 근거 ID 목록이고, `unknowns`는 사진으로 확정할 수 없는 별도 주장이며, `actions`는 대응 Code, 그 대응이 적용되는 조건 Code, 근거가 된 관계를 함께 적는다.

3.4 왜 단정이 아니라 조건부 대응인가

사진 한 장에는 자차의 속도, 앞 물체까지의 정확한 거리, 보행자가 다음 순간 어디로 움직일지가 들어 있지 않다. 이런 정보 없이 "지금 정지하라"를 정답으로 정하면, 그 정답은 사진이 아니라 정답을 만든 사람의 추측에 근거하게 된다. 그래서 우리는 사진으로 정당화할 수 있는 만큼만 요구한다. 예시 장면에서 정당화되는 대응은 "가려진 출입구 앞에 들어서기 전 확인한다"이며, "보행자가 반드시 튀어나온다"나 "아무도 없으니 그냥 간다"는 모두 사진이 뒷받침하지 않는 단정이므로 오답이다. 이렇게 하면 사진 한 장의 정보 한계가 핑계 문장이 아니라 채점 가능한 규칙이 된다.

4 정답을 정하는 규칙 (Taxonomy)

한 장면에 네 가지 정보를 서로 독립적으로 기록한다. **장면 Category**는 어떤 장면을 모을지와 결과를 어떻게 나누어 볼지를 정하고, **관계 R1–R4**는 모델이 판정할 대상을 정하며, **P/A/U**는 사진으로 그 관계를 확정할 수 있는지를 정하고, **대응 규칙**은 그 조건에서 어떤 답을 맞다고 볼지를 정한다. 하나의 큰 분류 나무가 아니라 네 항목을 나란히 기록하는 이유는, 한 장면에 주차 차량·보행자·출입구 가림이 동시에 있을 수 있어서 한 칸으로 분류할 수 없기 때문이다.

항목	값	쓰는 곳
장면 Category	다섯 Category 중 해당하는 것을 모두 고름(복수 선택)	장면 수집 목표와 Category별 결과 분석. 모델 출력에는 포함하지 않는다.
관계 R1–R4	네 관계 모두 모든 장면에서 판정	모델이 예측하고 V5–V9로 채점한다.
P / A / U	관계마다 Present, Absent, Unknown 중 하나	정답 판정과 "모름"의 채점 기준이 된다.
대응 규칙	필요한 대응, 허용 대응, 금지 대응(조건 포함)	모델의 대응을 V10–V12로 채점한다.

4.1 장면 Category: 무엇을 모을지 정하는 이름표

장면 Category는 보행자–차량 혼재 통행(Mixed Traffic), 주정차 차량 주변(Parked Vehicles), 도로·건물 출입구 주변(Entrances), 좁은 통행 공간(Narrow Passage), 자전거·이륜차 근접(Two-wheeler Nearby)

의 다섯 가지다. 한 장면에 여러 Category를 붙일 수 있다. Category는 위험의 정답이 아니다. 같은 "주정차 차량 주변" 장면이라도 차량이 진행 공간을 막는 경우와 길가에 비켜 서 있는 경우의 위험은 다르기 때문에, 위험 판단은 다음의 관계 판정으로만 정한다.

4.2 Driving Area: 모든 관계 판정의 기준선

Driving Area(이하 C)는 진행 가정에 따라 자차가 지나갈 공간으로, Annotator가 보이는 도로 경계와 도로가 이어지는 방향을 보고 사진 위에 다각형(Polygon)으로 그린다. 사진의 가운데 세로선을 진행 공간으로 쓰지 않는 이유는, 굽은 도로나 카메라가 한쪽으로 치우친 사진에서 엉뚱한 Object가 진행 공간 안에 있는 것으로 판정되기 때문이다. C는 정답을 만들고 채점할 때만 쓰며 모델에는 주지 않는다.

4.3 네 가지 관계 R1–R4

네 관계는 **사진 위에서 근거를 짚을 수 있고**, **서로 다른 대응으로 이어진다**는 두 조건을 만족하도록 골랐다. 예를 들어 R1은 양보·대기로, R3은 확인 후 진행으로, R4는 통행 가능성 확인으로 이어진다. 반대로 충돌 확률처럼 속도·거리·시간이 있어야 정할 수 있는 항목은 사진 한 장으로 검수할 수 없으므로 넣지 않았다.

관계	판정 질문	판정 기준과 주의할 점
R1 점유	보이는 Actor 또는 Obstacle이 C를 점유하는가?	대상이 지면에 닿은 부분(Footprint)이 C 안에 있으면 점유로 본다. Actor는 보행자·차량·자전거처럼 도로를 이용하는 주체이고, Obstacle은 움직이지 않는 장애물이다.
R2 출입구	C와 이어지는 출입구(골목 입구, 건물·주차장 출입구) 주변에 보이는 Road User가 있는가?	Road User의 Footprint가 출입구 Region 안에 있거나 그 경계에 닿아 있으면 "주변"으로 본다. 이 관계는 **현재 위치**만 묻고, 곧 진입할 것인지라는 움직임 예측은 묻지 않는다.
R3 가림	진행 판단에 필요한 영역(C, 또는 C와 이어진 출입구·교차 지점)의 시야가 Object에 가려져 있는가?	가림을 만드는 Object와 가려진 Region을 함께 근거로 기록한다. 가려진 곳에 실제로 누가 있는지는 R3가 아니라 별도 주장으로 다룬다.
R4 통행 제한	보이는 Obstacle의 배치가 C의 통행 폭을 좁히는가?	정확한 폭(미터)을 재지 않고, 사진에서 보이는 제약만 판정한다. 폭이 좁아진 것은 보이지만 지나갈 수 있는지 판단할 수 없으면 U로 둔다.

(1주차 확정) R2의 "경계에 닿음"에 허용할 거리와 R4에서 "좁아짐"으로 볼 기준은 Pilot 50장에서 포함·제외·경계 사례를 모아 Guideline에 그림으로 고정한다.

4.4 P / A / U: 사진으로 확정할 수 있는가

각 관계는 다음 셋 중 하나로 판정한다. **P**(Present)는 사진에 그 관계가 성립한다는 근거가 있다는 뜻이다. **A**(Absent)는 관련 영역과 Object를 충분히 볼 수 있어서 그 관계가 **없다고** 판정할 수 있다는 뜻이다. **U**(Unknown)는 사진의 정보만으로는 있다고도 없다고도 판정할 수 없다는 뜻이다. 예를 들어 보행자의 발이 C의 경계선 위에 걸쳐 있어 안인지 밖인지 가를 수 없으면 R1은 U다.

U는 "모델이 자신이 없다"는 뜻이 아니라 "사진에 정보가 없다"는 뜻이다. 따라서 U는 사람이 사진만 보고 정한 정답의 하나이며, 모델의 확신도(Confidence)와는 별개로 채점한다. 사람이 U로 정한 곳에서 모델이 P나 A로 단정하면 근거 없는 단정으로 세고, 사람이 P나 A로 정한 곳에서 모델이 U라고 답하면 불필요한 판단 보류로 센다(§7).

장면 단위 판정 규칙. 한 장면에 관련 대상이 여럿 있을 때는 다음 순서로 판정한다. 관계를 만족하는 대상이 하나라도 명확하면 장면의 판정은 **P**다. 명확한 **P**가 없고 판정이 풀리지 않은 대상이 하나라도 남아 있으면 **U**다. 관련 대상을 모두 충분히 확인했고 모두 해당하지 않으면 **A**다. 예를 들어 보행자 두 명 중 한 명을 편집으로 지워도 다른 한 명이 여전히 C 안에 있으면 R1은 **P**로 남는다. 이 규칙은 원본 사진과 편집 사진에 똑같이 적용한다.

보이는 것과 숨은 것의 분리 규칙. "보이는 Actor가 있다"와 "가림 뒤에 Actor가 있다"는 서로 다른 주장으로

기록한다. 어떤 보행자가 완전히 가려졌다면, 그 보행자에 대해 R1·R2는 남은 **보이는** 대상만으로 판정하고, "가림 뒤 Actor 존재"라는 별도 주장은 **U**로 기록하며, 가림 자체는 R3=**P**로 기록해 확인 대응을 요구한다. 숨은 Actor의 존재 주장은 R1–R4 점수(V5)에 넣지 않고 진술 오류(V13, V14)와 선택 실험 E5에서 따로 채점한다. 이렇게 나누면 "보이는 공간 관계를 얼마나 맞히는가"와 "보이지 않는 것을 단정하지 않는가"를 섞지 않고 측정할 수 있다.

4.5 대응 규칙: 조건이 붙은 대응을 어떻게 채점하는가

대응은 **대응 Code**와 **조건 Code**의 쌍으로 표현한다. 같은 "감속"이라도 어떤 조건에 붙였는지가 다르면 다른 답으로 보아야 하기 때문이다. 대응 Code는 일곱 개로 시작한다.

대응 Code	뜻
`VERIFY_BEFORE_ADVANCE`	진행 판단에 필요한 영역을 확인한 뒤 진행한다.
`REDUCE_SPEED_IF_MOVING`	현재 이동 중이라면 감속한다.
`YIELD_IF_OCCUPIED`	다른 Actor가 진행 공간을 점유하고 있으면 양보한다.
`HOLD_UNTIL_CLEAR`	점유나 제약이 풀릴 때까지 진입을 보류한다.
`VERIFY_PASSAGE`	장애물 사이를 지나갈 수 있는지 확인한다.
`MONITOR_AHEAD`	전방 Actor와 진행 공간의 변화를 계속 관찰한다.
`ADVANCE_WITH_MONITORING`	진행이 허용되는 조건에서 관찰하며 진행한다.

조건 Code는 "어떤 관측 상황에서 그 대응을 하는가"를 정하며, 각 조건 Code는 특정 관계의 정답 판정이 있어야만 쓸 수 있다. 이 연결 덕분에 Code가 "이 조건을 붙일 근거가 사진에 있는가"를 자동으로 검사할 수 있다.

조건 Code	뜻	쓸 수 있는 정답
`no_condition`	장면 전체에 그대로 적용한다.	제한 없음
`while_corridor_occupied`	C의 점유가 유지되는 동안 적용한다.	R1 = **P** 또는 **U**
`while_actor_near_entrance`	출입구 주변 Road User가 있는 동안 적용한다.	R2 = **P** 또는 **U**
`before_entering_occluded_area`	가려진 영역 앞에 들어서기 전에 적용한다.	R3 = **P** 또는 **U**
`before_passing_restricted_section`	좁아진 구간을 지나기 전에 적용한다.	R4 = **P** 또는 **U**

(1주차 확정) 기존 두 문서는 조건 Code의 예시 하나(`before_entering_occluded_ingress`)만 제시했기 때문에, 이 문서는 자동 채점이 가능하도록 위 다섯 개를 초기 목록으로 정의했다. 1주차 Pilot에서 빠진 조건이 발견되면 목록에 추가하고 Version을 올린다.

정답에는 장면마다 세 가지 집합을 적는다. **필요 대응 묶음**(Required Group)은 반드시 충족해야 하는 요구사항이며, 한 요구사항을 충족하는 허용 대안이 여럿이면 그중 하나만 답해도 된다. 서로 다른 요구사항은 각각 충족해야 한다. **허용 대응**(Allowed)은 그 장면의 근거로 정당화되는 모든 쌍이고, **금지 대응**(Forbidden)은 근거와 정면으로 충돌하는 쌍이다. 허용에도 금지에도 없는 쌍을 답하면, 근거가 확인되지 않은 대응으로 보아 통과시키지 않는다. 아래 표는 관계별 시작 규칙이다.

정답 상황	필요 대응 (하나 이상 충족)	금지 대응의 예
R1 = **P**	점유 조건에서 `YIELD_IF_OCCUPIED` 또는 `HOLD_UNTIL_CLEAR`. 이동 중 감속은 허용.	점유가 없다고 가정한 무조건 `ADVANCE_WITH_MONITORING`
R2 = **P**	출입구 조건에서 `MONITOR_AHEAD` 또는 `REDUCE_SPEED_IF_MOVING` (1주차 확정)	출입구 Road User를 무시한 무조건 진행
R3 = **P**	가림 조건에서 `VERIFY_BEFORE_ADVANCE`. 이동 중 감속은 허용.	숨은 Actor가 없다고 단정한 무조건 진행
R4 = **U**	좁아진 구간 조건에서 `VERIFY_PASSAGE`	확인되지 않은 폭을 충분하다고 단정한 진행
위험 요인 없음	`MONITOR_AHEAD` 또는 `ADVANCE_WITH_MONITORING`	존재하지 않는 Actor를 근거로 한 `YIELD`·`HOLD`

여러 관계가 함께 성립하면 각 관계의 필요 대응 묶음을 모두 요구하고, 같은 조건에서 서로 모순되는 쌍(예: 같은 조건의 `HOLD_UNTIL_CLEAR`와 `ADVANCE_WITH_MONITORING`)은 동시에 답하면 실패로 본다. R2의 필요 대응은 기존 문서에 정해져 있지 않아 이 문서에서 시작안을 넣었다. 마지막 줄의 **위험 요인 없는 장면**(No-hazard Scene)은 일부러 Test에 포함한다. 이런 장면이 없으면 모든 장면에 "정지하라"고 답하는 지나치게 조심스러운 모델을 걸러낼 수 없기 때문이다.

5 데이터: 어디서, 무엇을, 얼마나

AI Hub 71784의 Metadata로 후보를 좁힌 뒤, 사람이 무작위 표본을 직접 보고 실제로 쓸 수 있는 장면 수를 추정한다. 같은 영상에서 나온 장면들은 하나의 촬영 묶음(Group)으로 묶어 Train·Dev·Test 중 한 곳에만 넣고, Test는 모델 결과를 보기 전에 freeze한다. 목표 수량은 전체 장면 수가 아니라 "각 점수의 분모가 몇 개인가"를 기준으로 정한다.

5.1 데이터 출처

사진 한 장 실험은 AI Hub 71784를 주로 쓰고, 여러 Frame 실험의 후보는 597과 71851에서 고른다. 아래 수치는 각 AI Hub 공식 페이지에서 확인한 값이다.

데이터셋	공개 정보	이번 사용
71784 생활도로 객체인식[13]	가시광 카메라 사진 400,000장, 시나리오·도로 유형·시간대·날씨 코드, Instance Segmentation 정답. 연속 Frame의 FPS는 공개되어 있지 않다.	사진 한 장 실험의 주 데이터
597 교통사고 영상[14]	MP4 21,895건, 10초 Clip, 초당 15장 추출(Clip당 최대 150장), `video_file_name`·`sequence_frame_number` 필드, 블랙박스·1인칭 시점 구분	여러 Frame 실험 후보
71851 사고위험 운전습관[15]	운전자 영상·전방 영상·CAN 각 3,300세트, 실제 도로 2,666세트	여러 Frame 실험 후보
71854 위험상황 시뮬레이션[16]	MP4 100세트와 시뮬레이션 시나리오 파일	이번에는 쓰지 않음(후속 후보)

71784의 가시광 사진 중 직진 중 보행자 관련 시나리오(B08 도로 횡단, B09 차도 위 보행, B11 길 가장자리 보행, B12 불법주차 상황의 보행자·PM)는 각각 11,864장, 26,292장, 13,272장, 14,788장으로 합계 66,216장이다[13]. 다만 도로 유형 코드 R03의 공식 명칭은 "보차도로"이므로, 이 코드를 "보도 없는 골목"으로 그대로 바꿔 읽으면 조건에 맞지 않는 사진이 섞인다. 그래서 Metadata는 후보를 좁히는 데만 쓰고, 조건에 맞는지는 사람이 사진을 보고 확정한다. 또한 이 수치는 같은 영상에서 나온 비슷한 사진을 모두 센 값이므로, 실제로 쓸 수 있는 **서로 다른** 장면의 수는 이보다 훨씬 적다.

5.2 쓸 수 있는 장면 수를 추정하는 절차

전체 사진을 사람이 다 볼 수는 없으므로, 층을 나누어 무작위로 일부만 보고 전체를 추정한다. 먼저 Metadata의 시나리오·도로 유형·시간대·날씨를 실제 JSON에서 교차 집계해 후보를 좁힌다. 조건별 비율을 곱하지 않고 실제 교집합을 세는 이유는, 조건들이 서로 독립이 아니어서 곱하면 수량이 틀어지기 때문이다. 다음으로 후보를 촬영 묶음(Group)으로 묶는다. 그 뒤 데이터 출처나 도로 유형처럼 적합 비율이 다를 수 있는 층(Stratum) s마다 Group을 무작위로 골라 대표 사진을 사람이 검수한다. 검수 기준은 전방 시점인지, 진행 방향이 하나로 정해지는지, 생활도로인지, 판단할 수 있을 만큼 화질이 좋은지다.

층 s에서 검수한 Group m_s개 중 a_s개가 적합했다면 적합 비율은 $\hat{q}_s = a_s/m_s$이고, 그 층의 후보 Group이 N_s개라면 쓸 수 있는 전체 Group 수의 추정치는 $\hat{N} = \sum_s N_s \hat{q}_s$이다. 처음에는 주요 층마다 50개 Group을 보고, 비율의 신뢰구간이 넓으면 100개까지 늘린다. 이 추정치로 Annotation 예산과 수집 우선순위를 정한다.

5.3 촬영 묶음 단위로 나누기

Group은 같은 영상, 같은 연속 촬영 구간, 또는 눈으로 보아 같은 장면에서 나온 사진들의 묶음이다. 영상 ID나 Sequence ID가 있으면 그것으로 묶고, 없거나 불완전하면 파일 경로·촬영 시각·사진 유사도로 후보를 찾은 뒤 사람이 확인한다. 촬영 위치 정보가 있으면 같은 장소도 한 Group으로 묶는다. 위치 정보가 부족하면 이 평가가 검증하는 범위를 "새로운 장소"가 아니라 "새로운 촬영 묶음"으로 낮추어 적는다.

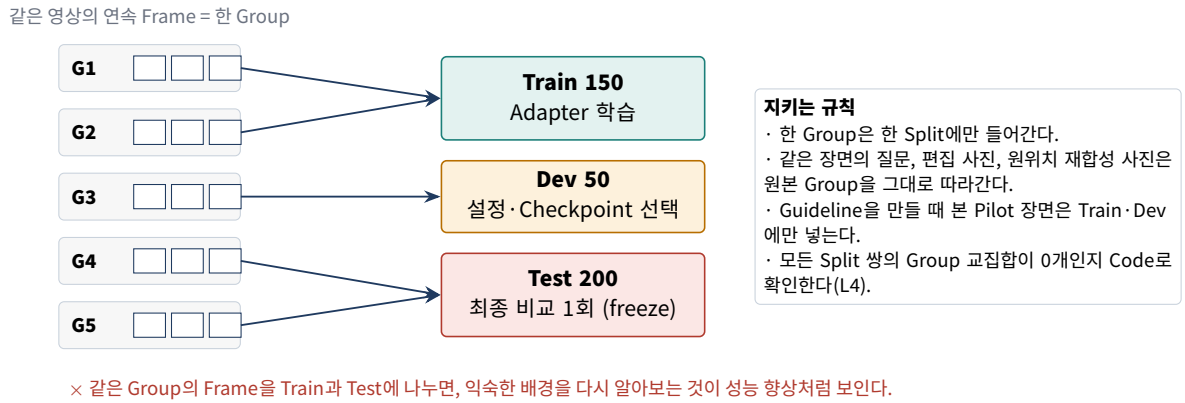


그림 4. Group 단위 분할. 숫자는 Group당 대표 장면 하나를 기준으로 한 초기 계획이며, 1주차 검수 결과로 확정한다.

기본적으로 한 Group에서 대표 장면 하나만 고른다. 한 Group에서 여러 장면을 고르는 경우에는 그 장면들을 같은 Split에 두고, 통계 계산(§7.7)에서도 한 묶음으로 다룬다. 결과에는 사진 수, 질문 수, 서로 다른 Group 수를 따로 적는다. 같은 장면에 여러 번 질문해 얻은 많은 응답은 그 장면을 더 자세히 본 것이지, 새로운 장면에서도 잘한다는 증거가 아니기 때문이다.

Split의 역할은 다음과 같이 고정한다. **Train**은 Adapter 학습에만 쓴다. **Dev**(Validation)는 Prompt, Checkpoint, 편집 설정, 임계값을 고르는 데 쓴다. **Test**는 모든 설정을 확정한 뒤 최종 비교에 한 번 쓴다.

5.4 목표 수량은 점수의 분모로 정한다

점수의 정밀도는 전체 사진 수가 아니라 그 점수의 분모가 정한다. 예를 들어 "P인 관계를 P로 맞힌 비율"(V6)의 분모는 정답이 P인 항목의 수다. 이 분모가 50개일 때 40개를 맞히면 점추정은 80%이지만 Wilson 95% 신뢰구간은 약 67.0%–88.8%로, 위아래로 10%p 안팎의 불확실성이 남는다. 신뢰구간 폭을 ±10%p로 줄이려면 가장 불리한 경우($p = 0.5$) 독립 관측이 약 97개, ±5%p로 줄이려면 약 385개가 필요하다 ($n \approx 1.96^2 p(1-p)/e^2$).

한 달 자원으로 385개를 관계마다 채울 수는 없으므로, Test의 초기 목표는 관계마다 **P** 50개, **A** 50개, **U** 30개로 정한다. 이 목표는 정밀도를 보장하는 기준이 아니라 자원에 맞춘 운영값이며, 그래서 모든 결과에 신뢰구간을 붙여 불확실성을 그대로 보여 준다. 모든 장면에서 네 관계를 모두 판정하므로 한 장면은 네 관계의 분모에 동시에 들어간다. 따라서 Test 200장면은 관계마다 200개의 판정 항목을 만들고, 그 안에서 P/A/U

목표를 채운다. 목표를 먼저 채운 뒤 장면 Category, 주간·야간, 날씨 분포를 점검하며, 표본이 부족한 세부 Category의 결과는 "탐색적 결과"로 표시한다.

5.5 정답 만들기와 검수

Annotation은 §4의 규칙을 사진에 적용해 정답을 만드는 작업이다. 한 장면에 대해 Object의 Class와 Box, Region의 종류와 Box, Driving Area C, R1–R4의 P/A/U와 그 근거 ID, 대응 규칙(필요·허용·금지 쌍)을 기록한다.

1. **Pilot.** 처음 50장면으로 Guideline을 시험하고, 관계마다 포함 예시·제외 예시·경계 예시를 그림으로 추가한다. Pilot 장면은 Train·Dev에만 넣는다.
2. **독립 Annotation.** 두 사람이 서로의 답을 보지 않고 같은 장면을 Annotation한다. 상용 VLM이나 기존 AI Hub 정답을 초안으로 쓸 수 있지만, 초안은 사람이 검수한 정답과 따로 저장하고 학습·채점에는 검수된 정답만 쓴다.
3. **일치도 측정.** 합의하기 **전에** 관계별 P/A/U의 단순 일치율(L1)과 Cohen's κ(L2)를 계산한다. κ는 두 사람이 우연히 같은 답을 고를 확률을 빼고 본 일치도다. Pilot에서 L1이 85% 미만이거나 L2가 0.7 미만이면, 어느 상태끼리 헷갈렸는지 표로 확인하고 Guideline을 보강한 뒤 다시 Annotation한다. 이 기준값은 일반적인 품질 기준이 아니라 이 프로젝트에서 재검토를 시작하는 운영값이다.
4. **합의.** 불일치가 사진의 정보 부족 때문인지 규칙이 모호해서인지 구분해 정답이나 Guideline을 고친다. 끝까지 합의되지 않는 장면은 제3자가 판정하거나 "모호 장면"으로 분리한다. Test 정답은 전체를 이중 검수하고 변경 이력을 남긴다.
5. **Object 목록 보완.** 정답에 빠진 Object가 있으면 모델이 맞게 찾은 Object가 "없는 것을 말했다"는 오류로 잘못 집계된다. 그래서 진술 오류를 채점하기 전에 Object 목록이 불완전한 장면은 추가로 Annotation한다.

5.6 Test를 freeze한다는 것의 뜻

Test를 freeze한다는 것은 사진 목록, Group별 Split, 정답, 점수 정의, 편집 절차를 모델 설정 선택 전에 고정하고, 개발 중에는 Test에 대한 모델의 답을 보지 않는다는 뜻이다. 이때 고정하는 대상은 평가 데이터와 채점 기준이며, 학습 중 모델 Weight를 고정하는 model freeze(예: §6에서 Vision Encoder와 Base Weight를 학습하지 않는 것)와는 다른 개념이다. 그래야 Test 결과를 보고 유리한 장면이나 유리한 채점 규칙을 고르는 일을 막을 수 있다. 나중에 정답 오류를 발견하면 조용히 고치지 않고, 변경 이유를 적은 새 Benchmark Version을 만들어 모든 모델을 다시 채점한다.

6 모델: 무엇을, 어떻게 학습하고 고르는가

공개 VLM 한 계열을 골라 **같은 모델**의 학습 전(Base)과 학습 후(Tuned)를 비교하고, 상용 대형 VLM을 Commercial 조건으로 두어 참고선으로 삼는다. 같은 모델끼리 비교해야 "모델이 커서 잘한다"와 "우리 데이터로 학습해서 잘한다"를 구분할 수 있다. 학습 방법은 QLoRA 하나로 제한하고, 어떤 설정을 쓸지는 Dev 점수만 보고 정한다.

6.1 세 가지 비교 조건

세 조건은 같은 사진, 같은 진행 가정, 같은 Output Schema, 같은 최대 출력 길이로 실행하고, 같은 Code로 채점한다. 각 모델의 정확한 Version과 사진 전처리 방식은 실행 기록에 남긴다.

조건	정의	이 조건이 답하는 질문
Base	고른 공개 모델을 추가 학습 없이(Adapter 없이) 실행한다. 양자화·전처리·Prompt는 Tuned와 같게 맞춘다.	출발점은 어디인가?
Commercial	Version을 고정한 상용 대형 VLM에 예시 없이 지시문만 주고 (Zero-shot) 실행한다.	큰 모델은 학습 없이 어디까지 하는가?
Tuned	Base와 같은 모델에 Train 데이터로 QLoRA Adapter를 학습해 실행한다.	소규모 학습으로 얼마나 나아지는가?

Commercial 조건은 데이터 이용 조건이 외부 API 전송을 허용할 때만 실행한다. 1주차에 AI Hub 이용 조건에서 허용 범위를 확인하지 못하면, 사진을 외부 API로 보내지 않고 Commercial 조건을 Report에서 "실행하지 않음" 으로 적는다. 어떤 상용 모델을 쓸지와 호출 예산도 1주차에 확정한다.

6.2 후보 모델과 1주차 장비 시험

첫 후보는 Gemma 4 E2B-it이다. Google 공식 Model Card에 따르면 이 모델은 사진 입력과 여러 장의 사진 입력을 지원하고 Apache 2.0 License로 공개되어 있다[17]. 이름의 "E2B"는 실제로 계산에 쓰이는 유효 Parameter가 약 2.3B라는 뜻이며, Embedding을 포함한 전체 Weight는 약 5.1B다[17]. 따라서 이름의 숫자만 보고 필요한 GPU Memory를 판단하면 안 되고, 실제 장비에서 재야 한다. 대안은 Gemma 3 4B-it로, 사진을 896×896으로 맞춘 뒤 256개 Token으로 바꾸어 입력하며 Gemma Terms of Use를 따른다[18]. 장비에 여유가 있으면 Gemma 4 E4B를 추가로 시험한다.

1주차에는 각 후보로 같은 장비에서 모델 불러오기, 사진 처리, 학습 1 Step, JSON 생성까지 끝까지 실행해 본다. 이때 요청당 추론 시간의 중앙값과 95번째 백분위수(T2), 최대 GPU Memory(T3), 형식이 맞는 응답의 비율(V1)을 잰다. 세 가지가 모두 실행 가능한 후보 중 V1이 높은 계열 하나를 고르고, 이후 Base와 Tuned는 그 계열로 고정한다.

6.3 QLoRA로 학습한다는 것의 뜻

모델 전체를 다시 학습하려면 GPU Memory와 시간이 많이 든다. **LoRA**는 원래 모델의 Weight는 그대로 두고, 그 옆에 작은 행렬 두 개(Adapter)를 붙여 이 작은 부분만 학습하는 방법이다[11]. **QLoRA**는 여기에 더해 원래 Weight를 4-bit로 압축(양자화)해 Memory를 더 줄이는 방법이다[12]. Google의 공식 Vision QLoRA 안내도 4-bit로 압축한 Gemma 4 E2B에 언어 모델 쪽 LoRA를 붙이는 구성을 쓴다[19].

이번 학습은 사진을 해석하는 Vision Encoder는 고정하고, 언어 모델의 Attention 부분에만 Adapter를 붙인다. 학습 데이터는 Train Split뿐이며, 손실(Loss)은 모델이 생성해야 하는 정답 JSON Token에서만 계산하고 Prompt·사진 Token·빈 칸 채움(Padding)은 제외한다. 손실이 줄어드는 것은 학습이 진행된다는 신호일 뿐이며, 모델 선택은 Dev의 주행 판단 점수로 한다.

설정	Rank r	Alpha α	Learning Rate	Epoch	근거
설정 A	16	32	1×10^{-4}	최대 3	기존 기획안의 제안값
설정 B	16	16	2×10^{-4}	3	Google 공식 Vision QLoRA 안내의 기본값[19]

Rank r은 Adapter 행렬의 크기를, Alpha α는 Adapter가 원래 Weight에 더해지는 세기를(α/r 배) 정한다. Epoch는 Train 데이터 전체를 한 번 학습하는 단위다. Dev가 50장면으로 작기 때문에 여러 설정을 반복해 비교하면 Dev에만 맞춘 설정을 고를 위험이 커진다. 그래서 비교하는 설정을 위 두 개로 제한한다.

6.4 Dev에서 고르는 규칙

설정과 Checkpoint는 다음 규칙으로 고른다. 규칙을 먼저 정해 두는 이유는, 점수를 본 뒤에 유리한 기준을 고르는 일을 막기 위해서다.

선택 규칙. 1단계(탈락 조건). Base보다 형식 오류율(V2)이 높아진 후보, R1–R4 중 하나라도 P 재현율(V6)이 낮아진 후보, R1–R4 중 하나라도 거짓 P 비율(V7)이 높아진 후보는 제외한다. 평균 점수가 올라도 특정 관계의 누락이나 과잉 판정이 나빠졌다면 주행 판단에서는 개선이 아니기 때문이다.
2단계(순위). 남은 후보 중 Action Pass Rate(V10)가 가장 높은 것을 고르고, 같으면 Relation Macro-F1(V5)이 높은 것, 그래도 같으면 추론 시간(T2)이 짧은 것을 고른다.
예외. 어떤 관계에서 해당 상태의 정답이 Dev에 하나도 없어 비교할 수 없으면 채택을 보류하고 그 상태를 추가 수집 대상으로 기록한다.

6.5 설정 고정

Test를 돌리기 전에 고른 모델과 비교 모델의 실행 조건을 모두 고정한다. 고정 대상은 Checkpoint, Adapter, 양자화 방식, 사진 전처리기(Processor), Prompt, Output Schema, 생성 설정, 장비 정보이며, 이것들을 하나의 실행 ID(Run ID)에 묶는다(§9). 같은 모델이라도 Prompt나 전처리가 바뀌면 답이 달라지기 때문이다.

6.6 조건부 확장: 여러 Frame 입력 비교

여러 Frame 실험은 "과거 1.5초의 사진을 더 보면 사진 한 장으로는 U였던 판단이 풀리는가"를 묻는다. 1주차 Gate는 다음 세 조건이다. 서로 다른 촬영 묶음의 전방 Clip을 30개 이상 확보하고 각 Clip의 카메라 방향과 시각 정보를 확인해야 하며, 판단 시점 t 이전 1.5초가 있어야 하고, 4장 입력의 추론이 장비에서 실행되어야 한다. 통과하면 $t-1.5$, $t-1.0$, $t-0.5$, t초의 네 장을 시간순으로 넣은 입력과 t 한 장만 넣은 입력을 비교한다. 마지막 Frame에서 명확한 P/A 판정은 두 입력에 공통 정답으로 쓰고, 과거 Frame 때문에 근거가 달라지는 U와 움직임 항목은 입력별로 다시 Annotation한다. 과거에 보였던 사람이 지금 가려져 있다면, 과거에 보였다는 사실만으로 지금 그 자리에 있다고 확정하지 않는다. 30개 규모의 결과는 탐색적 결과로만 보고한다. Gate를 통과하지 못하면 결과를 사진 한 장 실험으로 확정하고, 필요한 Clip 조건과 부족한 수량을 후속 수집 명세로 제출한다.

7 평가: 답안을 어떻게 채점하는가

모든 모델의 답안을 같은 Code가 다섯 단계로 채점한다. 대표 점수는 Relation Macro-F1(V5, 관계를 맞게 판정했는가)과 Action Pass Rate(V10, 대응 규칙을 모두 지켰는가) 두 개이고, 나머지 점수는 "왜 틀렸는가"를 설명하는 진단 점수다. 형식이 틀린 답도 버리지 않고 모든 점수의 분모에 실패로 남기며, 모든 점수에 분모와 95% 신뢰구간을 붙인다.

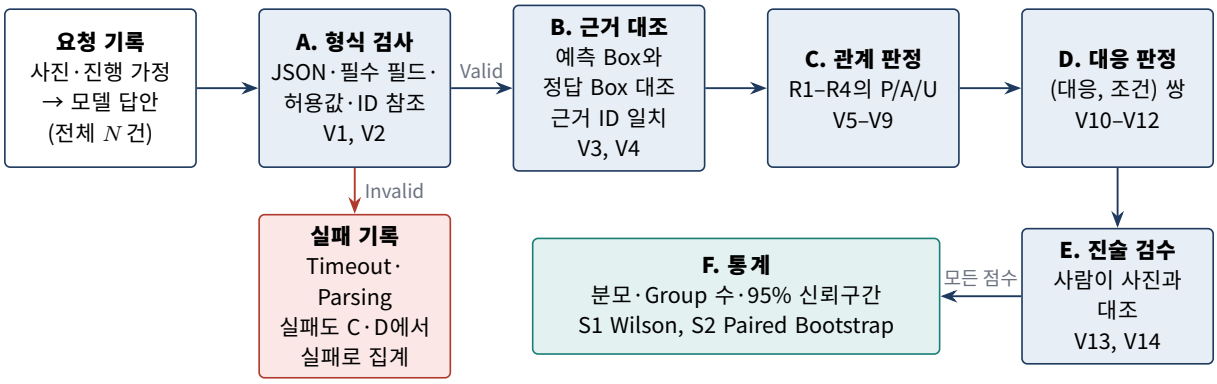


그림 5. 채점 순서. 사람이 만든 정답(Box, 관계, 대응 규칙)은 채점 Code에만 들어가고 모델 입력에는 들어가지 않는다. 형식이 틀린 답(Invalid)도 관계·대응 점수에서 실패로 남는다.

7.1 모든 점수에 공통으로 적용하는 규칙

평가 요청은 실행 전에 목록으로 먼저 고정한다. 응답에 성공한 요청만 남기면 실패율이 실제보다 낮아 보이기 때문이다. 전체 요청 수 N에는 시간 초과(Timeout)와 형식 오류도 포함된다. 형식 오류인 답은 관계 판정에

서는 실제 정답 상태를 놓친 것(FN)으로, 대응 판정에서는 실패로 센다. 분모가 0인 비율은 0이나 100%가 아니라 N/A로 보고한다.

7.2 A. 형식 검사 (V1, V2)

JSON으로 읽히고, 필수 필드가 있으며, 허용된 값만 쓰고, 참조한 ID가 같은 답 안에 선언되어 있으면 Valid다. V1은 Valid 비율, V2는 Invalid 비율이다. 형식 검사는 **채점할 수 있는 구조인지**만 본다. 실제로 없는 보행자를 `o1`로 선언한 답도 형식은 통과하므로, 내용이 사진과 맞는지는 다음 단계에서 본다. V2가 높으면 내용보다 실행·출력 형식을 먼저 고친다.

7.3 B. 근거 대조 (V3, V4)

먼저 모델이 찾은 Object가 사람이 표시한 Object와 같은 것인지 짝을 짓는다. 두 Box가 겹치는 정도는 IoU (Intersection over Union, 겹친 면적 ÷ 합친 면적)로 재며, **Class가 같고 IoU가 0.5 이상**인 쌍만 짝이 될 수 있다. 한 예측과 한 정답은 최대 한 번만 짝지으며(One-to-one Matching), 짝의 수가 가장 많아지게 하고 같으면 IoU 합이 큰 쪽을 고른다. 짝이 된 예측은 TP, 짝이 없는 예측은 FP, 짝이 없는 정답은 FN이다. 같은 보행자를 두 번 예측하면 하나만 TP이고 나머지는 FP다. 이로부터 V3 Object Precision($\frac{TP}{TP+FP}$), Recall($\frac{TP}{TP+FN}$), F1($\frac{2TP}{2TP+FP+FN}$)을 계산한다. 작은 Object에서 기준에 따라 결과가 달라지는지 보기 위해 IoU 0.3과 0.7에서도 함께 계산한다.

V4 Exact Match of Evidence IDs는 관계 판정의 근거로 연결한 ID 집합이 정답 집합과 **정확히** 같은지를 본다. Region도 같은 방식(같은 종류, IoU 0.5 이상)으로 짝짓되 V3에는 넣지 않는다. 근거가 될 수 있는 조합이 여럿이면 정답에 모두 등록하고, 그중 하나와 일치하면 성공이다. 분모는 정답이 P 또는 U이면서 근거가 필요한 판정 항목이다. V4가 필요한 이유는 다음 예시에 있다. R1을 P로 맞혔지만 근거로 엉뚱한 차량의 ID를 댄 답은 관계 점수에서는 맞지만 V4에서는 틀린다. 즉 "맞는 답을 틀린 이유로" 낸 경우를 잡아낸다.

7.4 C. 관계 판정 (V5–V9)

모든 장면의 네 관계를 같은 질문으로 채점하는 방식은 POPE의 고정 질문 원리를 따른 것이며[5], 여기에 공간 관계와 U를 더했으므로 원래 POPE 점수와는 다른 이름으로 보고한다.

대표 점수 V5 Relation Macro-F1. 관계 h와 상태 $c \in \{P, A, U\}$마다 "그 상태를 맞혔는가"를 따로 보아 F1을 구하고, 12개(4관계 × 3상태) F1을 똑같은 비중으로 평균한다.

$$F1_{h,c} = \frac{2\,TP_{h,c}}{2\,TP_{h,c} + FP_{h,c} + FN_{h,c}}, \qquad \text{V5} = \frac{1}{4}\sum_{h=1}^{4}\frac{1}{3}\sum_{c\in\{P,A,U\}} F1_{h,c}. \tag{1}$$

여기서 $TP_{h,c}$는 정답과 예측이 모두 c인 항목, $FP_{h,c}$는 다른 정답을 c로 예측한 항목, $FN_{h,c}$는 정답 c를 다른 것으로 예측한 항목(Invalid 포함)의 수다. 단순 정확도 대신 이 평균을 쓰는 이유는, 정답이 대부분 A인 관계에서 항상 A만 답해도 정확도는 높게 나오지만 P와 U의 F1이 0이 되어 V5가 낮아지기 때문이다. 어떤 상태의 정답이 하나도 없으면 그 F1과 전체 V5는 N/A로 두고, 정답이 있는 상태만 평균한 값을 진단용으로 따로 보인다.

진단 점수 V6–V9. V5가 낮을 때 어떤 종류의 오류인지 나누어 본다. 아래에서 y는 정답, $\hat{y}$는 예측이다.

점수	식	잡아내는 오류
V6 Recall for Present	$\#(y{=}P, \hat{y}{=}P) \,/\, \#(y{=}P)$	있는 위험 관계를 놓침
V7 False Positive Rate	$\#(y{=}A, \hat{y}{=}P) \,/\, \#(y{=}A)$	없는 위험 관계를 있다고 함
V8 Recall for Unknown	$\#(y{=}U, \hat{y}{=}U) \,/\, \#(y{=}U)$	판단할 수 없는 것을 단정함
V9 Over-abstention	$\#(y{\in}\{P,A\}, \hat{y}{=}U) \,/\, \#(y{\in}\{P,A\})$	판단할 수 있는데 "모름"으로 피함

예를 들어 어떤 관계에서 정답이 P인 항목 50개에 대해 모델이 P 35개, U 10개, Invalid 5개를 답했다면 V6은 $35/50 = 70\%$이다. U와 Invalid도 분모에 남아 놓친 것으로 세어지기 때문이다. V8과 V9를 함께

보는 이유는 둘이 서로 반대 방향의 실패이기 때문이다. 항상 U만 답하는 모델은 V8이 높지만 V9도 높아서 드러나고, U를 전혀 쓰지 않는 모델은 V9가 낮지만 V8이 0이 되어 드러난다. 판단 보류율과 오류를 함께 보아야 한다는 관점은 SelectiveNet 연구를 참고했다[7]. 다만 여기의 U는 사진의 정보 부족을 뜻하므로, 모델 확신도에 임계값을 두는 방식의 평가는 확신도 보정용 데이터가 따로 생긴 뒤에 추가한다.

7.5 D. 대응 판정 (V10–V12)

장면 i의 정답에는 허용 쌍 집합 A_i, 금지 쌍 집합 F_i, 필요 대응 묶음 $G_{i1}, \ldots, G_{im_i}$가 있고, 모델이 답한 (대응, 조건) 쌍의 집합을 S_i라 한다. 쌍의 형태로 비교하므로 같은 대응을 엉뚱한 조건에 붙인 답은 맞지 않는다.

대표 점수 V10 Action Pass Rate. 장면 i는 다음을 모두 만족할 때 통과한다($\mathrm{AP}_i = 1$).

$$\mathrm{AP}_i = \mathbf{1}\Big[\, V_i \;\wedge\; C_i \;\wedge\; S_i \subseteq A_i \;\wedge\; S_i \cap F_i = \varnothing \;\wedge\; \textstyle\bigwedge_{j=1}^{m_i} \big(S_i \cap G_{ij} \neq \varnothing\big)\Big], \qquad \mathrm{V10} = \tfrac{1}{N}\textstyle\sum_i \mathrm{AP}_i. \tag{2}$$

식의 각 조건을 말로 풀면 다음과 같다. V_i는 형식이 Valid하다는 뜻이다. C_i(일관성)는 답한 각 쌍의 조건 Code가 §4의 표에서 요구하는 정답 판정을 가지고 있고, 그 대응의 `based_on`이 그 조건이 기대는 관계를 가리키며, 같은 조건에서 서로 모순되는 쌍을 함께 답하지 않았다는 뜻이다. $S_i \subseteq A_i$는 허용된 쌍만 답했다는 뜻이고, $S_i \cap F_i = \varnothing$는 금지된 쌍이 없다는 뜻이며, 마지막 조건은 모든 필요 대응 묶음에서 하나 이상을 답했다는 뜻이다. 일관성 검사는 조건 Code와 정답 판정의 대응표 및 모순 쌍 목록으로 자동 판정하고, 규칙으로 판정하기 어려운 사례만 두 사람이 다시 본다.

예시 장면(그림 2)에 적용하면, 필요 대응 묶음은 {가림 조건의 `VERIFY_BEFORE_ADVANCE`}와 {좁아진 구간 조건의 `VERIFY_PASSAGE`} 두 개다. 그림 3의 답은 두 묶음을 모두 충족하므로 통과한다. 반면 `VERIFY_BEFORE_ADVANCE`만 답하면 두 번째 묶음을 놓쳐 실패하고, 여기에 `YIELD_IF_OCCUPIED`(점유 조건)를 더하면 R1의 정답이 A여서 그 조건을 붙일 근거가 없으므로 일관성에서 실패한다.

진단 점수. V11 Required Action Coverage는 전체 필요 대응 묶음 중 충족한 묶음의 비율로, "해야 할 것을 빠뜨렸는가"를 본다. 필요 대응이 없는 장면은 V11의 분모에서 빠지지만 V10에는 포함된다. V12 Disallowed Action Rate는 금지 쌍이 하나라도 있는 답의 비율로, "하면 안 되는 것을 했는가"를 본다. V11과 V12를 함께 보면 V10이 낮은 원인이 누락인지 과잉·부적절한 대응인지 가를 수 있다. 형식 오류인 답에서는 금지 쌍을 확인할 수 없으므로 V12는 V2, V10과 함께 읽는다.

V10은 우리가 정한 대응 규칙과 얼마나 일치하는지를 재는 점수이며, 실제 차량 제어 성능을 뜻하지 않는다. 실제 제어 성능은 별도의 주행 실험으로 검증해야 한다.

7.6 E. 진술 검수 (V13, V14)

모델의 답에 들어 있는 주장을 "보행자가 보인다"처럼 참·거짓을 따로 확인할 수 있는 최소 단위로 나눈 뒤, 사람이 사진과 대조한다. 오류는 세 종류로 기록한다. 보이지 않는 Object를 보인다고 한 것, 사진과 모순되는 공간 관계를 말한 것, 근거 없이 상태나 움직임을 단정한 것이다. V13은 검수한 진술 중 오류 진술의 비율이고, V14는 오류 진술이 하나라도 있는 답의 비율이다. 진술 단위와 응답 단위로 나누어 세는 방식은 CHAIR 연구의 집계 방식을 확장한 것이다[6]. 오류로 보이는 Object는 원본 사진을 다시 보아 정답 누락인지 실제 Hallucination(없는 것을 있다고 말함)인지 가린다. 진술을 아예 하지 않으면 V13은 N/A가 되지만, 그 답은 V5와 V10에서 실패하므로 말을 줄여 오류율만 낮추는 모델은 좋은 결과로 선택되지 않는다.

7.7 F. 통계: 점수 차이를 믿을 수 있는가

신뢰구간(Confidence Interval)은 표본이 달라졌다면 점수가 얼마나 달라질 수 있는지를 정해진 절차로 계산한 범위다. 점수 하나만 보고하면 50개 중 2개 차이와 같은 작은 차이도 개선처럼 보이므로, 모든 점수에 신뢰구간을 붙인다.

S1 Wilson 95% 신뢰구간은 장면마다 성공·실패가 하나씩 나오는 비율 점수에 쓴다[21]. 성공 수 k, 분모 n, $\hat{p} = k/n$, $z = 1.96$일 때

$$\mathrm{CI}_{95} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \tag{3}$$

이며, 예를 들어 90/100의 구간은 약 82.6%–94.5%다.

S2 Group 단위 Paired Bootstrap은 두 모델의 점수 **차이**의 신뢰구간에 쓴다. Bootstrap은 가진 표본에서 복원추출로 가상의 표본을 여러 번 다시 만들어 점수의 흔들림을 재는 방법이다. 같은 Group의 사진·질문·편집 사진을 한꺼번에 뽑아서 같은 영상의 Frame끼리 서로 닮은 점을 반영하고(Group 단위), 매번 두 모델에 똑같이 뽑힌 표본을 적용한다(Paired). 2,000번 반복해 얻은 차이 Δ^*의 2.5번째와 97.5번째 백분위수를 95% 구간으로 쓴다[10]. 어떤 반복에서 특정 상태의 정답이 0개가 되어 V5를 정의할 수 없으면, 그 반복을 버리지 않고 그 비율을 기록하며 V5의 구간은 N/A로 표시한다.

Test Bootstrap은 **평가 표본**의 흔들림만 반영하고 **학습**의 흔들림은 반영하지 않는다. 학습 Seed를 한 번만 썼다면 결과는 "그 한 번의 학습 결과에 대한 비교"라고 적고, 장비에 여유가 있으면 Seed 3개의 결과와 평균·표준편차를 함께 보인다.

7.8 결과를 보고 무엇을 고치는가

진단 점수는 다음 수정 대상을 고르기 위해 있다. 아래 표는 Dev에서 각 점수가 나쁠 때 먼저 볼 곳이다.

증상	먼저 점검할 곳
V2가 높다	출력 형식, 최대 출력 길이, Prompt의 Schema 설명
V3는 괜찮은데 V4가 낮다	관계와 근거 ID를 연결하는 학습 데이터와 Prompt
V6이 낮다	해당 관계의 P 표본과 Annotation 기준
V7이 높다	해당 관계의 A 표본, 특히 비슷하지만 해당하지 않는 경계 사례
V9가 높다	판단 가능한 장면에서 U를 고르는 경향, U 정답의 기준
V5는 괜찮은데 V10이 낮다	관계 판정에서 대응으로 넘어가는 조건 Code와 필요 대응 묶음

8 편집 사진 실험: 위치가 바뀌면 판단도 맞게 바뀌는가

같은 보행자를 다른 위치에 옮겨 놓은 사진을 만들어, 정답이 바뀐 만큼 모델의 판단도 맞게 바뀌는지 시험한다. 편집 과정 자체가 판단을 흔드는지는 보행자를 원래 자리에 다시 붙인 사진으로 따로 잰다. 편집 사진을 학습에 더하는 것이 도움이 되는지는 편집 사진이 아니라 **실제 사진** Test로만 판정한다.

8.1 왜 편집 사진이 필요한가

실제 사진끼리 비교하면 보행자 위치 말고도 배경, 조명, 다른 차량 등 모든 것이 다르다. 그래서 모델이 틀렸을 때 위치를 잘못 읽어서인지 다른 요소 때문인지 알 수 없다. 같은 사진에서 보행자 위치 **하나만** 바꾸면, 판단이 바뀌어야 할 이유는 위치 변화 하나뿐이다. 이것은 DriveBench가 같은 질문에 대해 사진 조건만 바꾸어 비교한 원리를 위치 관계로 옮긴 것이다[3]. 단, 편집 사진에는 합성 흔적이 남을 수 있으므로 학습 효과의 최종 판정에는 쓰지 않는다.

8.2 세 장의 사진과 비교 방법

원본 사진을 I^0, 보행자를 지운 배경에 같은 보행자를 **원래 자리에** 다시 붙인 사진을 I^s(Same-position Control), 같은 배경에 보행자를 **옮겨** 붙인 사진을 I^e(Edited)라 한다. I^s와 I^e는 같은 편집 과정을 거쳤고 보행자 위치만 다르다.

8.3 어떤 원본을 쓰고, 편집 사진을 어디에 넣는가

편집할 원본은 발까지 보이는 보행자, 정확한 Instance Mask(그 보행자에 속한 픽셀 표시), 평평한 지면, 단순한 배경, 약한 그림자를 갖춘 사진으로 한정한다. 발이 지면에 닿는 위치와 크기를 사람이 검수할 수 있어야 이동 전후의 정답을 확정할 수 있기 때문이다. 원본마다 보행자의 발을 놓을 수 있는 영역 P와 Driving Area C를 표시하고, 바꿀 것(보행자 위치, Box, R1의 정답)과 지킬 것(보행자의 모습·크기·자세, 다른 Object의 배치와 관계)을 미리 적는다. 제외한 원본은 제외 이유를 기록해, 결과가 검증된 편집 조건의 범위를 함께 보고한다.



그림 6. 원본·원위치 재합성·위치 이동의 세 사진. 파란 영역은 Driving Area이다. $(0, e)$ 쌍에도 E3을 계산하며, $(0, s)$에서 판단이 흔들리면 그 모델의 (s, e) 결과는 편집 흔적의 영향을 받았을 수 있다.

편집 사진은 원본의 Split과 Group을 그대로 이어받는다. Train 원본으로 만든 편집 사진만 학습 보강에 쓴다. Dev 원본 중 최대 20개는 편집 설정을 맞추고 오류를 진단하는 데만 쓴다. Test 원본 중 최대 40개로 만든 편집 사진은 고정한 절차로 **진단용 세트**를 이루며, 이 세트의 점수는 실제 사진 Test 점수와 섞지 않고 따로 보고한다.

8.4 만드는 절차

편집기는 원본 보행자 픽셀을 그대로 잘라 옮기는 Copy-Paste[8]와, 보행자를 뺀 자리만 주변에 맞게 다시 그려 채우는 SDXL Inpainting[20]을 결합한다. 보행자 픽셀을 다시 생성하지 않고 원본 그대로 쓰기 때문에 위치와 모습이 함께 바뀌는 일을 줄일 수 있다.

1. 원본에서 보행자 Mask와 잘라 낸 보행자 이미지를 얻고, 발이 지면에 닿는 점을 확인한다.
2. 높이(y), 크기, 회전, 자세는 그대로 두고 가로로만 옮긴다. 이동 거리는 사진 폭 W의 10% 이하($|\Delta x| \le 0.1W$)로 제한하고, 원본당 목표 위치 최대 3곳 × 난수 Seed 2개를 만든다. 목표 위치는 P 안에 있고, 다른 Object와 겹치지 않으며, C의 확실한 안쪽 또는 바깥쪽이어야 한다.
3. 보행자가 있던 자리(필요하면 그림자 포함)만 조금 넓혀 Inpainting으로 채운다. 초기 설정은 공식 예시의 20 Steps, Guidance 8.0, Strength 0.99이며, 1024픽셀 작업 크기에서 Mask 확장 약 8픽셀, 경계 보정 띠 3–5픽셀로 시작해 Dev에서 확정한다[20].
4. 채운 배경의 목표 위치에 원본 보행자를 붙이고, 경계의 좁은 띠만 보정한다.
5. 허용한 편집 영역 E(지운 자리, 붙인 자리, 경계, 그림자) 밖은 원본 픽셀로 되돌리고 무손실 PNG로 저장한다. 식으로는 $I^e = E \odot I^{\text{gen}} + (1 - E) \odot I^0$이며, $\odot$는 픽셀별 곱이다. 이렇게 하면 생성 과정에서 편집 영역 밖에 생긴 변화가 모두 사라지므로, 이후 "E 밖의 픽셀 차이가 0인가"를 Code로 직접 검사할 수 있다.

같은 높이를 유지하는 규칙은 원근 변화를 줄이기 위한 경험적 규칙일 뿐이므로, 최종 접지 위치와 크기가 자연스러운지는 사람이 확인한다. Dev에서 합성 품질이 병목으로 확인되면 대체 편집기 AnyDoor[9]를 비교하되, AnyDoor는 Object를 다시 생성하므로 모습과 자세가 보존되는지를 채택 기준으로 삼는다.

8.5 모델 답을 보기 전에 검수한다

검수는 모델에 사진을 넣기 **전에** 끝낸다. 모델이 잘 맞히는 편집 사진만 골라 남기는 일을 막기 위해서다. Code가 E 밖 픽셀 차이가 0인지, Mask와 Box가 맞는지, 지킬 Object가 보존되었는지 확인하고, 두 사람이 접지 위치, 원근, 잔상, 새로 생긴 Object, 지킬 관계의 보존, 정답의 명확성을 확인한다. 모든 항목을 통과한 세 장 묶음만 채택하며, 채택한 묶음은 원위치 재합성 사진에서 모델이 틀리더라도 모두 점수에 넣는다. E1은 생성 시도(실패와 재시도 포함) 중 채택된 비율이고, E2는 채택 묶음 하나당 GPU 시간과 사람 검수 시간이다. 두 값은 이 진단 자료를 얼마의 비용으로 얻을 수 있는지를 보여 준다.

8.6 Pair Accuracy (E3, E4)

응답이 **바뀌었는지**만 보면 바뀐 답이 틀린 경우를 놓친다. 그래서 두 사진의 정답을 **모두** 맞혔는지를 본다. Δ를 편집으로 정답이 바뀌는 항목, Γ를 정답이 그대로인 항목이라 할 때,

$$\mathrm{E3} = \frac{1}{N_{\mathrm{pair}}} \sum_{i} \mathbf{1}\big[V_i^u \wedge V_i^v \wedge \hat{y}_{i,\Delta}^u = y_{i,\Delta}^u \wedge \hat{y}_{i,\Delta}^v = y_{i,\Delta}^v\big], \tag{4}$$

$$\mathrm{E4} = \frac{1}{N_{\mathrm{pair}}} \sum_{i} \mathbf{1}\big[V_i^u \wedge V_i^v \wedge \hat{y}_{i,\Gamma}^u = \hat{y}_{i,\Gamma}^v = y_{i,\Gamma}\big] \tag{5}$$

이다. (u, v)는 비교하는 두 사진이며, E3은 $(0, e)$와 (s, e)에, E4는 $(0, s)$, $(0, e)$, (s, e)에 따로 계산한다. 한쪽이라도 형식 오류면 그 쌍은 실패다. E4에서 두 예측이 서로 같기만 하고 정답과 다르면 통과시키지 않는다.

기본 실험은 위치 이동뿐이며, 객체 제거·가림·배경 변경은 선택 확장이다. 확장할 때 정답은 §4의 규칙으로 갱신한다. 보행자를 지우면 그 보행자에 대한 판정은 바뀌지만 남은 가림과 통행 제한은 유지한다. 보행자를 완전히 가리면 R1·R2는 남은 보이는 대상으로 다시 판정하고, 가림 뒤 존재는 U, 가림 자체는 R3=P로 기록한다. 이때 E5는 가림 뒤 존재의 정답이 U인 항목에서 P나 A로 단정한 비율이며, R1–R4 점수와 따로 보고한다.

8.7 학습 보강을 채택하는 규칙

실제 사진만 학습한 조건(Real-only)과 편집 사진을 더한 조건(Real-plus-edited)을 같은 Base 모델, 같은 Optimizer Update 횟수, 같은 Batch 크기로 학습해, 추가 데이터 **양**이 아니라 **종류**의 효과만 비교한다. 채택 여부는 Dev의 실제 사진 점수로 정하고, 고른 설정의 효과를 freeze한 실제 사진 Test에서 최종 확인한다. 편집 사진의 Pair Accuracy만 오르고 실제 사진 점수가 오르지 않으면, 편집 사진은 학습 자료가 아니라 진단 자료로 유지한다.

9 재현과 Demo

점수가 바뀌었을 때 무엇이 바뀌어서인지 답할 수 있게, 실행 하나에 들어간 데이터·정답·Prompt·모델·채점 Code의 Version을 하나의 Run ID로 묶고, 검사→추론→채점→Report를 한 Script로 다시 실행할 수 있게 한다. Web Demo는 같은 Run의 기록을 읽어 보여 주므로, 발표 화면과 Report가 같은 결과를 설명한다.

9.1 실행 기록

한 번의 학습 또는 평가 실행마다 Run ID를 붙이고, 데이터 목록·Split·정답 파일의 Hash, 모델 Checkpoint와 Adapter, Prompt와 Output Schema, 전처리 설정, 난수 Seed, 편집 설정, 채점 Code Version, 장비·Library 정보를 함께 저장한다. Hash는 파일 내용으로 계산한 고유값으로, 파일이 바뀌었는지는 알려 주지만 무엇이 바뀌었는지는 알려 주지 않는다. 그래서 Hash와 함께 실제 설정값과 변경 내역도 저장한다. 이 구성은 데이터·모델 검증과 실행 Metadata를 연결하라는 Google Cloud MLOps 안내의 원칙을 최소 범위로 적용한 것이다[23].

9.2 재실행 Script

Script는 정해진 순서로만 실행된다. 먼저 사진과 정답의 ID가 대응하는지, 필수 설정이 있는지, Split 간 Group 중복이 0인지(L4) 검사한다. 통과하면 추론을 실행하고, 형식(V1, V2)을 검사한 뒤 §7의 채점 Code를 실행해 Report를 만든다. 추론 시간(T2)과 GPU Memory(T3)는 장비, 입력 크기, Batch, 출력 길이를 고정한 상태에서 재고, 모델 불러오기 시간과 API 통신 시간은 따로 잰다. 실패한 요청도 원래 응답과 오류 Code를 Run ID와 함께 남긴다.

9.3 Web Demo

Demo의 한 화면은 사진 한 장에 대한 판단 전체를 보여 준다. 원본 사진 위에 모델이 예측한 Box를 그리고, 옆에 R1–R4 판정, U의 이유, 조건부 대응을 보여 준다. 화면의 모든 Box에는 누가 그렸는지(모델, 외부

Detector, 사람)를 표시한다. 사람의 정답 Box는 기본 화면에 섞지 않고 별도 비교 화면에서만 보여 준다. 사람이 그린 Box를 모델이 찾은 것으로 오해하는 일을 막기 위해서다. 같은 이유로, 외부 Detector의 Box나 정답 Box를 모델 입력으로 준 실험은 각각 따로 이름을 붙여 기본 결과와 분리해 보고한다.

정답이 있는 Benchmark 사진에서는 예측과 정답의 차이, 적용한 채점 규칙, 오류 이유를 함께 보여 주고, 모델별 화면에는 V5와 V10을 중심으로 분모, Group 수, 신뢰구간, 장면 Category별 결과를 보인다. 사용자가 새로 올린 사진에는 정답이 없으므로 예측과 실행 시간만 보여 주고 점수는 계산하지 않는다. 새 사진에 사람이 정답을 달면 별도 Dataset Version으로 관리하며, freeze한 Test에 조용히 더하지 않는다.

10 일정, Gate, 위험 대응

첫 주에 "데이터가 충분한가"와 "장비에서 도는가"를 먼저 확인하고, 매주 끝에 다음 단계로 넘어갈지를 정하는 Gate를 둔다. 일정이 밀리면 확장 실험과 세부 Category부터 줄이고, 핵심 관계 네 개와 Test 검수 수준은 끝까지 지킨다.

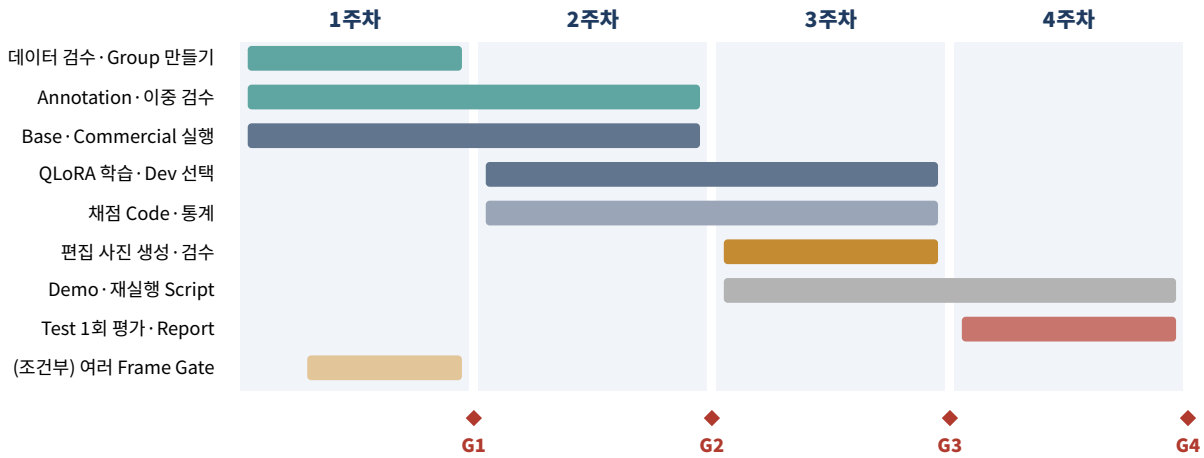


그림 7. 주별 작업과 Gate. 막대는 작업 기간이고, 마름모는 각 주 끝의 결정 시점이다.

주차	산출물	Gate에서 정하는 것
1주차	Metadata 색인, Group 목록, 층별 적합 비율(D1)과 추정 수량(D2), Pilot 50장면 Annotation과 일치도, 후보 모델 장비 시험 결과, Base 실행	**G1.** 관계 정의 · 조건 Code · Schema · 모델 계열 확정, Commercial 실행 가능 여부, 여러 Frame 실험 진행 여부
2주차	Group 단위 Split, Annotation v1, Base · Commercial의 Dev 결과, 첫 QLoRA 결과, 채점 Code	**G2.** Test freeze, Dev 오류에 따른 학습 · 편집 규칙 결정
3주차	Tuned 모델, 검수된 편집 묶음, Real-only 대 Real-plus-edited Dev 비교, Demo 연결	**G3.** 최종 설정 고정, 편집 사진의 학습 보강 채택 여부
4주차	Test 1회 평가, 신뢰구간, 오류 Report, 재실행 Package, Model Card · Dataset Card	**G4.** 같은 Script로 결과가 다시 나오는지 확인

위험	대응
쓸 수 있는 장면이 예상보다 적다	세부 Category 수와 확장 실험을 먼저 줄이고, 핵심 관계의 P/A/U 목표와 Test 검수 수준은 유지한다. 부족한 상태는 Report에 수집 대상으로 적는다.
Annotation 일치도가 낮다	혼동 표로 헷갈린 상태를 찾아 경계 사례를 Guideline에 추가하고 해당 장면을 다시 Annotation한다. 해결되지 않는 장면은 모호 장면으로 분리한다.
후보 모델이 장비에서 돌지 않는다	Gemma 3 4B-it로 바꾸거나 입력 해상도·Batch를 낮춘다. 바꾼 내용은 실행 기록에 남긴다.
데이터 이용 조건이 외부 API를 허용하지 않는다	사진을 외부로 보내지 않고 Commercial 조건을 "실행하지 않음"으로 보고한다.
여러 Frame 조건을 못 채운다	사진 한 장 결과로 확정하고, 필요한 Clip 조건과 부족 수량을 후속 명세로 낸다.
편집 사진 품질이 낮다	Dev에서 설정을 조정하거나 AnyDoor를 비교하고, 그래도 낮으면 편집 사진을 진단 자료로만 쓴다.

11 결과를 어떻게 해석할 것인가

"완료"와 "개선"을 다른 기준으로 판정한다. 완료는 제출물이 모두 갖추어졌는지로 판정하고, 개선은 대표 점수 두 개의 차이와 그 신뢰구간으로 판정한다. 결과가 기대와 다르더라도, 무엇을 주장할 수 있고 무엇은 주장할 수 없는지를 미리 정해 두면 해석이 흔들리지 않는다.

완료 기준. freeze한 Test와 Annotation Guideline, 채점 Code, 학습 전후 모델, 세 조건(또는 Commercial을 제외한 두 조건)의 Test 결과와 신뢰구간, 오류 Report, 같은 결과를 다시 만드는 Script와 Demo가 모두 있으면 완료다. 성능 향상은 완료 기준에 넣지 않는다.

개선이라고 말하는 기준. Tuned와 Base의 V5 차이와 V10 차이의 Paired Bootstrap 95% 구간이 **둘 다** 0보다 위에 있고, R1–R4의 V6 차이와 V7 차이 중 어느 것도 구간 전체가 나빠지는 방향에 있지 않을 때, 그 Test에서 개선되었다고 보고한다. 한 점수의 구간만 0보다 위에 있으면, 그 능력에 한정해 개선을 말하고 다른 점수와의 Trade-off를 적는다. 구간이 0을 포함하면 "차이를 확인하지 못했다"고 적고, 구간을 좁히는 데 필요한 관계·상태의 추가 표본 수를 제시한다.

주장하지 않는 것. 이 Benchmark는 위험 장면과 P/A/U를 의도적으로 균형 있게 모은 시험이므로, 여기서 나온 Precision 같은 점수는 이 시험 분포에서의 값이며 실제 도로에서의 빈도를 대표하지 않는다. V10은 우리가 정한 대응 규칙과의 일치도이며 차량 제어 성능이 아니다. 편집 사진에서의 성능 향상만으로는 실제 사진에서의 개선을 주장하지 않는다. 학습 Seed를 한 번만 쓴 비교는 그 한 번의 학습 결과에 대한 비교로만 적는다.

마무리. 이 판단 결과를 Model Card와 Dataset Card에 남기는 것으로 한 달 프로젝트를 마친다. 그러면 다음 팀이나 기업은 같은 기준에서 데이터나 모델 하나만 바꾸어 실험을 이어 갈 수 있다.

A 점수 전체 표

모든 점수의 정의를 한곳에 모았다. "단계"는 그 점수를 계산하는 시점이다(1: 데이터 선별, 2: Annotation·분할, 3: 학습·선택, 4: 평가, 5: 편집 실험, 6: 재현). 대표 점수는 굵은 글씨로 표시했다.[1]

ID	이름	식	분모와 뜻	단계
데이터와 정답				
D1	Eligible Proportion	$\hat{q}_s = a_s / m_s$	층 s에서 검수한 Group 중 과제 조건에 맞는 비율	1
D2	Estimated Eligible Count	$\hat{N} = \sum_s N_s \hat{q}_s$	쓸 수 있는 Group 수의 추정치	1
D3	Number of Groups	$\lvert\{\text{group_id}\}\rvert$	서로 다른 촬영 묶음 수. 사진 수·질문 수와 따로 보고	1–6
L1	Raw Agreement	$n_{\text{agree}} / n_{\text{double}}$	합의 전 두 사람의 P/A/U 일치 비율	2
L2	Cohen's κ	$(p_o - p_e)/(1 - p_e)$	우연 일치를 뺀 일치도. $p_e = 1$이면 N/A	2
L3	Samples per Relation–State	n_{hc}, g_{hc}	관계 h·상태 c별 장면 수와 Group 수	2, 4
L4	Split Overlap	$\lvert G_a \cap G_b \rvert$	모든 Split 쌍에서 0이어야 함	2, 6
학습과 실행 비용				
T1	Training Loss	$-\frac{1}{T}\sum_t \log p_\theta(y_t \mid x, y_{<t})$	정답 출력 Token T개의 평균. 학습 진행 확인용	3
T2	Inference Latency	$Q_{.50}(t_i)$, $Q_{.95}(t_i)$	모델 불러오기 이후 요청별 시간의 중앙값·95번째 백분위수	3, 6
T3	Peak GPU Memory	$\max_t M(t)$	측정 구간의 최대 GPU Memory. 측정 방식 명시	3, 6
형식과 근거				
V1	Valid Output Rate	N_{valid} / N	형식이 맞는 답의 비율	3–5
V2	Invalid Output Rate	$1 - \text{V1}$	형식 오류와 Timeout의 비율	3–5
V3	Object P / R / F1	$\frac{2TP}{2TP+FP+FN}$ 등	Class 일치·IoU≥0.5 일대일 짝짓기	4
V4	Evidence ID Exact Match	$\frac{1}{K}\sum \mathbf{1}[\hat{E}_{ih} \in E^*_{ih}]$	근거가 필요한 P/U 판정 K개 중 근거 ID 집합이 정확히 맞은 비율	4
관계 판정				
V5	**Relation Macro-F1**	$\frac{1}{4}\sum_h \frac{1}{3}\sum_c F1_{h,c}$	4관계 × 3상태 F1의 균등 평균	3–5
V6	Recall for Present	$\#(P \to P)/\#(y{=}P)$	있는 관계를 놓치지 않는 정도	3–5
V7	False Positive Rate	$\#(A \to P)/\#(y{=}A)$	없는 관계를 있다고 하는 정도	3–5
V8	Recall for Unknown	$\#(U \to U)/\#(y{=}U)$	판단할 수 없는 것을 모른다고 하는 정도	4
V9	Over-abstention	$\#(\{P, A\} \to U)/\#(y{\in}\{P, A\})$	판단할 수 있는데 피하는 정도	4
대응과 진술				
V10	**Action Pass Rate**	$\frac{1}{N}\sum_i \text{AP}_i$	형식·일관성·허용·금지·필요 대응을 모두 통과한 비율	3–5
V11	Required Action Coverage	$\sum_{i,j} r_{ij} / \sum_i m_i$	필요 대응 묶음 중 충족한 비율	4

[1] 기존 Blueprint의 Risk Macro-F1과 ActionPass는 각각 이 문서의 Relation Macro-F1(V5)과 Action Pass Rate(V10)이다. 기존 Methods Notes의 Macro-F1 across Relations and Classes와 Action Rule Compliance Rate도 같은 점수다.

ID	이름	식	분모와 뜻	단계
V12	Disallowed Action Rate	$\frac{1}{N}\sum_i \mathbf{1}[B_i]$	금지 쌍이 하나라도 있는 답의 비율	4
V13	Statement Error Rate	$\sum_{i,k} e_{ik} / \sum_i K_i$	검수한 최소 진술 중 오류 진술 비율	4
V14	Response Error Rate	$\frac{1}{N}\sum_i \mathbf{1}[\sum_k e_{ik} > 0]$	오류 진술이 하나라도 있는 답의 비율	4
편집 실험				
E1	Acceptance Rate	$N_{\text{acc}}/N_{\text{attempt}}$	생성 시도 중 검수 통과 비율	5
E2	Time per Accepted Sample	T/N_{acc}	채택 묶음당 GPU 시간·검수 시간	5
E3	Pair Accuracy (changed)	식 (4)	정답이 바뀌는 항목을 두 사진 모두 맞힌 비율	5
E4	Pair Accuracy (unchanged)	식 (5)	정답이 그대로인 항목을 두 사진 모두 맞힌 비율	5
E5	Hidden-object Assertion	N_{assert}/N_U	가림 뒤 존재가 U인데 P/A로 단정한 비율(선택)	5
통계				
S1	Wilson 95% CI	식 (3)	장면당 성공/실패 하나인 비율 점수	1, 4, 5
S2	Paired Bootstrap CI	$[Q_{.025}(\Delta^*), Q_{.975}(\Delta^*)]$	Group 단위 2,000회 복원추출로 구한 두 모델 차이의 구간	4, 5

B 용어 설명

AI·통계를 전공하지 않은 독자를 위해, 이 문서에 나오는 용어를 본문에서 쓰인 뜻으로 설명한다.

용어	뜻
VLM	Vision-Language Model. 사진과 글을 함께 입력받아 글로 답하는 AI 모델이다.
Benchmark	여러 모델을 같은 조건에서 비교하기 위한 고정된 시험지(데이터)와 채점 기준의 묶음이다.
Annotation	사람이 사진에 정답(Box, 관계 판정, 대응 규칙)을 다는 작업이다. 그 결과를 정답(Reference Label)이라 한다.
Annotation Guideline	Annotator가 같은 기준으로 정답을 달도록 규칙과 예시를 적은 문서다.
Taxonomy	무엇을 어떤 이름으로 기록할지 정한 분류 체계다.
Bounding Box (Box)	사진에서 대상을 둘러싸는 직사각형이다.
IoU	Intersection over Union. 두 Box가 겹친 면적을 두 Box를 합친 면적으로 나눈 값으로, 1이면 완전히 겹친다.
Fine-tuning	이미 학습된 모델을 우리 데이터로 조금 더 학습시키는 것이다.
LoRA / QLoRA	원래 모델은 그대로 두고 작은 Adapter만 학습하는 방법(LoRA)과, 원래 모델을 4-bit로 압축해 Memory를 더 줄인 방법(QLoRA)이다.
Checkpoint	학습 중 특정 시점에 저장한 모델 Weight와 설정이다.
Zero-shot	정답 예시 없이 지시문만 주고 답하게 하는 방식이다.
Prompt	모델에 주는 지시문이다.
JSON / Output Schema	JSON은 이름–값 쌍의 텍스트 형식이고, Output Schema는 그 JSON에 들어갈 필드·자료형·허용값을 정한 명세다.
Train / Dev / Test	각각 학습용, 설정 선택용(Validation), 최종 비교용 데이터다.

용어	뜻
Group	같은 영상이나 연속 촬영 구간에서 나온 사진들의 묶음이다. 데이터를 나누고 통계를 낼 때 한 단위로 다룬다.
TP / FP / FN	맞게 찾은 것(True Positive), 잘못 찾은 것(False Positive), 놓친 것(False Negative)이다.
Precision / Recall / F1	Precision은 찾은 것 중 맞은 비율, Recall은 있어야 할 것 중 찾은 비율, F1은 둘의 조화평균이다.
Macro-F1	여러 범주의 F1을 범주 크기와 관계없이 똑같은 비중으로 평균한 값이다.
Hallucination	사진에 없는 것을 있다고 말하는 오류다.
신뢰구간 (CI)	표본이 달라졌다면 점수가 얼마나 달라질 수 있는지를 정해진 절차로 계산한 범위다.
Bootstrap	가진 표본에서 복원추출을 반복해 점수의 흔들림을 재는 방법이다.
Cohen's κ	두 사람의 판정 일치도에서 우연히 일치할 몫을 뺀 값이다. 1이면 완전 일치, 0이면 우연 수준이다.
Inpainting	사진의 지정한 영역을 주변과 어울리게 새로 그려 채우는 방법이다.
Copy-Paste	Mask로 잘라 낸 Object 픽셀을 다른 위치에 붙이는 합성 방법이다.
Seed	난수 생성의 시작값이다. 같은 Seed와 같은 조건이면 같은 결과를 재현하기 쉽다.
Hash	파일 내용으로 계산한 고유값으로, 파일이 바뀌었는지 확인하는 데 쓴다.
MLOps	모델 개발에 쓰는 데이터·Code·실험을 관리하고 자동화하는 방법이다.

C 1주차에 확정하는 항목

다음 항목은 현재 시작값만 정해져 있고 1주차 결과로 확정한다. 담당은 기존 기획안의 역할 분담을 따른다.

항목	현재 시작값	확정 근거	담당
장면 수와 Split	Train 150 / Dev 50 / Test 200	D1·D2 추정치와 관계별 P/A/U 확보량	한태문
R2 "주변", R4 "좁아짐" 기준	출입구 Region 경계 접촉, 정성 판정	Pilot 50장의 경계 사례와 일치도	한태문
조건 Code 목록	다섯 개(§4)	Pilot에서 누락 조건 확인	윤유경
R2 필요 대응	`MONITOR_AHEAD` 또는 `REDUCE_SPEED_IF_MOVING`	Pilot 장면 검토	윤유경
모델 계열	Gemma 4 E2B-it (대안 Gemma 3 4B-it)	T2·T3·V1 장비 시험	하경흠
Commercial 모델과 예산	미정	AI Hub 이용 조건, 호출 단가와 한도	문혜승
Region IoU 기준	0.5	Dev에서 고정	하경흠
여러 Frame 실험 여부	Gate 조건 세 가지	Clip 30개·1.5초·장비 실행 확인	한태문·하경흠
편집 설정	20 Steps, Guidance 8.0, Strength 0.99	Dev의 E1과 합성 흔적	하경흠

D 참고 자료와 쓰인 곳

아래 표는 각 문헌에서 무엇을 가져왔고 무엇을 이번 과제에 맞게 바꾸었는지를 정리한 것이다. Relation Macro-F1과 P/A/U 체계, Action Pass Rate, 표본 목표, 세 장 편집 비교의 구체적인 조합은 이 기획의 제안이다.

출처	가져온 것	바꾼 것과 쓰인 곳
DriveBench[3]	정상·손상·검은 화면 사진에 같은 질문을 하는 비교, 정답 분포 편향 분석	사진 조건만 바꾸는 비교 원리를 위치 편집으로 옮기고, 정답이 바뀌어야 하는지까지 채점한다(§1, §8).
DriveLM[4]	인지–예측–계획을 이어 묻는 Graph VQA	Object/Region → 관계 → 대응을 ID로 잇는다. 사진 한 장 범위에 맞춰 움직임 예측보다 관측과 조건부 대응을 우선한다(§3).
POPE[5]	모든 사진에 같은 존재 질문을 하는 고정 질문 평가	존재를 공간 관계로 넓히고 U를 추가했으므로 다른 이름으로 보고한다(V5–V9).
CHAIR[6]	Object 단위·문장 단위 Hallucination 집계	공간 관계와 근거 없는 움직임 단정까지 넓혀 V13·V14로 보고한다.
SelectiveNet[7]	판단 보류 비율과 오류를 함께 보는 관점	여기의 U는 사진 정보 부족이므로 확신도 기반 보류와 구분한다(V8, V9).
Copy-Paste[8]	Mask로 Object를 잘라 붙이는 합성	배치 가능 영역, Driving Area, 사람 검수를 더한다(§8).
AnyDoor[9]	참조 Object를 지정 영역에 생성하는 편집	합성 품질이 병목일 때만 비교한다.
rliable[10]	점수와 구간을 함께 보고하는 원칙	Group 단위 Paired Bootstrap 2,000회로 적용한다(S2).
NIST, scikit-learn[21, 22]	Wilson 구간, Cohen's κ의 정의	S1·L2에 그대로 쓰고 기준값은 프로젝트 운영값으로 정한다.
LoRA, QLoRA, Gemma 문서 [11, 12, 17, 18, 19]	Adapter 학습, 4-bit 양자화, 모델 사양, 공식 학습 예시	후보 모델과 두 가지 학습 설정을 정한다(§6).
AI Hub[13, 14, 15, 16]	데이터 형식, Metadata, 수량	후보를 걸러 내고 실제 적합성은 표본 검수로 확정한다(§5).

참고 문헌

[1] 카카오모빌리티 산학협력 과제 소개 자료 및 질의응답(팀 제공 자료). Taxonomy, Tracking, 데이터 접근, MLOps에 관한 전달 내용.

[2] 데일리안, 경찰청·도로교통공단 2017–2021년 교통사고 자료 인용 보도. https://m.dailian.co.kr/news/view/1109416

[3] S. Xie et al. Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives. ICCV, 2025. https://arxiv.org/abs/2501.04003

[4] C. Sima et al. DriveLM: Driving with Graph Visual Question Answering. ECCV, 2024.

[5] Y. Li et al. Evaluating Object Hallucination in Large Vision-Language Models. EMNLP, 2023. https://aclanthology.org/2023.emnlp-main.20/

[6] A. Rohrbach et al. Object Hallucination in Image Captioning. EMNLP, 2018. https://aclanthology.org/D18-1437/

[7] Y. Geifman and R. El-Yaniv. SelectiveNet: A Deep Neural Network with an Integrated Reject Option. ICML, 2019.

[8] G. Ghiasi et al. Simple Copy-Paste Is a Strong Data Augmentation Method for Instance Segmentation. CVPR, 2021.

[9] X. Chen et al. AnyDoor: Zero-shot Object-level Image Customization. CVPR, 2024.

[10] R. Agarwal et al. Deep Reinforcement Learning at the Edge of the Statistical Precipice. NeurIPS, 2021. https://agarwl.github.io/rliable/

[11] E. J. Hu et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.

[12] T. Dettmers et al. QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS, 2023.

[13] AI Hub. 생활도로 객체인식 자율주행 데이터 (71784). https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=71784

[14] AI Hub. 교통사고 영상 데이터 (597). https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=597

[15] AI Hub. 사고위험 환경에서의 운전습관 데이터 (71851). https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71851

[16] AI Hub. 실도로 위험상황 시뮬레이션 데이터 (71854). https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71854

[17] Google. Gemma 4 Model Card. https://ai.google.dev/gemma/docs/core/model_card_4

[18] Google. Gemma 3 Model Card. https://ai.google.dev/gemma/docs/core/model_card_3

[19] Google. Vision fine-tuning with QLoRA (Gemma). https://ai.google.dev/gemma/docs/core/huggingface_vision_finetune_qlora

[20] Diffusers. stable-diffusion-xl-1.0-inpainting-0.1 Model Card. https://huggingface.co/diffusers/stable-diffusion-xl-1.0-inpainting-0.1

[21] NIST/SEMATECH. Confidence Limits for a Proportion. e-Handbook of Statistical Methods. https://www.itl.nist.gov/div898/handbook/prc/section2/prc241.htm

[22] scikit-learn. cohen_kappa_score. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.cohen_kappa_score.html

[23] Google Cloud. MLOps: Continuous Delivery and Automation Pipelines in Machine Learning. Architecture Center.