1 Taxonomy

Taxonomy는 역할이 다른 두 구조로 나눈다. **Scene Annotation**은 도로 구조·통행 규칙·관측 환경·Object·관계·시간 정보를 한 장면에 여러 속성의 조합으로 기록한다. **Model의 판단 과정**은 제공된 입력 → 관측 근거 → 관계 판단 → 조건부 대응의 순서를 따른다.

모델의 입력은 전방 카메라 사진 한 장과 진행 가정 `follow_visible_road_forward`(보이는 도로를 따라 앞으로 진행하려 한다)이다.

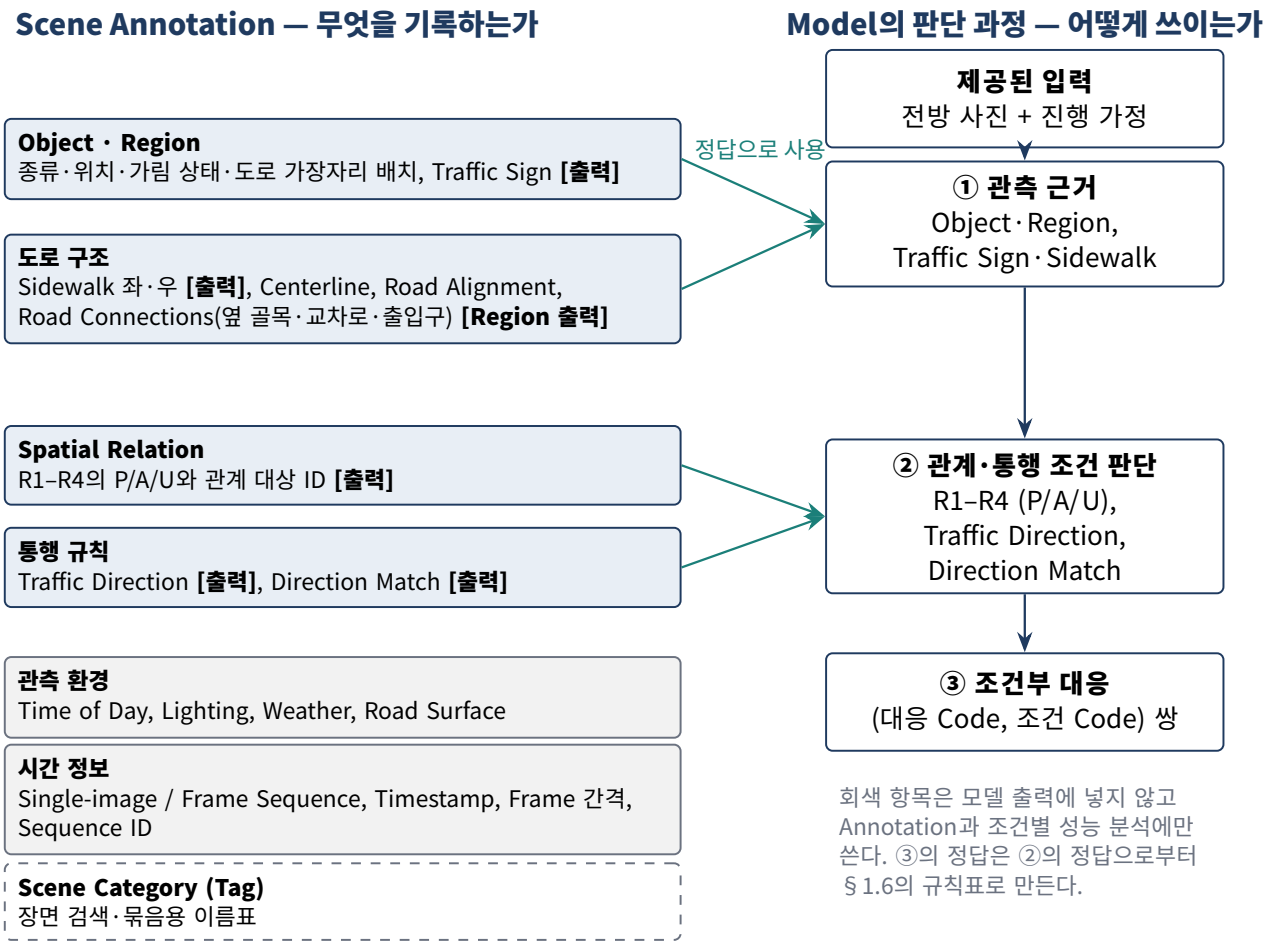


그림 1. Taxonomy의 두 구조. 왼쪽은 장면마다 기록하는 속성이고, **[출력]** 표시가 있는 것만 모델이 예측하고 채점받는다. 오른쪽은 그 정보가 판단에 쓰이는 순서다. P/A/U는 각 관계의 정답 Label이고, 대응은 판단 결과에 따른 Output이다.

1.1 Scene Annotation 항목

한 장면에 여러 속성을 함께 기록한다. 예를 들어 "보도 없는 야간 일방통행 도로의 양측 길가 차량"은 좌·우 Sidewalk = Absent, Traffic Direction = One-way, Time of Day = Night, 도로 가장자리 Vehicle 배치 = 양측이라는 속성의 조합으로 나타낼 수 있다. 가림과 통행 제약은 장면 하나의 속성이 아니라 특정 Object와 영역 사이의 관계이므로, 이 표가 아니라 §1.4의 관계 항목(R3, R4)에서 대상 ID와 함께 다룬다.

기록하는 항목은 두 가지 용도로 나뉜다. **모델 출력** 항목은 모델이 예측하고 채점받는 항목이다. **분석 전용** 항목은 사람이 기록만 하고 모델은 예측하지 않는 항목으로, 결과를 조건별로 나누어 모델이 어떤 환경에서 약한지 찾는 데 쓴다. 예를 들어 Time of Day를 기록해 두면 "야간 장면에서 위험을 더 자주 놓치는가"를 확인할 수 있고(§2.7), 이것이 어떤 조건의 데이터를 보강할지 정하는 근거가 된다. 아래 표의 마지막 열이 각 항목의 용도이며, 그림 1에서 **[출력]** 표시가 있는 상자와 회색 상자가 각각 이 둘에 해당한다.

분류 항목	기록할 값	작성 기준	용도
Sidewalk	좌·우 각각 Present / Absent / Unknown	지정한 진행 구간에서 보도 유무를 확인한다. 한쪽이 가려지면 그쪽만 Unknown이다.	모델 출력

분류 항목	기록할 값	작성 기준	용도
Centerline	Present / Absent / Unknown	중앙선의 존재를 기록한다. 이 값으로 일방통행 여부를 대신 판정하지 않는다.	분석 전용
Road Alignment	Straight / Curved / Unknown	도로가 곧은지 굽었는지를 기록하며, Driving Area(§1.3)를 그릴 때 참고한다.	분석 전용
Road Connections	옆 골목, 교차로, 차량 출입구, 건물 출입구	연결부마다 종류와 Region ID를 기록한다.	모델 출력 (Region)
Traffic Direction	One-way / Two-way / Unknown	진행하려는 도로 구간에 적용되는 규칙과 그 확인 근거(표지 Object ID 등)를 기록한다.	모델 출력
Direction Match	Consistent / Conflicting / Unknown / Not applicable	확인된 일방통행 방향과 진행 가정의 일치 여부다. 판정 규칙은 §1.5에 있다.	모델 출력
Time of Day	Day / Twilight / Night / Unknown	시간대를 기록한다. 정확한 촬영 시각은 Timestamp로 따로 저장한다.	분석 전용
Lighting	낮은 조도, 역광, 강한 눈부심 각각의 Present / Absent / Unknown	시간대와 별도로 기록한다.	분석 전용
Weather	강수(비·눈), 안개 각각의 Present / Absent / Unknown	젖은 노면만으로 지금 비가 온다고 판정하지 않는다.	분석 전용
Road Surface	건조, 젖음, 고인 물, 눈 덮임	상태가 다른 영역은 Region별로 기록한다. 실제 마찰계수는 기록 대상이 아니다.	분석 전용
Objects	종류, 위치(Box), 가림 상태, 도로 가장자리 배치	보행자·차량·자전거/이륜차 외에 판단 근거로 쓰는 교통표지도 포함한다.	모델 출력
Temporal Information	Single-image / Frame Sequence, Timestamp, Frame 간격, Sequence ID	어떤 시간 근거가 제공되는지 기록한다.	분석 전용

모델 출력 항목은 다음 기준으로 골랐다. Traffic Direction과 Direction Match는 그 방향으로 진행해도 되는지를 바꾸므로 대응 평가와 직접 이어진다. Sidewalk는 이 프로젝트의 주 대상인 "보도 없는 도로"를 모델이 구분하는지 확인하기 위한 항목이며, 첫 달의 대응 규칙에는 쓰지 않는다. Objects와 Road Connections는 관계 판정의 근거가 되는 대상이므로 모델이 직접 찾아야 한다. 분석 전용 항목은 모델이 예측하지 않지만, 모델이 설명 문장에서 "비가 오고 있다"처럼 스스로 언급하면 그 진술이 사진과 맞는지는 검수한다(V13, V14).

이와 별도로, 장면을 수집하고 묶기 위한 Tag를 붙인다. Tag는 혼재 통행, 도로 가장자리 차량 주변, 출입구 주변, 좁은 통행 공간, 이륜차 근접의 다섯 가지이며, 정답이나 채점 대상이 아니다. 차량 관련 Tag를 "주정차 차량"이 아니라 "도로 가장자리 차량"이라고 부르는 이유는, 사진 한 장으로는 차량이 정지해 있는지 확인할 수 없어서 보이는 위치만으로 이름을 붙이기 때문이다.

1.2 값과 함께 그 값을 알게 된 근거를 기록한다

모델의 정답은 모델이 받은 입력, 즉 사진 한 장으로 알 수 있는 것만으로 정한다. 같은 장면이라도 "데이터셋이 알고 있는 사실"과 "사진으로 알 수 있는 사실"이 다를 수 있기 때문이다. 이 둘을 구분하기 위해 각 속성에는 값 하나만 적지 않고, Value(검수한 값), Source(확인에 쓴 자료: Image, Frame Sequence, Dataset Metadata), Evidence(근거가 된 Region·Object·Frame·Metadata Field의 ID), Annotation Status(작성·검수 완료 여부), Model Input 포함 여부(그 근거를 모델도 받았는지)를 함께 저장한다.

예를 들어 Metadata에는 일방통행으로 적혀 있지만 사진에는 판독 가능한 표지가 없다면, 데이터셋에서 확인한 규칙은 One-way(출처: Metadata)로 기록해 조건별 분석에 쓰고, 사진만 입력하는 평가에서 모델의 정답은 Unknown으로 둔다. 이 장면에서 모델이 One-way라고 답하면 사실과는 맞더라도 사진에 근거가 없는 단정이므로 오답이다. Metadata를 입력으로 주는 실험을 따로 할 때는 그 입력 조건에 맞는 정답을 별도로 만든다.

정상적인 값을 적을 수 없는 경우는 세 가지로 구분한다. **Unknown**은 검수했지만 제공된 정보로 판단하기 어렵다는 뜻이고, **Missing**은 아직 작성하지 않았거나 검수가 끝나지 않았다는 뜻이며, **Not applicable**은 그 표본에 해당하지 않는 질문이라는 뜻이다. 세 경우는 처리 방법이 다르다. Unknown은 정답의 하나로 채점하고, Missing은 Unknown 정답으로 학습시키지 않으며 채점에서도 제외하고, Not applicable은 그 질문의 분모에서 뺀다. 또한 한 속성이 Unknown이라고 해서 다른 항목의 판정까지 Unknown으로 바꾸지 않는다. 예를 들어 통행

규칙이 Unknown이어도 R1–R4는 사진에서 보이는 대로 판정한다.

1.3 Driving Area: 관계 판정의 기준 영역

R1–R4는 모두 Driving Area(이하 C)를 기준으로 판정한다. C는 가정한 진행 방향과 도로 구조를 기준으로 정한 **평가 영역**으로, Annotator가 보이는 도로 경계, Road Alignment, 도로가 이어지는 방향을 보고 사진 위에 다각형(Polygon)으로 그린다.

C는 "보행자나 장애물을 피해 실제로 지나갈 경로"가 아니다. Annotator가 보행자를 피하도록 C를 고쳐 그리면 그 보행자는 항상 C 밖에 있게 되어, "보행자가 진행 공간을 점유하는가"(R1)라는 질문이 의미를 잃기 때문이다. 그래서 C는 Object를 보기 전에 도로 구조만으로 정하고, 진행 대상 구간과 경계 작성 기준은 Guideline에 그림 예시와 함께 명시한다. C는 정답을 만들고 채점할 때만 쓰며 모델에는 주지 않는다.

1.4 네 가지 관계 R1–R4와 P/A/U

R1–R4는 모델이 판정하는 위험 관계이며, 어떤 대응이 필요한지를 정하는 근거가 된다. 네 관계는 **사진 위에서 근거를 짚을 수 있고**, **서로 다른 대응으로 이어진다**는 두 조건을 만족하도록 골랐다. 충돌 확률처럼 속도·거리·시간이 있어야 정할 수 있는 항목은 사진 한 장으로 검수할 수 없으므로 넣지 않았다.

관계 이름만 주면 Annotator마다 서로 다른 대상을 떠올릴 수 있으므로, 각 관계는 무엇과 무엇 사이의 관계인지를 정하고 그 대상의 ID와 판정 근거를 함께 기록한다. 아래 표에서 **Actor**는 보행자·차량·자전거처럼 도로를 이용하는 주체이고, **Obstacle**은 움직이지 않는 장애물이며, **Footprint**는 대상이 지면에 닿은 부분이다.

관계	판정 질문	함께 기록할 대상과 근거	판정 기준
R1 점유	보이는 Actor 또는 Obstacle이 C를 점유하는가?	점유하는 Object ID, C의 해당 구간, 점유 판정의 근거	Footprint가 C 안에 있으면 점유로 본다.
R2 출입구	C와 이어지는 출입구 주변에 보이는 Actor가 있는가?	Actor의 Object ID, 출입구 Region ID, 그 출입구가 C와 이어진다는 근거	Footprint가 출입구 Region 안에 있거나 경계에 닿아 있으면 "주변"으로 본다. 현재 위치만 묻고 움직임 예측은 묻지 않는다.
R3 가림	진행 판단에 필요한 영역의 시야가 Object에 가려져 있는가?	가리는 Object ID, 가려진 Region ID, 그 영역을 확인해야 하는 이유	가려진 곳에 실제로 누가 있는지는 R3가 아니라 별도 주장으로 다룬다.
R4 통행 제한	보이는 Object의 배치가 C 구간의 통행 공간을 제한하는가?	제약을 만드는 Object ID, 영향을 받는 C의 구간, 관측되는 공간 제약	정확한 폭을 재지 않고 제약이 있는지만 판정한다. 실제로 지나갈 수 있는지는 대응(`VERIFY_PASSAGE`)에서 다루므로, R4=P와 "통과 가능성 미확인"은 함께 성립할 수 있다.

각 관계는 다음 셋 중 하나로 판정한다. **P**(Present)는 그 관계가 성립한다는 근거가 사진에 있다는 뜻이고, **A**(Absent)는 관련 영역과 Object를 충분히 볼 수 있어서 그 관계가 **없다고** 판정할 수 있다는 뜻이며, **U**(Unknown)는 사진의 정보만으로는 있다고도 없다고도 판정할 수 없다는 뜻이다. U는 "모델이 자신이 없다"가 아니라 "사진에 정보가 없다"는 뜻이며, 사람이 사진만 보고 정한 정답의 하나다.

장면 단위 판정 규칙. 한 장면에 관련 대상이 여럿이면, 관계를 만족하는 대상이 하나라도 명확할 때 **P**, 명확한 **P**가 없고 판정이 풀리지 않은 대상이 남아 있을 때 **U**, 관련 대상을 모두 확인했고 모두 해당하지 않을 때 **A**로 정한다.

보이는 것과 숨은 것의 분리 규칙. "보이는 Actor가 있다"와 "가림 뒤에 Actor가 있다"는 서로 다른 주장이다. 완전히 가려진 보행자에 대해 R1·R2는 남은 **보이는** 대상만으로 판정하고, "가림 뒤 Actor 존재"라는 별도 주장은 **U**로 기록하며, 가림 자체는 R3=**P**로 기록해 확인 대응을 요구한다. 숨은 Actor의 존재 주장은 V5에 넣지 않고 진술 검수(V13, V14)에서 따로 채점한다.

1.5 Direction Match 판정 규칙

Direction Match는 확인된 일방통행 방향과 진행 가정이 일치하는지를 나타내며, Traffic Direction 값에 따라 다음과 같이 정한다. Traffic Direction이 Two-way이면 일방통행 비교가 적용되지 않으므로 **Not applicable**이다. One-way이고 일방통행 방향이 진행 가정과 같으면 **Consistent**, 반대면 **Conflicting**, 일방통행이라는

것은 확인되지만 방향을 판독할 수 없으면 **Unknown**이다. Traffic Direction 자체가 Unknown이면 Direction Match도 **Unknown**이다. 두 값 모두 근거 ID(예: 일방통행 표지의 Object ID)를 함께 기록하며, 중앙선의 유무만으로 일방통행 여부를 대신 판정하지 않는다.

1.6 대응 규칙

모델의 대응이 맞는지는 장면마다 미리 적어 둔 대응 규칙으로 판정한다. 대응은 **대응 Code**와 **조건 Code**의 쌍으로 표현한다. 같은 "감속"이라도 어떤 상황에 붙였는지가 다르면 다른 답이기 때문이다. 대응 Code는 `VERIFY_BEFORE_ADVANCE`(확인 후 진행), `REDUCE_SPEED_IF_MOVING`(이동 중이면 감속), `YIELD_IF_OCCUPIED`(점유 시 양보), `HOLD_UNTIL_CLEAR`(해소될 때까지 보류), `VERIFY_PASSAGE`(통과 가능성 확인), `MONITOR_AHEAD`(전방 관찰), `ADVANCE_WITH_MONITORING`(관찰하며 진행)의 일곱 가지다.

조건 Code는 그 대응을 어떤 관측 상황에서 하는지를 정한다. 각 조건 Code는 특정 관계의 정답이 있어야만 쓸 수 있으므로, "이 조건을 붙일 근거가 사진에 있는가"를 Code로 자동 검사할 수 있다.

조건 Code	뜻	쓸 수 있는 정답
`no_condition`	장면 전체에 그대로 적용한다.	제한 없음
`while_corridor_occupied`	C의 점유가 유지되는 동안 적용한다.	R1 = **P** 또는 **U**
`while_actor_near_entrance`	출입구 주변에 Actor가 있는 동안 적용한다.	R2 = **P** 또는 **U**
`before_entering_occluded_area`	가려진 영역 앞에 들어서기 전에 적용한다.	R3 = **P** 또는 **U**
`before_passing_restricted_section`	좁아진 구간을 지나기 전에 적용한다.	R4 = **P** 또는 **U**

정답에는 장면마다 세 가지 집합을 적는다. **필요 대응 묶음**(Required Group)은 반드시 충족해야 하는 요구사항이며, 한 요구사항을 충족하는 허용 대안이 여럿이면 그중 하나만 답해도 된다. **허용 대응**(Allowed)은 그 장면의 근거로 정당화되는 모든 쌍이고, **금지 대응**(Forbidden)은 근거와 충돌하는 쌍이다. 허용에도 금지에도 없는 쌍을 답하면 근거가 확인되지 않은 대응으로 보아 통과시키지 않는다. 여러 관계가 함께 성립하면 각 관계의 필요 대응 묶음을 모두 요구한다. 아래 표는 관계별 기본 규칙이다.

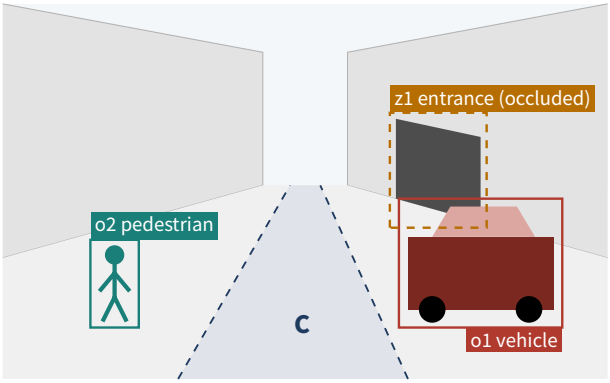
정답	필요 대응	금지 대응의 예
R1 = **P** (진행 공간 점유)	점유 조건에서 양보 또는 진입 보류. 이동 중 감속은 허용한다.	점유가 없다고 가정한 무조건 진행
R2 = **P** (출입구 주변 Actor)	출입구 조건에서 전방 관찰 또는 이동 중 감속	출입구 주변 Actor를 무시한 무조건 진행
R3 = **P** (연결부 시야 가림)	가림 조건에서 확인 후 진행. 이동 중 감속은 허용한다.	숨은 Actor가 없다고 단정한 무조건 진행
R4 = **P** (통행 공간 제한)	좁아진 구간 조건에서 통과 가능성 확인	통과 가능성을 확인하지 않고 충분하다고 단정한 진행
R4 = **U** (제약 존재 불명)	같은 조건에서 통과 가능성 확인	제약이 없다고 단정한 진행
위험 요인 없음	전방 관찰 또는 관찰하며 진행	존재하지 않는 Actor를 근거로 한 양보·보류

대응은 사진에서 판정한 R1–R4로만 정한다. 따라서 통행 방향이 Unknown이라는 사실이나 야간이라는 사실만으로는 대응 규칙이 바뀌지 않는다. 통행 방향이 Unknown인 장면에서 모델이 규칙을 단정해 말하면 그것은 대응 오류가 아니라 진술 오류(V13, V14)로 센다. 위험 요인이 없는 장면(No-hazard Scene)은 평가 데이터에 일부러 포함한다. 이런 장면이 없으면 모든 장면에 "정지하라"고 답하는 지나치게 조심스러운 모델을 걸러낼 수 없기 때문이다.

방향 충돌 장면의 처리. 일방통행을 거꾸로 가는 장면(Direction Match = Conflicting)에는 위 규칙을 적용하지 않는다. 이런 장면에서는 R3=P여서 "확인 후 진행"이 필요하더라도, 그 방향으로의 진행 자체가 부적절하므로 같은 대응을 금지해야 해서 맞는 답이 존재하지 않기 때문이다. 그래서 방향 충돌 장면은 기본 대응 평가(V10–V12)에서 분리해 Direction Match 평가(A1, A2)에만 쓴다. R1–R4 판정(V5–V9)은 진행이 허용되는지와 무관하게 사진에서 관측되는 관계이므로 이 장면에서도 평가한다.

1.7 예시

그림 2은 위 규칙을 한 장면에 적용한 예다. 도로 가장자리 차량 o1이 건물 출입구 z1을 가리고, 보행자 o2는 C 밖에 있다. 이때 R1·R2는 A, R3은 P(근거 o1, z1), R4는 P(근거 o1)이며, 필요 대응은 (확인 후 진행, 가려진 영역 진입 전)과 (통과 가능성 확인, 좁아진 구간 통과 전) 두 묶음이다.



관계 판정

R1 A o2의 발이 C 밖에 있다.

R2 A z1 주변에 보이는 Actor가 없다.

R3 P o1이 z1의 시야를 가린다.

R4 P o1이 이 구간의 통행 공간을 좁힌다.

모델이 출력하는 장면 속성

Sidewalk 좌·우 **A** · **A**

Traffic Direction **Unknown**(판독 가능한 표지 없음)

Direction Match **Unknown**

분석 전용 속성: Time of Day = Day

가림 뒤 Actor 존재: **U**

필요한 대응: z1 앞에 들어서기 전 확인, o1 옆을 지나기 전 실제 통과 가능성 확인

그림 2. 예시 장면과 정답. 그림의 Box와 C는 사람이 그린 정답(Annotation)이며, 모델에는 사진만 주어지고 모델은 자신의 Box를 따로 출력한다. 각 항목의 정의는 §1에 있다.

2 Metric: 답안을 어떻게 채점하는가

대표 점수는 **Relation Macro-F1**(V5, 관계를 맞게 판정했는가)과 **Action Pass Rate**(V10, 대응 규칙을 모두 지켰는가) 두 개이고, 나머지는 "왜 틀렸는가"를 설명하는 진단 점수다. 모든 점수에는 분모와 95% 신뢰구간을 붙인다.

채점은 형식 검사(V1, V2) → 근거 대조(V3, V4) → 관계 판정(V5–V9) → 장면 속성 판정(A1, A2) → 대응 판정(V10–V12) → 진술 검수(V13, V14)의 순서로 진행하고, 마지막에 같은 점수를 조건별로 다시 계산하며 신뢰구간을 붙인다(S1, S2). 사람이 만든 정답은 채점 Code에만 들어가고 모델 입력에는 들어가지 않는다.

2.1 공통 규칙: 실패한 요청을 어떻게 세는가

평가 요청은 사진 한 장을 모델에 넣어 답을 받는 한 번의 실행이다. 평가 요청 목록은 실행 전에 고정하고, 시간 초과(Timeout)나 형식 오류가 난 요청도 결과에서 지우지 않는다. 답을 제대로 낸 요청만 남기면 실패율이 실제보다 낮아 보이기 때문이다.

다만 실패한 요청(Invalid)이 반영되는 방식은 점수마다 다르다. 관계·속성 판정에서는 실제 정답을 놓친 것(FN)으로 세므로, V6과 V8에서는 분모에만 남는다. V7과 V9는 각각 "P로 단정함"과 "U로 피함"을 세는 점수이므로 Invalid를 분자에 넣지 않는다. V10과 V11은 Invalid를 실패로 세지만, V12는 금지 쌍이 **확인된** 답만 세므로 Invalid를 분자에 넣지 않는다. V13은 검수할 진술이 있는 답만 대상으로 한다. 이처럼 반영 방식이 다르므로 Invalid 비율(V2)은 항상 함께 보고한다. 분모가 0인 비율은 0이나 100%가 아니라 N/A로 보고한다.

2.2 형식과 근거 (V1–V4)

V1은 JSON으로 읽히고, 필수 필드가 있으며, 허용된 값만 쓰고, 참조한 ID가 같은 답 안에 실제로 선언된 답의 비율이고, V2는 그 나머지 비율이다. 형식 검사는 채점할 수 있는 구조인지만 본다. 실제로 없는 보행자를 `o1`로 선언한 답도 형식은 통과하므로, 내용이 사진과 맞는지는 다음 단계에서 본다.

V3은 모델의 Box가 정답 Box와 같은 대상인지 본다. 두 Box가 겹친 면적을 합친 면적으로 나눈 값(IoU)이 0.5 이상이고 Class가 같은 쌍만 짝이 될 수 있으며, 한 예측과 한 정답은 최대 한 번만 짝짓는다. 짝이 된 예측은 TP, 짝이 없는 예측은 FP, 짝이 없는 정답은 FN이고, 이로부터 Precision, Recall, F1을 계산한다. IoU 0.3과 0.7에서도 함께 계산해 기준에 따른 차이를 확인한다.

V4는 관계 판정의 근거로 연결한 ID 집합이 정답 집합과 정확히 같은지를 본다. R1을 P로 맞혔지만 근거로

엉뚱한 차량의 ID를 댄 답은 관계 점수에서는 맞고 V4에서는 틀린다. 즉 V4는 "맞는 답을 틀린 이유로" 낸 경우를 잡아낸다. 분모는 정답이 P 또는 U이면서 근거가 필요한 판정 항목이며, 근거가 될 수 있는 조합이 여럿이면 모두 정답으로 등록한다. 장면 속성의 근거 ID도 같은 방식으로 대조하되 속성별로 따로 보고한다.

2.3 관계 판정 (V5–V9)

대표 점수 V5 Relation Macro-F1. 관계 h와 상태 $c \in \{P, A, U\}$마다 F1을 구하고, 12개(4관계 $\times$ 3상태)를 똑같은 비중으로 평균한다.

$$F1_{h,c} = \frac{2\,TP_{h,c}}{2\,TP_{h,c} + FP_{h,c} + FN_{h,c}}, \qquad \mathrm{V5} = \frac{1}{4}\sum_{h=1}^{4}\frac{1}{3}\sum_{c\in\{P,A,U\}} F1_{h,c}. \tag{1}$$

단순 정확도 대신 이 평균을 쓰는 이유는, 정답이 대부분 A인 관계에서 항상 A만 답하면 정확도는 높아도 P와 U의 F1이 0이 되어 V5가 낮아지기 때문이다. 모든 장면에 같은 관계를 묻는 방식은 POPE의 고정 질문 원리를 따른 것이며[1], 공간 관계와 U를 더했으므로 원래 POPE 점수와는 다른 이름으로 보고한다. 어떤 상태의 정답이 하나도 없으면 그 F1과 전체 V5는 N/A로 두고, 정답이 있는 상태만 평균한 값을 따로 보인다.

진단 점수 V6–V9. V5가 낮을 때 어떤 종류의 오류인지 나누어 본다. 아래에서 y는 정답, $\hat{y}$는 예측이고, $\#(\cdot)$은 괄호 안 조건을 만족하는 항목의 개수다.

점수	식	잡아내는 오류
V6 Recall for Present	$\#(y{=}P, \hat{y}{=}P) \,/\, \#(y{=}P)$	있는 위험 관계를 놓침
V7 False Positive Rate	$\#(y{=}A, \hat{y}{=}P) \,/\, \#(y{=}A)$	없는 위험 관계를 있다고 함
V8 Recall for Unknown	$\#(y{=}U, \hat{y}{=}U) \,/\, \#(y{=}U)$	판단할 수 없는 것을 단정함
V9 Over-abstention	$\#(y{\in}\{P,A\}, \hat{y}{=}U) \,/\, \#(y{\in}\{P,A\})$	판단할 수 있는데 "모름"으로 피함

예를 들어 정답이 P인 항목 50개에 모델이 P 35개, U 10개, Invalid 5개를 답했다면 V6은 $35/50 = 70\%$이다. V8과 V9는 반대 방향의 실패를 잡는다. 항상 U만 답하는 모델은 V8이 높지만 V9도 높아서 드러나고, U를 전혀 쓰지 않는 모델은 V8이 0이 되어 드러난다. 판단 보류율과 오류를 함께 보아야 한다는 관점은 SelectiveNet을 참고했으나[3], 여기의 U는 사진의 정보 부족을 뜻하므로 모델 확신도 기반 평가와는 구분한다.

2.4 장면 속성 판정 (A1, A2)

모델 출력 항목인 장면 속성(Sidewalk 좌, Sidewalk 우, Traffic Direction, Direction Match)은 V5에 합치지 않고 따로 채점한다. V5에 섞으면 관계 판정과 속성 판정의 성능이 한 숫자에 합쳐져, 어느 쪽이 좋아지거나 나빠졌는지 알 수 없기 때문이다.

A1 Attribute Macro-F1은 Field f마다 $\mathrm{A1}_f = \frac{1}{|\mathcal{C}_f|}\sum_{c\in\mathcal{C}_f} F1_{f,c}$로 계산한다. 값 집합 $\mathcal{C}_f$는 Sidewalk가 {Present, Absent, Unknown}, Traffic Direction이 {One-way, Two-way, Unknown}, Direction Match가 {Consistent, Conflicting, Unknown}이다. Direction Match의 정답이 Not applicable인 장면은 A1의 분모에서 빼고, 정답이 Missing인 항목은 모든 Field에서 채점하지 않는다. 정답이 적용 가능한 값인데 모델이 Not applicable이라고 답하면 그 정답 Class를 놓친 것(FN)으로 센다. A1과 함께 Field별 Confusion Matrix(정답 값과 예측 값의 교차표)와 값별 표본 수를 보고한다. 예를 들어 Traffic Direction의 교차표를 보면, 사진에 근거가 없는데 One-way라고 단정한 경우가 얼마나 되는지 바로 보인다.

A1은 Not applicable인 장면을 분모에서 빼므로, 실제로는 Two-way라서 비교가 적용되지 않는 장면에서 모델이 Consistent나 Conflicting이라고 답한 오류를 잡지 못한다. 이 오류는 A2 Direction Applicability Error로 따로 잰다.

$$\mathrm{A2} = \frac{\#(y = \mathrm{N/A},\ \hat{y} \in \{\mathrm{Consistent}, \mathrm{Conflicting}\})}{\#(y = \mathrm{N/A})} \tag{2}$$

2.5 대응 판정 (V10–V12)

장면 i의 정답에는 허용 쌍 집합 A_i, 금지 쌍 집합 F_i, 필요 대응 묶음 $G_{i1}, \ldots, G_{im_i}$가 있고, 모델이 답한 (대응, 조건) 쌍의 집합을 S_i라 한다.

대표 점수 V10 Action Pass Rate. 장면 i는 다음을 모두 만족할 때 통과한다.

$$\mathrm{AP}_i = \mathbf{1}\Big[\, V_i \ \wedge\ C_i \ \wedge\ S_i \subseteq A_i \ \wedge\ S_i \cap F_i = \varnothing \ \wedge\ \textstyle\bigwedge_{j=1}^{m_i} \big(S_i \cap G_{ij} \neq \varnothing\big)\Big], \qquad \mathrm{V10} = \tfrac{1}{N}\textstyle\sum_i \mathrm{AP}_i. \tag{3}$$

N은 기본 대응 평가에 쓰는 장면의 수이며 방향 충돌 장면은 포함하지 않는다. 식의 조건을 차례로 풀면 다음과 같다.

- V_i: 형식이 Valid하다.
- C_i(일관성): 두 검사를 모두 통과한다. 첫째는 **정답과의 일관성**으로, 답한 각 쌍의 조건 Code가 요구하는 정답 판정이 실제로 있어야 한다. 둘째는 **답 내부의 일관성**으로, 모델 **자신이** 낸 관계 판정이 그 조건을 뒷받침해야 한다. 예를 들어 모델이 R3=A라고 출력하면서 가림을 근거로 대응하면, 정답 R3가 P라도 답 안에서 모순되므로 실패다. 같은 조건에서 서로 모순되는 쌍(예: 같은 조건의 `HOLD_UNTIL_CLEAR`와 `ADVANCE_WITH_MONITORING`)을 함께 답해도 실패다.
- $S_i \subseteq A_i$: 허용된 쌍만 답했다.
- $S_i \cap F_i = \varnothing$: 금지된 쌍이 없다.
- 마지막 조건: 모든 필요 대응 묶음에서 하나 이상을 답했다.

그림 2의 장면에서 확인 후 진행만 답하면 통과 가능성 확인 묶음을 놓쳐 실패하고, 여기에 점유 조건의 양보를 더하면 정답 R1이 A여서 그 조건을 붙일 근거가 없으므로 실패한다. V10은 우리가 정한 대응 규칙과의 일치도이며 차량 제어 성능을 뜻하지 않는다.

진단 점수. V11 Required Action Coverage는 전체 필요 대응 묶음 중 충족한 묶음의 비율로 "해야 할 것을 빠뜨렸는가"를 보고, V12 Disallowed Action Rate는 금지 쌍이 하나라도 있는 답의 비율로 "하면 안 되는 것을 했는가"를 본다. 둘을 함께 보면 V10이 낮은 원인이 누락인지 부적절한 대응인지 가를 수 있다.

2.6 진술 검수 (V13, V14)

모델의 설명을 "보행자가 보인다"처럼 참·거짓을 따로 확인할 수 있는 최소 진술로 나누고, 사람이 사진과 대조한다. 오류는 보이지 않는 Object를 보인다고 한 것, 사진과 모순되는 공간 관계를 말한 것, 근거 없이 상태나 움직임을 단정한 것, 근거 없이 통행 규칙이나 노면 상태를 단정한 것의 네 종류로 기록한다. 분석 전용 속성도 설명에 나오면 같은 방식으로 검수한다. V13은 검수한 진술 중 오류 진술의 비율이고, V14는 오류 진술이 하나라도 있는 답의 비율이다. 진술 단위와 응답 단위로 나누어 세는 방식은 CHAIR의 집계 방식을 확장한 것이다[2].

오류로 보이는 Object는 원본 사진을 다시 보아 정답에서 빠뜨린 것인지 실제 Hallucination(없는 것을 있다고 말함)인지 가린다. 진술을 하지 않으면 V13은 N/A가 되지만, 그 답은 V5와 V10에서 실패하므로 말을 줄여 오류율만 낮추는 모델은 좋은 결과로 선택되지 않는다.

2.7 조건별 분석

같은 점수를 장면 조건별로 다시 계산하면 모델이 약한 환경을 찾을 수 있다. 조건은 Scene Annotation의 속성으로 정하며, 기본 조건은 Time of Day(Day / Night), 좌·우 Sidewalk 유무, Traffic Direction이다. 예를 들어 야간 장면에서 R1의 Present Recall은

$$\mathrm{Recall}_{R1,P|\mathrm{Night}} = \frac{\#\{\, i \in S_{\mathrm{Night}} :\ y_{i,R1} = P,\ \hat{y}_{i,R1} = P \,\}}{\#\{\, i \in S_{\mathrm{Night}} :\ y_{i,R1} = P \,\}} \tag{4}$$

이다. S_{Night}는 사람의 Annotation으로 미리 정한 야간 장면의 집합이다. 모델이 야간이라고 예측한 장면으로 집합을 만들면 모델마다 평가 대상이 달라지므로, 모든 모델에 같은 집합을 쓴다.

조건별로 나누면 분모가 작아진다는 점에도 주의해야 한다. 야간 사진이 50장이어도 그중 R1이 P인 장면이 3개라면 이 점수의 분모는 3이다. 그래서 분모가 작은 조건의 결과는 탐색적 결과로만 다루고, 성능 차이를 확정하는 근거로 쓰지 않는다.

2.8 통계와 "개선"의 판정 기준

S1 Wilson 95% 신뢰구간은 장면마다 성공·실패가 하나씩 나오는 비율 점수에 쓴다[5]. 성공 수 k, 분모 n, $\hat{p} = k/n$, $z = 1.96$일 때

$$\mathrm{CI}_{95} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \tag{5}$$

이다. 예를 들어 40/50(80%)의 구간은 약 67.0%–88.8%이며, 분모가 50개여도 위아래로 10%p 안팎의 불확실성이 남는다는 뜻이다.

S2 Group 단위 Bootstrap은 Wilson 구간을 쓸 수 없는 점수(V5, A1처럼 여러 F1을 평균한 점수)와 두 모델의 점수 차이에 쓴다. Bootstrap은 가진 표본에서 복원추출을 반복해 점수의 흔들림을 재는 방법이다. 같은 영상·같은 촬영 구간에서 나온 사진(Group)은 서로 닮았으므로 한꺼번에 뽑고, 매번 두 모델에 똑같이 뽑힌 표본을 적용한다. 2,000번 반복하면서 매번 각 모델의 점수 M_A^*, M_B^*와 차이 $\Delta^* = M_A^* - M_B^*$를 계산하고, 각각의 2.5번째와 97.5번째 백분위수를 그 모델의 점수 구간과 차이의 구간으로 보고한다[4]. 어떤 반복에서 특정 상태의 정답이 0개가 되어 V5를 정의할 수 없으면, 그 비율을 기록하고 V5의 구간은 N/A로 표시한다.

"개선"이라고 말하는 기준. 추가 학습한 모델(Tuned)이 학습 전 모델(Base)보다 개선되었다고 말하려면, 두 모델의 V5 차이와 V10 차이의 95% 구간이 **둘 다** 0보다 위에 있어야 하고, R1–R4의 V6 차이와 V7 차이 중 어느 것도 구간 전체가 나빠지는 방향에 있지 않아야 한다. 한 점수만 개선되면 그 능력에 한정해 말하고 Trade-off를 적는다. 구간이 0을 포함하면 "차이를 확인하지 못했다"고 적고, 구간을 좁히는 데 필요한 추가 표본 수를 제시한다.

2.9 점수 전체 표

대표 점수는 굵게 표시했다. 정답 품질 점수(L1–L3)는 모델이 아니라 사람이 만든 정답을 평가한다. 두 Annotator가 서로 보지 않고 같은 장면을 기록했을 때 얼마나 일치하는지를 R1–R4, Sidewalk, Traffic Direction, Time of Day처럼 Field마다 따로 계산하며, 서로 다른 속성을 하나의 일치도로 합치지 않는다.

ID	이름	식	분모와 뜻
정답 품질			
L1	Raw Agreement	$n_{\text{agree}}/n_{\text{double}}$	합의 전 두 Annotator의 일치 비율(Field별)
L2	Cohen's κ	$(p_o - p_e)/(1 - p_e)$	우연히 일치할 몫을 뺀 일치도(Field별). 처음 50장면에서 L1 85% 미만 또는 L2 0.7 미만이면 판정 기준을 재검토
L3	Samples per Relation–State	n_{hc}, g_{hc}	관계·상태별 장면 수와 Group 수. 조건별 수도 함께 기록
형식과 근거			
V1 / V2	Valid / Invalid Output Rate	N_{valid}/N, $1 - \text{V1}$	형식이 맞는 답 / 형식 오류와 Timeout의 비율
V3	Object P / R / F1	$\frac{2TP}{2TP+FP+FN}$ 등	Class 일치·IoU≥0.5 일대일 짝짓기
V4	Evidence ID Exact Match	$\frac{1}{K}\sum \mathbf{1}[\hat{E}_{ih} \in E_{ih}^*]$	근거가 필요한 P/U 판정 K개 중 근거 ID 집합이 정확히 맞은 비율
관계와 장면 속성			
V5	**Relation Macro-F1**	$\frac{1}{4}\sum_h \frac{1}{3}\sum_c F1_{h,c}$	4관계 × 3상태 F1의 균등 평균
V6	Recall for Present	$\#(P \to P)/\#(y{=}P)$	있는 관계를 놓치지 않는 정도
V7	False Positive Rate	$\#(A \to P)/\#(y{=}A)$	없는 관계를 있다고 하는 정도
V8	Recall for Unknown	$\#(U \to U)/\#(y{=}U)$	판단할 수 없는 것을 모른다고 하는 정도
V9	Over-abstention	$\#(\{P, A\} \to U)/\#(y{\in}\{P, A\})$	판단할 수 있는데 피하는 정도
A1	Attribute Macro-F1	$\frac{1}{\lvert\mathcal{C}_f\rvert}\sum_c F1_{f,c}$	장면 속성 Field별 F1 평균. V5에 합산하지 않음
A2	Direction Applicability Error	$\#(\text{N/A} \to \{\text{Cons.}, \text{Conf.}\})/\#(y{=}\text{N/A})$	비교가 적용되지 않는 장면에서 방향 일치를 판정한 비율
대응과 진술			
V10	**Action Pass Rate**	$\frac{1}{N}\sum_i \text{AP}_i$	기본 대응 평가 장면 중 모든 조건을 통과한 비율
V11	Required Action Coverage	$\sum_{i,j} r_{ij} / \sum_i m_i$	필요 대응 묶음 중 충족한 비율
V12	Disallowed Action Rate	$\frac{1}{N}\sum_i \mathbf{1}[B_i]$	금지 쌍이 확인된 답의 비율
V13	Statement Error Rate	$\sum_{i,k} e_{ik} / \sum_i K_i$	검수한 최소 진술 중 오류 진술 비율
V14	Response Error Rate	$\frac{1}{N}\sum_i \mathbf{1}[\sum_k e_{ik} > 0]$	오류 진술이 하나라도 있는 답의 비율
조건별 분석과 통계			
—	조건별 점수	$M \mid S_c$	점수 M을 Annotation으로 정한 조건 집합 S_c에서 다시 계산

ID	이름	식	분모와 뜻
S1	Wilson 95% CI	위 식	장면당 성공/실패 하나인 비율 점수
S2	Group Bootstrap CI	$Q_{.025}, Q_{.975}$ of M^*, Δ^*	각 모델 점수와 두 모델 차이의 구간(2,000회)

참고 문헌

[1] Y. Li et al. Evaluating Object Hallucination in Large Vision-Language Models. EMNLP, 2023.

[2] A. Rohrbach et al. Object Hallucination in Image Captioning. EMNLP, 2018.

[3] Y. Geifman and R. El-Yaniv. SelectiveNet: A Deep Neural Network with an Integrated Reject Option. ICML, 2019.

[4] R. Agarwal et al. Deep Reinforcement Learning at the Edge of the Statistical Precipice. NeurIPS, 2021.

[5] NIST/SEMATECH. Confidence Limits for a Proportion. e-Handbook of Statistical Methods.