실전SW 프로젝트 · 진행 결과

생활도로 위험 판단 VLM

평가 벤치마크 및 초기 실행 결과

공간 관계와 조건부 대응의 근거 기반 평가

kakao mobility 산학 프로젝트

Team1

윤유경 · 문혜승 · 고연오 · 하경흠 · 한태문

2026. 11.

설계 반영

기업 피드백과 프로젝트의 대응

기업이 전달한 방향	팀의 설계 및 반영	현재 상태
골목길 Taxonomy 자율 설계	4대 공간 관계와 조건부 대응 정의	명세 및 Draft 샘플
시간 정보 활용에 긍정적 4주 일정 우려	Track 1 우선, 시간 정보는 단계적 확장	단일 이미지 실행
AI Hub 데이터 우선 활용	71784 중심, 472·597 보조 활용	샘플 기반 검증
AIOps/MLOps 구성에 긍정적	데이터·모델·프롬프트·평가 기록 연결	Run 산출물 보존

기업의 전달 방향과 팀이 정한 평가 규칙을 구분하여 관리

프로젝트 목표

개발자의 모델 비교와 오류 검토를 지원

사용자 생활도로 인지·판단 모델을 평가하는 엔지니어

사용자가 확인할 질문	최종 산출물	현재 확보한 증거
어떤 상황에서 판단이 달라지는가?	데이터셋 + 평가 벤치마크	명세, Draft 1문항, 채점 검산
경량 모델이 얼마나 개선되는가?	Fine-tuned VLM	모델 추론, QLoRA 학습·재로딩
판단의 근거가 원본과 일치하는가?	Web Viewer	실제 결과 뷰어 + 화면 프로토타입

최종 비교 목표: 동일한 평가 데이터에서 Base와 Tuned의 차이 확인

평가 설계

생활도로의 4대 공간 관계

관계	관찰할 내용	연결할 근거
R1 진행 영역 점유	진행 영역 C 안의 객체 점유	객체와 C의 공간 관계
R2 출입구 주변 관계	출입구·경계와 객체의 관계	출입구 영역과 관찰 가능한 위치
R3 시야 가림	진행 영역 주변의 가려진 공간	가림 객체와 가려진 영역
R4 통행 공간 제약	객체 배치에 의한 공간 제한	제약 객체와 영향받는 구간

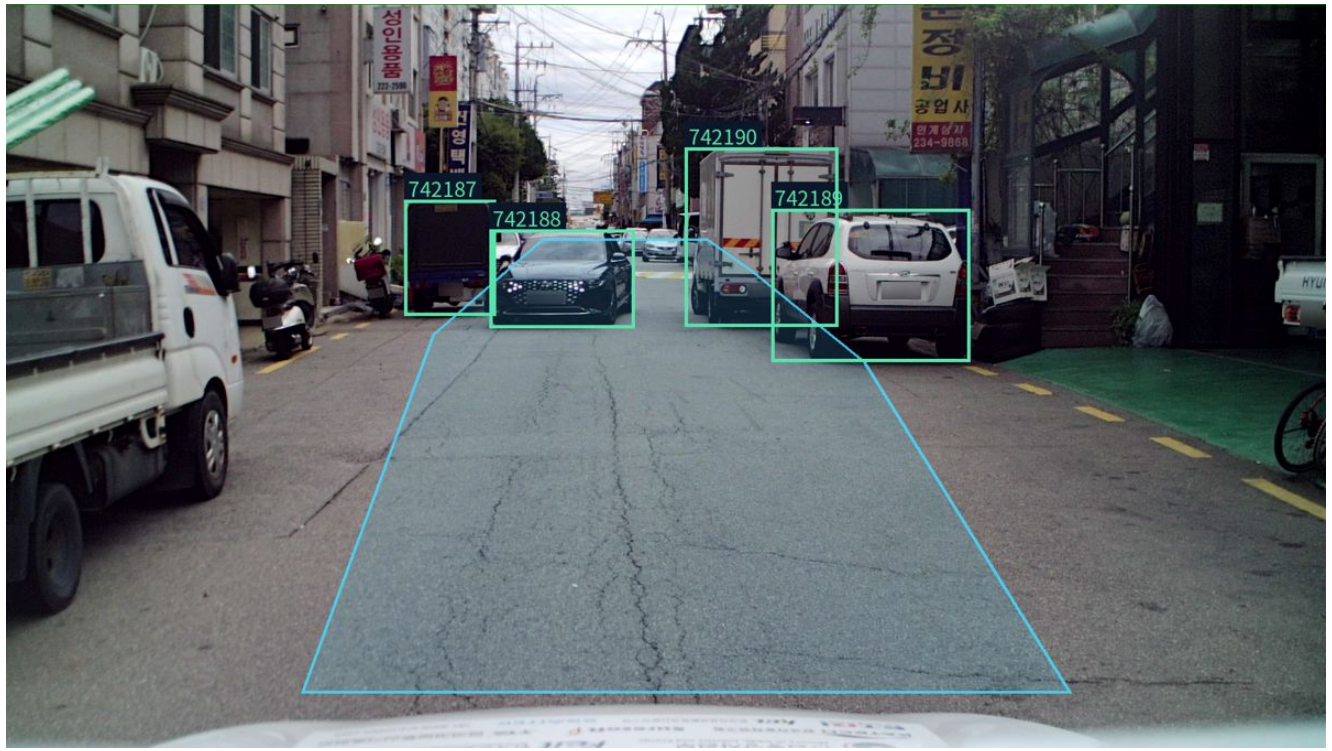
상황 태그: 주정차, 보행자, 출입구, 야간·우천 등

상황 태그와 R1~R4를 함께 기록하여 오류 유형별 비교

P: 관찰됨 A: 관찰되지 않음 U: 입력만으로 판단 불가

라벨 체계

객체 근거와 조건부 대응의 연결



Draft GT 예시

단계	이 장면의 라벨
관찰 근거	전방 차량과 진행 영역 C
관계 판정	R1 = P 진행 영역 점유
조건부 대응	점유 상태가 지속되는 동안 YIELD / HOLD

예시는 Draft 라벨 설명이며 실제 모델 출력과 구분합니다. C는 평가용 기준 영역입니다.

데이터 구축

계획 규모와 실제 실행 범위

200~400

이미지·클립 구축 목표

약 50

초기 라벨 검수 Pilot

1

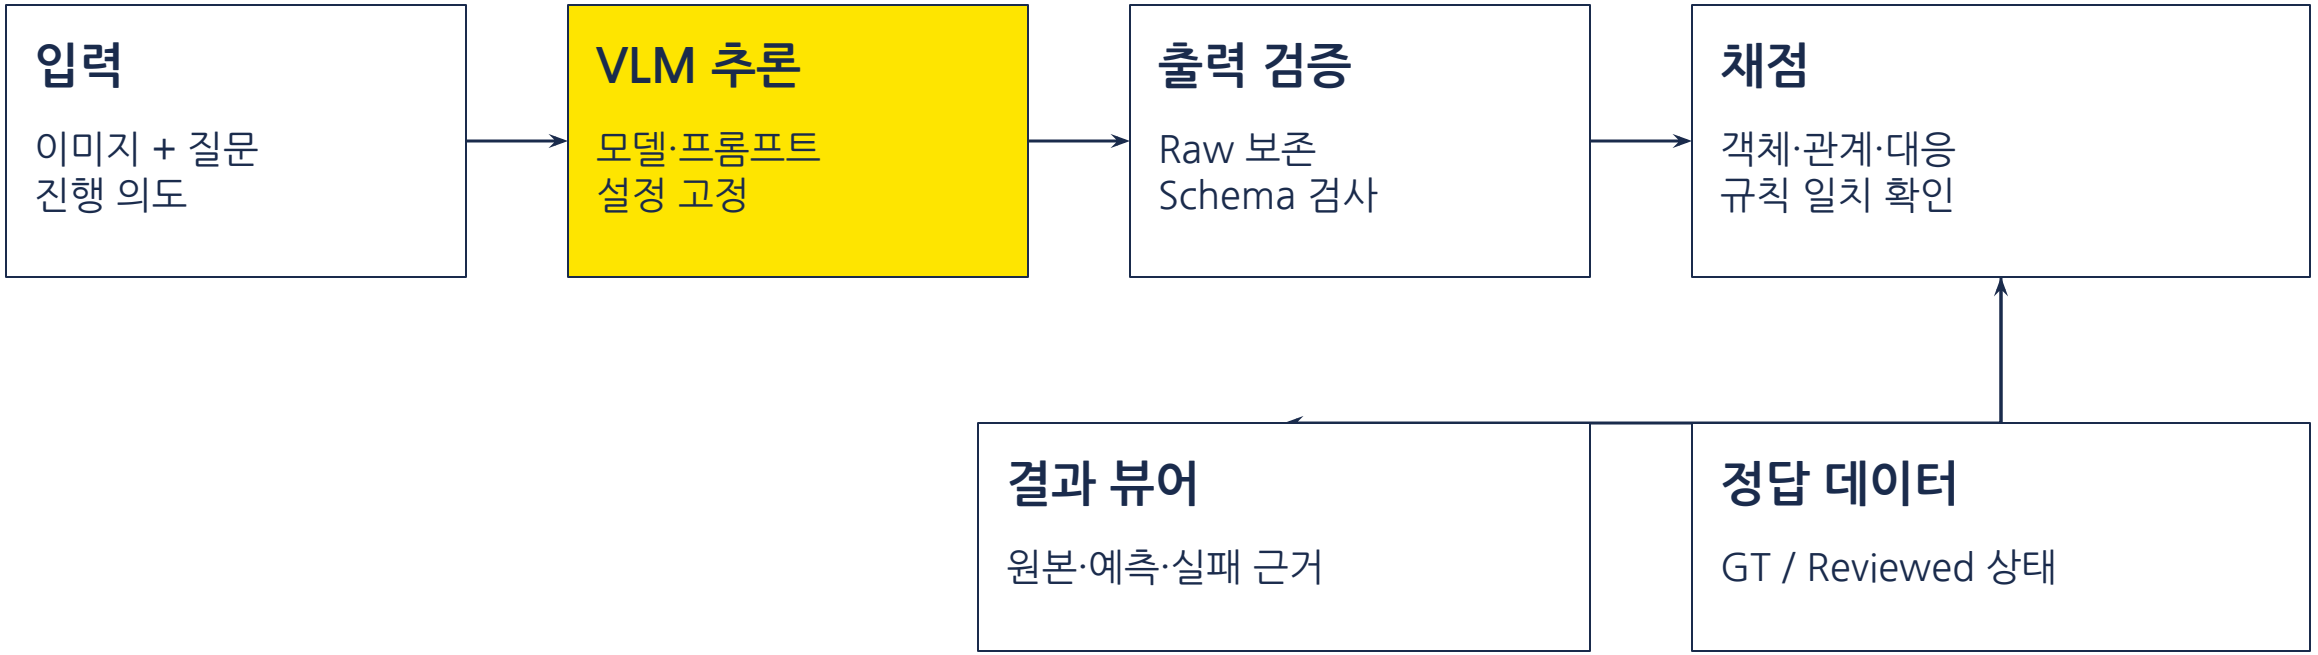
현재 독립 장면 / Draft

평가 트랙	필요 입력	현재 범위
Track 1 현재 공간 관계	전방 단일 이미지	F 이미지 1장 실행
Track 2 미래 상황	연속 프레임·사건 시점	입력 미확보
Track 3 자차 움직임	시간 정보·자차 모션	입력 미확보

원본과 편집본은 같은 source group으로 묶어 split 간 중복을 방지합니다.

실행 구조

입력·정답·실행 기록을 분리한 평가 파이프라인



Run ID 데이터 / Split / 프롬프트 / 모델 revision / 평가 코드 / 산출물

비교 및 평가

동일한 데이터에서 모델별 판단과 근거를 비교

비교 대상	확인할 역할	현재 상태
오픈 VLM Base	학습 전 기준 성능	단일 샘플 추론 완료
상용 대형 VLM	상용 모델과의 격차	외부 API 이용 조건 확인 후
경량 VLM Tuned	학습에 따른 개선 폭	QLoRA 경로 검증 완료

핵심 평가 관계 판정 / 조건부 대응의 규칙 일치

오류 진단 객체 매칭 / 근거 연결 / 환각 / JSON 형식

운영 지표 추론 지연시간 / GPU 메모리 / 학습 처리량

현재는 1개 Draft 문항의 진단 결과입니다. Reviewed Test 기반 공식 점수는 추후 산출합니다.

실제 실행 결과

샘플 1문항에서 추론·채점·결과 저장을 연결



원본 1920×1080 / F 한 장

Object	3 / 16
Relation	0 / 4
Action	False

Draft 기준 진단 결과

첫 출력의 code fence 제거 후
Schema 검사 통과

google/gemma-4-E4B-it · BF16 / soft-token budget 280 · 첫 출력 기준

오류 분석

객체 인식 이후에도 관계 근거 연결이 필요



분류 오류

GT: truck
Prediction: car

IoU 0.7803

위치가 겹쳐도
class 조건에서 탈락

관계 근거 누락

확인한 단계	결과
주요 차량 3개	객체 매칭 성공
Relation evidence	모두 빈 배열
관계 판정	R1~R4 모두 A
조건부 대응	MONITOR_AHEAD

객체 누락만으로 관계 실패를 설명할 수 없음

좌표·IoU·assignment 독립 검산과 evaluator test 30개로 기존 결과를 재확인했습니다.

추가 실험

프롬프트 수정으로 출력 형식 준수 개선

항목	기존 NF4 첫 출력	수정 prompt 첫 출력
Strict Schema	실패	통과
regions 필드	필수 필드 누락	[] 직접 출력
Object 진단	N/A	4 / 16
Relation 진단	N/A	0 / 4
Action 진단	N/A	False

확인한 개선: 형식 준수　**남은 과제: 공간 관계와 근거 연결**

NF4의 기존 첫 출력과 수정 prompt 첫 출력을 비교했습니다. 재시도 결과와 구분합니다.

프론트엔드 프로토타입

점수에서 실패 장면과 판단 근거까지 확인

F1 실행 / F2 Report / F3 오류 목록 / F4 비교 / F5 상세



F5 장면 상세

원본·C·정답·예측 레이어

정답·예측 탭 전환
객체 ID 선택 시 박스 강조
관계·조건부 대응 확인

다음 연결: 실제 Run 결과 API

Commit 1f4baec · 가상 데이터 기반 프로토타입. 화면의 모델명·점수·신뢰구간은 예시 값입니다.

GPU 자원 검증

24GB GPU에서 시작하는 운영 계획

A6000 실험 조건	Microbatch × 누적	평균 초 / step
24GiB allocator 제한	1 × 4	24.830
제한 해제, 동일 batch	1 × 4	24.831
제한 해제, microbatch 증가	2 × 2	24.343

약 2.0% Microbatch 1→2 처리량 개선

Effective batch 4 유지 / sequence length 6,040 / NF4 QLoRA

운영안: 24GB에서 MB1 × 누적4로 시작하고 동일 조건 실기 검증

실측: 같은 RTX A6000 48GB에서 제한 비교. 실제 AWS 24GB GPU의 속도·가용 메모리는 미측정입니다.

실행 계획

검수된 데이터와 비교 가능한 최종 결과 확보

단계	핵심 작업	완료 기준
1주차 라벨 검수	Pilot 약 50장, 독립 검수, 규칙 정리	Reviewed reference 확보
2주차 평가 고정	Schema·근거 매칭·예외 규칙 정리	평가 코드 및 규칙 버전 고정
3주차 모델 개선	Dev 오류 분석, 데이터 보강, QLoRA	중복 제거 후 Test 동결
4주차 최종 비교	Base/Tuned 동일 Test, 뷰어 연결	결과·근거·재현 자료 전달

이번 미팅의 협의

① R1·R4의 Roadside 적용 기준

② Pilot 라벨 검토 및 피드백 방식

③ Track 1 우선 완료 및 시간 정보 확장 순서

GitHub 상세 자료

실험 결과·재현 자료 ↗

오류 분석·Human Review ↗

실제 모델 출력 JSON ↗

기술 명세 PDF ↗

최신 프론트엔드 HTML ↗

HTML은 다운로드 후 브라우저에서 실행