실전SW프로젝트 · 기획안 발표

보도 없는 생활도로 위험 판단 VLM

위험 객체 위치와 **영상 의존도**를 함께 평가하는 벤치마크와 경량 판단 모델

kakaomobility 한국형 주행 VLM

Team1

윤유경, 문혜승, 고연오, 하경흠, 한태문

발표 26. 10. 23.

팀 구성

역할과 담당 산출물

PM · 기획

윤유경

① 문제 정의
② 사용자
③ 스토리
⑥ 범위, 통합

모델 · 알고리즘

하경흠

⑤ 기술 스펙
(모델 선정, LoRA)
⑦ 평가 방법

백엔드 · 인프라

문혜승

⑤ 아키텍처,
서빙, API, DB

디자인 · 프론트엔드

고연오

④ 화면 설계,
웹 데모

데이터

한태문

⑤ 데이터 스펙,
라벨링 가이드 및
검수

목차

필수 산출물

01 문제 정의서

02 사용자와 사용 시나리오

03 사용자 스토리와 성공기준

04 화면 설계

05 데이터·기술 스펙

06 범위 확정표

07 평가 방법 정의

산출물 ① · 왜 해야 하는가?

문제 정의서

배경	보도와 차도가 나뉘지 않은 생활도로에서는 보행자, 차량, 이륜차·PM이 같은 노면을 함께 사용한다.
근거	보도·차도 미분리 도로는 보행자 보호가 중요한 환경이다. 도로교통공단 분석 보도에서 보행 사망자 수는 보도가 있는 도로의 약 3배였다.
문제 정의	행동 정답률만으로는 위험 객체 누락과 영상 없이 맞힌 답을 구분하기 어렵다. 개발자는 어떤 유형의 데이터를 보강할지 판단할 근거가 부족하다.
목표	위험 Recall·객체 F1 개선과 환각 감소를 목표로 하며, 개선 폭과 95% 신뢰구간을 보고한다.
제약·가정	기간 4주, GPU 1장, 데이터 승인·이용 조건과 외부 API 비용 확인이 필요하다.

출처: 도로교통공단 2017~2021년 분석을 인용한 연합뉴스(2022. 5. 2.). 사망자 수 비교이며 노출량 대비 위험비가 아님.

산출물 ① · 근거

VLM의 함정

단위: GPT score 0~100(점)

모델 · 과제	정상 영상	영상 없음	차이
GPT-4o · 행동	45.40	50.03	+4.63
GPT-4o · 계획	75.75	73.21	−2.54
Qwen2-VL-7B · 인지	28.99	35.16	+6.17
Qwen2-VL-7B · 행동	49.07	54.48	+5.41

정답 편향

행동 객관식 정답의 약 78.6%가 '직진'이라
보지 않고도 맞힐 수 있다.

생활도로에서는 (검증할 가설)

예시) '골목이면 서행'이라는 추측도
정답으로 집계될 수 있다.

출처: Xie et al., DriveBench (2025). 12개 VLM, 19,200개 프레임

산출물 ① · 문제 진술

자율주행 인지·판단 모델 개발자는
보도 없는 생활도로에서 행동 정답률만 확인하면
위험 객체 누락과 영상 없이 맞힌 답을 구분하기 어렵다.

그 결과 취약한 상황과 데이터 보강의 우선순위를 정하기 어렵다.

우리는 위험 객체 위치와 영상 의존도를 함께 평가하고,
경량 모델의 위험 Recall 개선과 환각 감소를 검증한다.

목표치·채점 규칙은 검증Set으로 고정하고, 평가Set은 마지막 평가 단계에서만 사용한다.

산출물 ② · 누가 쓰는가?

주 사용자와 보조 사용자

주 사용자

자율주행 인지·판단 모델 개발자

서비스 지역을 주택가 생활도로까지 넓히기 전에
모델을 검증한다.

보조 사용자 · 운영 담당자

유형별 취약 사례와 검토 필요 표시를 보고
추가 검증·데이터 보강 대상을 정한다.

목표

T1~T5 중 어떤 상황에서 위험을 놓치는지 찾아
데이터 보강 우선순위를 정한다.

현재 방식

골목 프레임 30개를 직접 골라
행동 정답률만 확인한다(가상 사례).

불편과 손실

정답률만으로 위험 객체 누락 여부를 파악하기 어렵다.

환경·제약

버전마다 장면이 달라 비교할 수 없고,
원본 프레임은 비식별화가 필요하다.

기호 설명 T1~T5: 상황 유형 5개(경로 위 보행자, 좁아진 통과 폭, 주차 차량 사이 사각, 마주 오는 차량과의 교행, 이륜차·PM 혼재), 14쪽 참고

산출물 ② · 언제 쓰는가?

사용 시나리오 (개발자)

	계기	행동	결과
As-Is **현재**	새 모델 버전이 출시된다.	골목 프레임 약 30개를 골라 행동만 체크한다.	정답률 하나만 남고, 약한 유형과 판단 근거를 구체적으로 파악하지 못한다.
To-Be **도입 후**	새 모델 버전이 출시된다.	고정 평가셋 200장을 모델 3종류 × 2조건으로 실행한다.	유형별 Recall, 영상 의존도, 놓친 사례를 파악할 수 있게 된다.

예외 형식 오류·지원 범위 밖 입력은 판단 보류하고, 낮은 확신도는 검토 대상으로 표시한다.

기호 설명 모델 3종류: ① 미세조정 전 모델 ② 상용 대형 VLM ③ 우리 모델(LoRA). 2조건: 정상 영상, 영상 없음

산출물 ③ · 무엇이 되면 성공인가?

사용자 스토리와 성공기준 (1/2)

번호	사용자 스토리	우선순위	성공기준
S1	프레임 한 장을 넣으면 정해진 JSON 형식의 판단을 받는다.	Must	정상 입력 200장의 응답·상태가 저장되고, schema 실패는 판단 보류로 표시된다.
S2	모델이 찾은 위험 객체를 프레임 위 박스로 본다.	Must	좌표·클래스가 원본 위에 표시되고, F1·precision·환각률이 정답 라벨과 비교된다.
S3	같은 프레임에 대한 모델 3종류의 판단을 나란히 본다.	Must	200장 × 3종의 정상 입력 결과와 실패 상태가 누락 없이 저장·표시된다.
S4	'위험 높음'을 놓친 프레임만 모아 본다.	Must	정답 high 중 예측이 high가 아닌 사례를 모두 모으고, Recall과 행동 오답을 확인한다.

성공기준은 기능 완료를 정의한다. 모델 성능의 개선 목표와 통계적 불확실성은 M1~M9에서 별도로 보고한다.

산출물 ③ · 무엇이 되면 성공인가?

사용자 스토리와 성공기준 (2/2)

번호	사용자 스토리	우선순위	성공기준
S5	같은 평가셋의 정상 영상과 영상 없음 결과를 비교한다.	Must	동일 질문의 두 조건 결과와 행동 정확도 차이, McNemar 검정 결과가 표시된다.
S6	근거 문장이 장면과 맞는지 검토한다.	Must	고정 50장 × 3종 응답을 2인과 LLM으로 채점하고 일치도·상관계수를 보고한다.
S7	운영 담당자로서 유형별 안전 중요 Recall을 한눈에 본다.	Must	유형별 표본 수·Recall·95% 신뢰구간과 추가 검토 대상이 함께 표시된다.
S8	짧은 클립을 넣어 움직임까지 반영한 판단을 받는다.	Could	Later로 미루고, 이번 범위에서는 제외한다.

기호 설명 ① 미세조정 전 모델 · ② 상용 대형 VLM · ③ LoRA 모델 · T1~T5는 14쪽 · LLM-as-judge는 사람 평가와 별도 보고

산출물 ④ · 어떻게 보이는가?

프레임 판단 상세 화면 (F5) 예시



출처: AI Hub '생활도로 객체인식 자율주행 데이터',
한국지능정보사회진흥원 사업결과

상황 유형 · S1
T5 이륜차·PM 혼재 (보조: T2)

위험 객체 · S2
이륜차 1대, 자차 전방의 통과 공간에 위치

위험 수준 · 권장 행동
높음 · 정지 준비

근거 · S6
전방 이륜차와 주차 차량으로 통과 공간이 좁아 보인다.
이동 방향·속도는 단일 이미지로 확정하지 않는다.

예시 화면. 단일 이미지의 관측 사실과 잠재 위험을 구분한다. F1~F4 와이어프레임은 부록 A1~A2에 있다.

산출물 ④ · 어떻게 보이는가?

화면 흐름과 상태 화면

핵심 화면 · F1 실행 후 F2에서 F3·F4·F5 선택

F1
평가 실행
S1 · S3 · S5

→

F2
결과 리포트
S2 · S4 · S5 · S7

F3
오답 사례 뷰어
S4

F4
baseline 비교
S3 · S5

F5
판단 상세
S1 · S2 · S6

상태 화면

빈 화면
평가 전이면
F1로 가는 기능

로딩
진행률과 남은 시간

오류
실패 프레임 수와
재실행

판단 보류
형식 오류·
지원 범위 밖 입력

결과 없음
필터 초기화 버튼

F1 입력 → F2 결과 요약, F2에서 F3·F4·F5로 이동. 화면별 입력·출력·상태 배치는 부록 A1~A2.

기호 설명 F1~F5: 화면 번호. S1~S7: 사용자 스토리 번호(9~10쪽).
baseline 비교: ① 미세조정 전 모델 · ② 상용 대형 VLM · ③ 우리 모델의 판단을 나란히 비교

산출물 ⑤ · 무엇으로 만드는가?

데이터 스펙

출처·이용 조건	AI Hub 생활도로 객체인식 데이터 승인·이용 조건 확인 후 사용한다.
규모·분할	학습 200 · 검증 40 · 평가 200장. 동일 주행 시퀀스는 같은 분할에만 둔다.
라벨·검수	VLM 초벌 후 2인 독립 검수·합의. 합의 전 kappa와 유형별 분포를 보고한다.
개인정보	얼굴·번호판 비식별화와 외부 전송 조건을 확인한 데이터만 API 입력으로 사용한다.
확보 일정	샘플 확보. 원본은 1주차 내 신청·승인 상태 확인 담당: 한태문 / 지연 시 확보 샘플로 E2E 개발



예시: 양측 주차로 통과 공간이 좁고,
전방에 차량이 보이는 생활도로(T2).

출처: AI Hub '생활도로 객체인식 자율주행 데이터',
한국지능정보사회진흥원 사업결과

분할·검수·이용 조건의 상세 규칙은 부록 A4. 평가 200장은 고위험 중심의 진단용이며 실제 도로의 발생 비율을 대표하지 않는다.

산출물 ⑤ · 무엇으로 만드는가?

상황 taxonomy와 출력 형식

ID	상황	판정 기준
T1	경로 위 보행자	보행자가 자차 진행 경로 안에 있다.
T2	좁아진 통과 폭	주정차 차량 때문에 남은 폭이 차 한 대 수준 이하이다.
T3	주차 차량 사이 사각	주차 차량으로 가려진 보행자 출입 가능 공간이 보인다.
T4	마주 오는 차량과의 교행	좁은 통과 공간 안에 자차를 향한 맞은편 차량이 보인다.
T5	이륜차·PM 혼재	이륜차나 전동킥보드가 보행자·차량과 같은 공간에 있다.

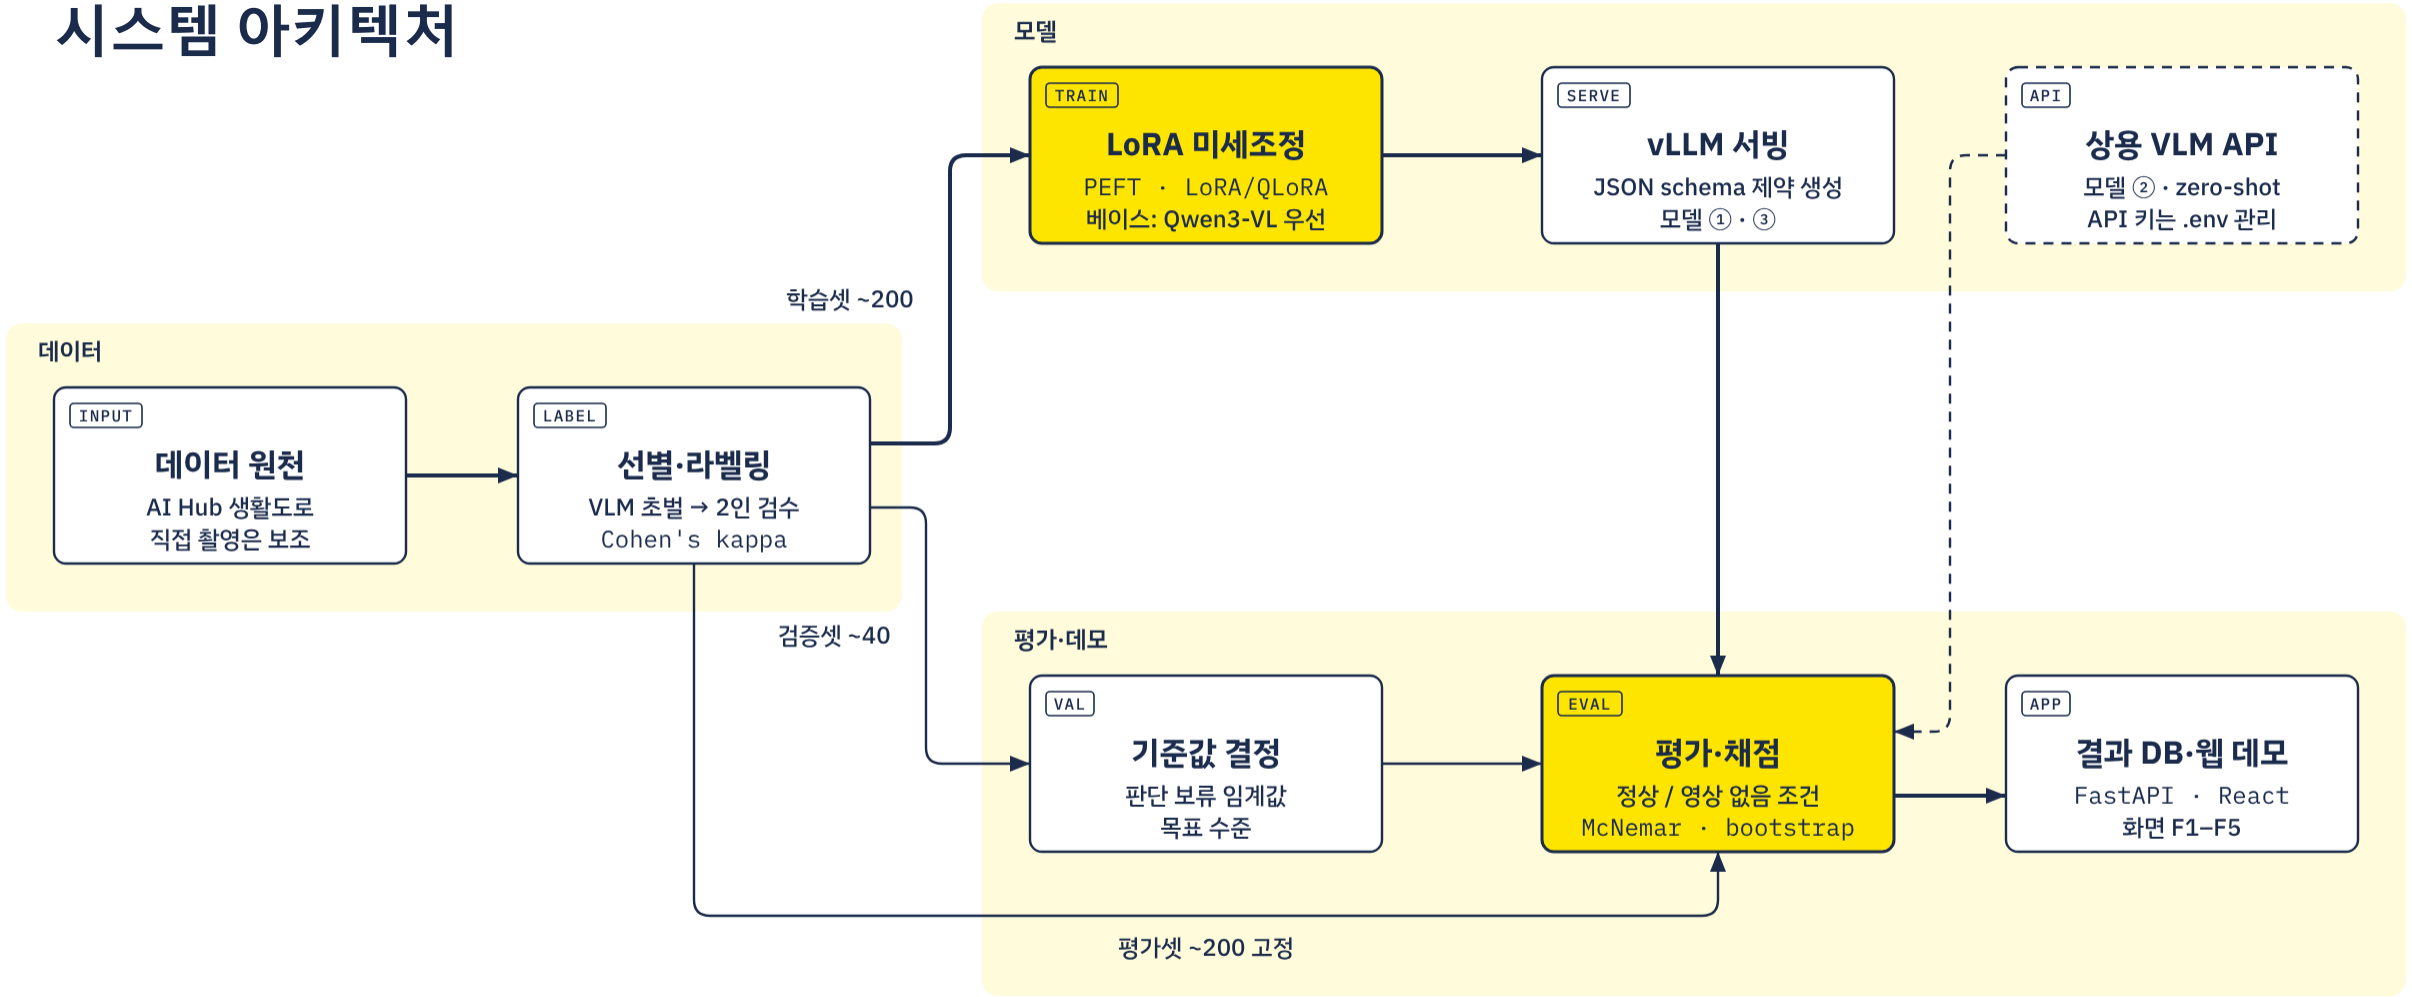
{ scene_types[], hazards[{id,type,position,state,bbox}], risk{level,target_ids,reason}, action, rationale, confidence }

bbox=[x1,y1,x2,y2], 0~1 좌표. action 4종·위험 3단계와 가림 규칙은 부록 A3.

4주 내 이중 검수·유형별 분석을 위해 5종으로 한정한다. scene_types는 다중 선택하며 미관측 객체의 박스는 만들지 않는다.

산출물 ⑤ · 무엇으로 만드는가?

시스템 아키텍처



범례 핵심 구성 요소 · 팀 구현 구성 요소 · 외부 서비스 · 주 흐름 · 데이터 분할·보조 흐름 · 비교 대상 응답

산출물 ⑤ · 무엇으로 만드는가?

후보 VLM 3종류를 비교하여 모델을 선택한다

후보	크기·라이선스	강점	확인할 점
Qwen3-VL-Instruct (우선)	4B · 8B, Apache-2.0	bbox grounding 지원 vLLM 서빙 후보	한국어 근거 문장 품질
Kanana-1.5-v-3b-instruct	약 3.6B, kanana-license	한국어·한국 특화	bbox 출력 품질 검증
HyperCLOVAX-SEED-Vision-Instruct-3B	약 3.7B, hyperclovax-seed	한국어 중심 이미지·영상 지원	grounding 지원 여부

학습	PyTorch · Transformers · PEFT 1주차 호환 확인 후 버전·commit 고정
서빙	vLLM 우선, 호환 실패 시 Transformers JSON 검증·실패 상태 저장
서비스	FastAPI · React · SQLite 환경 파일·모델 revision 함께 기록
인프라·API	GPU 1장 확보·메모리 실측 후 크기 결정 API 모델·예산·요청 제한: 1주차 확정

후보 모델 공식 카드 출처는 부록 A7. 선정은 GPU 적합성·한국어·bbox 품질·이용 조건 기준. 기술·API 운영 계획은 부록 A6.

산출물 ⑥ · 어디까지 하는가?

범위 확정표

In
반드시 완성

JSON 판단 출력 · S1

위험 객체 박스 · S2

모델 3종 비교 · S3

놓친 사례 모음 · S4

정상·영상 없음 비교 · S5

근거 품질 평가 · S6

유형별 Recall 리포트 · S7

고위험 중심 고정 평가셋 200장

Later
여유 시 추가

짧은 클립 입력 · S8
- 시간 정보·정답 라벨 추가 필요

직접 촬영 평가 세트
- 비식별화·수집 공수

추가 상황 유형·도로 환경
- 5종의 검수·분석을 먼저 완료

Out
제외

실시간 처리·차량 탑재·제어 출력
- 판단 출력까지만 평가

Full fine-tuning
- 기간·메모리·실험 비용을 고려하여 LoRA/QLoRA에 집중

열화상·LiDAR, 다른 도로 유형 제외
- 카메라와 생활도로로 한정

계정·권한·서비스 배포
- 데모는 결과 확인용

S1~S7은 Must·In, S8은 Could·Later.

산출물 ⑦ · 어떻게 증명하는가?

평가 지표 (1/2) · 핵심 지표

지표	평가 데이터	베이스라인	목표 수준	측정 절차
M1 안전 중요 상황 Recall	평가 200장 중 정답 high ≥150장	①, ②	① 대비 개선 목표. 개선 폭·95% CI와 McNemar p값 보고	정답 high 중 예측 high 비율. 보류는 미탐, 유형별 n·CI 보고
M2 위험 객체 F1	평가셋 약 200장	①, ②	① 대비 F1 개선 목표. precision·recall과 차이의 95% CI 보고	동일 클래스·IoU ≥0.5, 1:1 매칭. 프레임 단위 paired bootstrap
M3 객체 환각률	평가셋 약 200장	①, ②	① 대비 감소 목표. 응답·객체 단위 비율과 차이의 95% CI 보고	없는 객체를 언급한 응답/전체 응답. 객체 단위도 별도 보고

수치 목표는 검증셋에서 고정한다. 통계적 유의성은 결과 해석에 사용하며 기능 완료의 필수 조건으로 두지 않는다.

기호 설명 ① 미세조정 전 · ② 상용 VLM · CI: 신뢰구간 · IoU: 박스 겹침 비율. 환각·보류·동일 시퀀스 처리 규칙은 부록 A4~A5.

산출물 ⑦ · 어떻게 증명하는가?

평가 지표 (2/2) · 진단과 운영 지표

지표	평가 데이터	베이스라인	목표 수준	측정 절차
M4 영상 의존도	평가셋 × 정상· 영상 없음	모델 3종	영상 유무에 따른 행동 정확도 차이를 보고	동일 질문의 action 정오, McNemar·영상 없음 정확도
M5 형식 통과율	검증셋으로 기준, 평가셋에서 측정	없음	schema 통과 목표 100%. 실제 비율·실패 건수 보고	실패한 응답은 판단 보류로 기록
M6 지연시간·자원	평가셋 약 200장	①	모델별 실측값 비교. 환경·정밀도 함께 보고	준비 3회 제외: p50·p95 GPU peak·파라미터 수

In M7 근거 품질: 50장 × 3종, 2인 5점 척도·가중 kappa·LLM 채점 상관계수

추가 지표 M8 행동 정확도·혼동행렬 / M9 비고위험 과잉 경고율. 정의·목표·절차는 부록 A5.

영상 유무 차이와 bbox 정확도는 시각 근거의 진단 지표이며, 모델이 특정 객체를 인과적 근거로 사용했음을 입증하지 않는다.

산출물 ⑦ · 어떻게 증명하는가?

측정 절차와 평가 규칙

정량 평가

로컬 ①·③은 temperature 0.
검증셋에서 반복 안정성을 확인한다.
API ②는 조건별 3회 반복한다.

200장 × 2조건 × (1+3+1)
= 2,000회 본 평가 추론.
초벌·파일럿·추가 평가는 별도.

정성 평가

오답을 객체 누락·위치 오판,
없는 객체 언급, 상황 오분류,
행동 과소·과대 판단으로 분류한다.

고정 50장의 근거 문장을
사람 2인과 LLM이 평가하고
일치도·상관계수를 보고한다.

평가 규칙

규칙·목표·프롬프트는 검증셋으로
고정한다. 개발에는 검증셋만 쓴다.

정답 불일치는 합의 검수한다.
판정 불가 사례만 모델 실행 전에
제외하고 수량·사유를 공개한다.
최종 평가 후에는 재튜닝하지 않는다.

평가 1회는 반복 실행을 포함한다. 상세는 부록 A4~A6 참고.

산출물 연결 확인

스토리에서 평가까지

③ 사용자 스토리	④ 화면	⑥ 범위	⑦ 평가지표
S1 JSON 판단 받기	F1, F5	In	M5, M6
S2 위험 객체 박스 보기	F2, F5	In	M2, M3
S3 baseline 3종 비교	F1, F4	In	M1~M3, M8~M9
S4 놓친 사례 모아 보기	F2, F3	In	M1, M8, M9
S5 정상·영상 없음 비교	F1, F2, F4	In	M4
S6 근거 문장 검토	F5	In	M7
S7 유형별 Recall 보기	F2	In	M1, M9 (유형별)
S8 짧은 클립 입력	없음	Later	평가 제외

S1~S7은 화면·범위·지표와 연결한다. 세부 와이어프레임·라벨·채점 규칙은 부록에서 확인한다.

기호 설명 S: 사용자 스토리(9~10쪽). F: 화면(11~12쪽). M: 평가 지표(18~19쪽). In/Later: 범위(17쪽)

진행 계획

일정과 리스크

1주차 10/26~11/1	스키마 고정·GPU 확인·데이터 신청 샘플 5~10장 E2E와 후보 파일럿
2주차 11/2~11/8	분할·검수, 검증셋 baseline·목표 고정 LoRA 1차 학습 및 UI 기능 구현
3주차 11/9~11/15	검증셋으로 채점기·웹 기능 통합 근거 평가 rubric·API 비용 점검
4주차 11/16~11/22	고정 평가 캠페인·근거 평가·오류 분석
최종 발표 16주차 수업	결과 리포트와 데모 발표

리스크	대응
라벨링 시간 부족	파일럿 검수 시간을 측정하고 유형 균형을 유지하며 학습셋 축소
GPU 사양 미확인	4B·QLoRA로 파일럿 후 결정
채점 일관성	가이드를 수정해 재검수·합의. 판정 불가만 사전 제외하고 비율·사유를 함께 보고
원본 승인 지연·보행자 장면 부족	확보 샘플로 E2E부터 구현. 1주차 내 확보량·유형 분포 확인, 부족하면 범위·일정을 재협의
API 비용	단가·토큰·요청 한도로 예상액 산정 한도 초과 전 중단·팀 내 조정

1주차 E2E: 입력 → mock/모델 응답 → JSON 저장 → 박스·판단 표시. 담당, API 운영, 환경 고정 계획은 부록 A6.

감사합니다

Team1 · 보도 없는 생활도로 위험 판단 VLM

Appendix

부록 A1 · 상세 설계

핵심 화면 와이어프레임 · F1 평가 실행 / F2 결과 리포트

F1 평가 실행 [S1·S3·S5]

입력: 이미지 업로드 / 고정 평가셋 선택

① 미세조정 전 ② 상용 VLM ③ LoRA

조건: 정상 이미지 / 이미지 없음

실행 시작

출력: run_id·진행률·성공/실패 수
완료 시 F2로 이동

F2 결과 리포트 [S2·S4·S5·S7]

유형·모델·입력 조건 필터

위험 Recall / 행동 정확도 / 객체 F1
환각률·과잉 경고율·n·95% CI

T1~T5 × 모델 3종 성능표

사례 선택: F3 / 모델 비교: F4
프레임 선택: F5 / 실행 로그·결과 내려받기

상태 빈 화면: 입력 안내 / 실행 중: 진행률 / API 오류: 실패 건수·재시도 / 결과 없음: 필터 초기화

부록 A2 · 상세 설계

핵심 화면 와이어프레임 · F3 오답 사례 / F4 모델 비교

F3 오답 사례 뷰어 [S4]

유형 / 미탐·오탐 / 모델 / 보류 필터

사례 목록
프레임 ID
오류 분류

원본 + 정답·예측 박스
정답 high / 예측 low
action 정답·예측

클릭: F5 상세 / 결과 리포트로 돌아가기
출력: 필터와 일치하는 사례 수·목록

F4 모델 비교 [S3·S5]

동일 프레임 ID / 정상·영상 없음 전환

① 원본

위험 수준
action
bbox·근거
오류·보류 상태

② 상용

위험 수준
action
bbox·근거
오류·보류 상태

③ LoRA

위험 수준
action
bbox·근거
오류·보류 상태

정답 라벨과 모델별 성공·실패를 나란히 표시
프레임 선택 시 F5 / F2로 복귀

상태 필터 결과 없음: 초기화 / 응답 실패: 원인·재시도 / 판단 보류: 보류 사유 / 로딩: 프레임별 진행률

부록 A3 · 상세 설계

정답 라벨 가이드 · 위험 수준·행동·가림

라벨	단일 이미지에서의 판정 기준	허용 행동의 출발 기준
high	경로 충돌·통과 곤란 등 즉시 대응할 근거가 보임	정지 준비 또는 정지 후 대기
medium	가림·혼재 등 주의 요인은 있으나 즉시 충돌은 불명확	서행 또는 정지 준비
low	보이는 범위에서 뚜렷한 충돌·통과 장애가 없음	정상 주행 또는 서행

QA 라벨: 인지(보이는 객체·위치) / 예측(관측에 근거한 잠재 위험·불확실성) / 판단(허용 행동).
프레임마다 허용 action 집합을 고정하고, 그 집합에 속한 예측만 행동 정답으로 센다.

단계 프롬프트: 관측 사실 → 잠재 위험·불확실성 → 위험 수준·행동. 최종 응답은 공통 JSON으로 저장한다.

T3 가림: 가려진 출입 공간은 잠재 위험으로 기술한다. 보이지 않는 보행자를 존재한다고 쓰거나 박스를 만들면 객체 환각이다.
bbox는 보이는 객체에만 부여하고, 진행 경로는 화면 내 상대 위치로 정의한다. scene_types는 다중 선택 가능.

부록 A4 · 상세 설계

데이터 분할·검수·평가셋 고정 절차

단계	규칙	담당·완료 시점
확보·권리	AI Hub 승인·다운로드·외부 API 전송·재배포 조건 기록 허용 범위를 확인하지 못한 원본은 외부 API에 전송하지 않음	문혜승, 윤유경 1주차
분할	학습 200 / 검증 40 / 평가 200. 시퀀스 단위 분리 중복·유사 프레임 점검, T1~T5·위험 수준별 표본 수 기록	한태문, 고연오 2주차
검수	2인 독립 판단 후 합의. 합의 전 kappa·불일치율 보고 kappa 0.61 미만은 가이드 재검토 기준, 정확성 보증이 아님	전원(한태문 가이드) 2주차
고정	판정 불가만 모델 실행 전 제외, 수량·사유와 대체 규칙 기록 manifest·라벨·규칙 버전 고정. 최종 평가 후 재튜닝 금지	윤유경, 하경흠 최종 평가 전

평가 구성: high 150장 이상 + medium/low 합계 50장 이하를 목표로 하는 위험 중심 진단셋.
유형별 n과 confidence interval을 함께 보고하며, 실도로 빈도나 운행 승인 기준으로 해석하지 않는다.

부록 A5 · 상세 설계

추가 평가 지표와 공통 채점 규칙

지표	데이터·baseline	목표·측정 절차
M8 행동 판단	정상 입력 평가 200장 ①·②·③ 동일 질문	① 대비 정확도 개선 목표, 검증셋에서 수치 고정 허용 action 집합 기준 정확도·혼동행렬·행동별 recall
M9 과잉 경고율	정답 medium/low ①·②·③ 비교	① 대비 악화 여부와 95% CI 보고 예측 high 수 / 정답 non-high 수
M7 근거 품질	유형별 고정 50장 × 3종 사람 2인 + LLM	장면 일치·근거 없는 단정 1~5점 사람 간 가중 kappa, 평균 사람 점수–LLM Spearman ρ

M1 = 정답 high에서 예측 high인 수 / 정답 high 수. 보류는 미탐으로 처리한다.
M3 응답 환각률 = 없는 객체를 언급한 응답 수 / 전체 입력 수. 객체 단위 비율도 병기한다.

보류는 M8에서 오답으로 세고 별도 비율을 공개한다. M9에서 보류가 오탐으로 집계되지 않는 점을 함께 표시한다.
동일 프레임 paired bootstrap(시퀀스당 1장 우선, 복수면 시퀀스 단위 재표집). API 반복별 평균·표준편차·검정 결과를 보고한다.

부록 A6 · 상세 설계

실행 환경·외부 API·업무 연결 계획

항목	확정·실행 계획	담당
모델·환경	1주차 GPU 실측 후 4B/8B·정밀도 선택. 학습·검증 모형 고정 PyTorch·Transformers·PEFT·vLLM 버전과 CUDA·revision 기록	하경흠, 문혜승
API·비용	1주차 상용 zero-shot 모델 ID·요청 한도·단가·예산 상한 합의 200×2×3=1,200회 비교 호출 + 초벌 라벨·근거 채점 별도 산정	윤유경, 문혜승
실패·보안	429·timeout은 제한 재시도·지수 backoff, 실패도 원본 저장 API 키는 .env·.gitignore, 예산 도달 시 실행 중단	문혜승, 고연오
모듈 계약	image_id·run_id·model_id·condition·schema_version 공통 사용 1주차 mock E2E, 이후 같은 스키마로 실제 모델 교체	전원(통합 윤유경)
지원 연결	데이터·검수: 한태문 주담당, 고연오, 윤유경 지원 / 모델·평가: 하경흠 주담당, 윤유경 지원 / 배포·실험 환경: 문혜승 화면·데모: 고연오 주담당, 한태문 지원 / 배포·환경: 문혜승 주담당, 하경흠 지원	주담당이 결정 책임

버전·예산·승인은 TBD.

부록 A7 · 상세 설계

참고 자료와 확인 경로

과제·구성 요건	카카오모빌리티 실전SW프로젝트 안내 / 실전SW프로젝트 기획안 작성 안내 (제공 자료)
데이터	AI Hub 생활도로 객체인식 자율주행 데이터 (dataSetSn=71784) https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=71784
평가 근거	Xie et al., Are VLMs Ready for Autonomous Driving? ICCV 2025 https://github.com/worldbench/DriveBench
후보 모델	https://huggingface.co/Qwen/Qwen3-VL-4B-Instruct https://huggingface.co/kakaocorp/kanana-1.5-v-3b-instruct https://huggingface.co/naver-hyperclovax/HyperCLOVAX-SEED-Vision-Instruct-3B
사고 통계	도로교통공단 분석 인용 연합뉴스(2022. 5. 2.), 보행 사망자 수 비교 https://www.yna.co.kr/view/AKR20220429149200004

후보 모델의 성능은 본 데이터에서 검증한다. 데이터·모델의 개별 이용 조건과 외부 API 전송 가능 여부는 사용 전에 확인한다.