포지션별 이해 자료: AI 모델 (VLM · Training)

국내 생활도로 VLM 평가 벤치마크 및 개발 명세서 기준 · 실전SW프로젝트 팀1

본 문서는 AI 모델 포지션이 프로젝트를 이해하고 자기 파트의 배경, 설계 이유, 핵심 규칙을 설명할 수 있도록, 명세서에서 해당 포지션에 필요한 내용만 정리한다. 내용이 명세서와 다르면 명세서를 따른다.

1 프로젝트 한눈에 보기

본 프로젝트는 보도 없는 국내 생활도로의 전방 카메라 사진에서, VLM이 판단의 근거가 되는 Object를 찾고(①), 네 가지 위험 관계를 판정하고(②), 관계에 맞는 조건부 대응을 고르는지(③)를 단계마다 정답과 대조해 채점하는 Benchmark와, 이를 실행하고 결과를 확인하는 시스템을 만든다.

단계마다 채점하는 이유는 최종 답만으로는 모델이 장면을 보고 판단했는지 확인할 수 없기 때문이다. 기존 주행 VLM 평가에서는 사진을 넣지 않아도 점수가 비슷하거나 오히려 높게 나온 사례가 보고되었다 [1]. 따라서 본 Benchmark는 근거 Object, 관계 판정, 대응을 각각 사람이 작성한 정답과 대조한다.

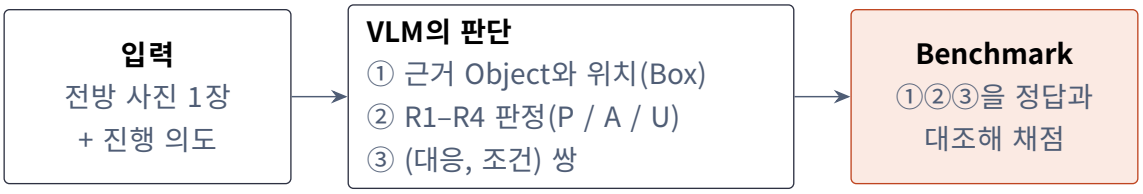


그림 1. 전체 구조. 정답을 기록하는 항목과 규칙이 Taxonomy이고, 채점 방법이 Metric이다.

평가는 세 Track으로 나누며, 첫 달에는 Track 1을 핵심 산출물로 완성한다. Track 2·3은 필요한 사건·시간·센서 정보의 검수 가능성을 확인한 뒤 핵심 일정에 영향을 주지 않는 범위에서 진행한다.

Track	무엇을 평가하는가	정답의 출처
Track 1 (Core) 현재 장면	사진 한 장에서 근거 Object, 위험 관계 R1–R4, 조건부 대응	사람이 입력만 보고 작성한 Annotation
Track 2 (Extension) 미래 사고	판단 시점까지의 영상으로 H 초 안에 자차와 충돌할 보행자	실제 사고 기록과 검수한 충돌 시점
Track 3 (Extension) 자차 움직임	관측 구간의 속도 변화와 회전 방향	영상과 동기화된 GNSS/INS 기록

1.1 공통 용어

아래 용어는 네 포지션이 같은 뜻으로 사용한다. 회의와 문서에서 다른 이름으로 바꾸어 부르지 않도록 통일한다.

용어	뜻
Driving Area (C)	진행 의도와 도로 구조만으로 정한 평가 영역(가상 주행 복도). 보행자나 장애물을 피해 그리지 않으며, 정답 작성과 채점에만 사용하고 모델에는 제공하지 않는다.
R1–R4	네 가지 위험 관계. R1 점유(C 안에 대상이 있는가), R2 출입구(C와 이어지는 출입구 주변에 보이는 Actor가 있는가), R3 시야 가림(필요한 영역이 가려졌는가), R4 통행 제한(통행 공간이 좁아졌는가).

용어	뜻
P / A / U	관계의 판정 값. P는 성립 근거가 있음, A는 충분히 확인했고 성립하지 않음, U는 입력만으로 판정할 수 없음을 의미한다. U는 모델의 자신감 부족이 아니라 정답의 하나다.
Actor / Obstacle	Actor는 보행자·이륜차·차량처럼 도로를 이용하는 주체, Obstacle은 스스로 움직이지 않는 장애물이다. 길가에 정렬되어 움직임의 근거가 없는 차량은 배치 속성을 Roadside Vehicle로 기록한다.
(대응, 조건) 쌍	대응은 단순 행동이 아니라 대응 Code와 조건 Code의 쌍으로 평가한다. 장면마다 필요(Required)·허용(Allowed)·금지(Forbidden) 대응을 정답으로 둔다.
Source Group	같은 영상·같은 촬영 구간에서 나온 자료의 묶음. 한 Group은 Train, Dev, Test 중 한 곳에만 배정한다.
Test freeze	모델 설정을 고르기 전에 Test의 입력·정답·채점 규칙을 고정하고, 마지막에 한 번만 채점하는 원칙.
V5 / V10	Track 1의 대표 점수. V5 Relation Macro-F1은 관계 판정, V10 Action Pass Rate는 대응 규칙 준수를 측정한다.

1.2 포지션 사이에서 주고받는 산출물

네 포지션은 아래 산출물로 연결된다. 자기 산출물의 형식이 바뀌면 그 산출물을 사용하는 포지션에 먼저 알린다.

산출물	작성	사용
Annotation Guideline, 정답(`references`), 장면 속성·근거(`annotations`)	데이터	AI 모델(학습), 백엔드(채점), 프론트엔드(정답 표시)
모델 출력(`predictions`), 실행 설정(`runs`)	AI 모델	백엔드(채점), 프론트엔드(예측 표시)
자동 채점 결과, Report API	백엔드	프론트엔드(화면), 팀 전체(비교 판단)
Web Viewer(F1–F5)	프론트엔드	모델 개발자, 운영·검증 담당자

2 AI 모델 포지션의 역할

AI 모델 포지션은 Google Gemma 4 계열 모델이 사진을 받아 근거 Object, R1–R4 판정, (대응, 조건) 쌍을 정해진 JSON 형식으로 출력하게 하고, 추가 학습 전(Base)과 후(Tuned)의 성능을 같은 조건에서 비교할 수 있게 만든다.

모델이 최종 대응만 맞히는 것으로는 충분하지 않다. 사진을 보지 않고도 그럴듯한 대응을 답할 수 있기 때문이다[1]. 본 Benchmark는 모델이 어떤 Object를 근거로 어떤 관계를 판정했고 그 관계에서 어떤 대응을 골랐는지를 단계마다 채점하므로, 모델은 세 단계를 모두 같은 답 안에서 일관되게 출력해야 한다.

AI 모델 포지션의 산출물은 네 가지다. 첫째, 입력을 받아 Schema에 맞는 JSON을 출력하는 추론 Code와 Prompt다. 둘째, Gemma 4의 좌표 출력을 본 문서의 좌표로 바꾸는 Parser다. 셋째, Base 모델의 Zero-shot 결과와 오류 분석 Report다. 넷째, LoRA 또는 QLoRA로 학습한 Checkpoint와 그

실행 기록이다.

3 입력과 출력

입력은 Track마다 다르고, 출력은 모든 모델이 같은 Schema를 따른다. 출력 Schema를 먼저 고정해 두면 모델 크기나 학습 방식이 바뀌어도 채점 체계를 그대로 사용할 수 있다.

Track	입력
Track 1	판단 시점 t의 전방 사진 한 장과 진행 의도 `follow_visible_road_forward`(보이는 도로를 따라 앞으로 진행하려 한다)
Track 2	판단 시점 t까지의 Frame. 이후 Frame은 입력에 넣지 않는다.
Track 3	관측 구간의 Frame Sequence

Track 1의 출력은 다섯 부분으로 구성한다. `objects`는 근거 Object의 ID, Class, 정규화 좌표 Box이고, `regions`는 출입구처럼 Object가 아닌 근거 영역이다. `scene`은 좌·우 Sidewalk, Traffic Direction, Direction Match이고, `relations`는 R1–R4 각각의 판정 값과 근거 ID이며, `actions`는 (대응, 조건) 쌍과 그 근거 관계(`based_on`)다. 설명 문장(`explanation`)은 선택 항목이지만, 내면 진술 단위로 검수된다.

```
{
  "intent": "follow_visible_road_forward",
  "objects": [
    {"id": "o1", "class": "pedestrian",
     "bbox": [0.43, 0.55, 0.49, 0.81]},
    {"id": "o2", "class": "vehicle", "placement": "roadside",
     "bbox": [0.57, 0.51, 0.85, 0.87]}
  ],
  "regions": [{"id": "z1", "class": "occluded_entrance",
               "bbox": [0.62, 0.31, 0.79, 0.69]}],
  "scene": {"sidewalk_left": "A", "sidewalk_right": "A",
            "traffic_direction": "Unknown",
            "direction_match": "Unknown"},
  "relations": [
    {"code": "R1", "state": "P", "evidence": ["o1", "o2"]},
    {"code": "R2", "state": "A", "evidence": []},
    {"code": "R3", "state": "P", "evidence": ["o2", "z1"]},
    {"code": "R4", "state": "P", "evidence": ["o2"]}
  ],
  "actions": [
    {"code": "HOLD_UNTIL_CLEAR",
     "condition": "while_corridor_occupied", "based_on": ["R1"]},
    {"code": "VERIFY_BEFORE_ADVANCE",
     "condition": "before_entering_occluded_area", "based_on": ["R3"]},
    {"code": "VERIFY_PASSAGE",
     "condition": "before_passing_restricted_section", "based_on": ["R4"]}
  ],
  "explanation": "보행자 o1이 C를 점유하고, o2가 z1을 가린다."
}
```

위 출력은 명세서 §2.5의 예시 장면에 대한 모범 답이다. 필드 이름은 2주차 Schema 확정 때 최종 결정하며, 확정 후에는 모델이 바뀌어도 변경하지 않는다.

4 출력 규칙

채점기는 출력의 형식, 근거, 관계, 대응을 각각 검사한다. 아래 규칙을 지키지 않으면 내용이 맞아도 점수를 잃는다.

형식. 출력은 JSON으로 읽혀야 하고, 필수 항목이 있어야 하며, 허용된 값과 0–1 범위의 좌표를 지켜야 한다. 관계나 대응에서 참조한 ID는 같은 답 안에 실제로 선언되어 있어야 한다. 이 조건을 지키지 않은 답은 Invalid로 집계되며, 관계 판정에서는 정답을 놓친 것으로, 대응 판정에서는 실패로 처리된다.

판정 값. R1–R4는 P, A, U 중 하나로 답한다. U는 "입력에 판정할 정보가 없다"는 정답이며, 판정할 수 있는 장면에서 U로 피하면 Over-abstention(V9)이 오르고, 판정할 수 없는 장면에서 단정하면 Recall for Unknown(V8)이 내려간다. 보이지 않는 대상에는 Box를 선언하지 않는다. 가림 뒤에 사람이 있다고 단정하는 진술은 근거 대조와 진술 검수에서 오류로 집계된다.

대응. 대응은 아래 일곱 가지 대응 Code와 여섯 가지 조건 Code의 쌍으로만 답한다. 각 조건 Code는 특정 관계 판정이 있어야 쓸 수 있으므로, 모델은 자기 출력의 `relations`와 모순되지 않는 조건만

사용해야 한다. 예를 들어 R3 = A라고 출력하면서 가림을 근거로 대응하면, 정답 R3가 P라도 답 안에서 모순되어 실패로 처리된다.

대응 Code	뜻
VERIFY_BEFORE_ADVANCE	확인 후 진행
REDUCE_SPEED_IF_MOVING	이동 중이면 감속
YIELD_IF_OCCUPIED	점유 시 양보
HOLD_UNTIL_CLEAR	해소될 때까지 보류
VERIFY_PASSAGE	통과 가능성 확인
MONITOR_AHEAD	전방 관찰
ADVANCE_WITH_MONITORING	관찰하며 진행

조건 Code	쓸 수 있는 관계 판정
no_condition	제한 없음
while_corridor_occupied	R1 = P
while_actor_near_entrance	R2 = P
before_entering_occluded_area	R3 = P
before_passing_restricted_section	R4 = P 또는 U
before_resolving_uncertainty	R1 · R2 · R3 중 U (based_on에 U인 관계를 모두 기재)

장면마다 정답에는 필요·허용·금지 대응이 정해져 있다. 모델은 필요 대응 묶음을 모두 충족하고, 금지 대응과 정답에 등록되지 않은 쌍을 답하지 않아야 통과한다. 위험 요인이 없는 장면(R1–R4 모두 A)에서는 관찰하며 진행이 정답이므로, 모든 장면에 정지나 보류를 답하는 모델은 통과하지 못한다.

5 좌표 변환

본 Benchmark의 Box는 사진의 가로·세로로 나눈 정규화 좌표 $[x_1, y_1, x_2, y_2]$(0–1)다. Gemma 4는 Object Detection 결과를 1000×1000 기준의 상대 좌표 Box(box_2d)로 출력하는 사례가 공개되어 있으므로[2], 이를 변환하는 Parser가 필요하다.

변환은 각 좌표를 1000으로 나누는 방식으로 수행한다. 다만 공개 자료는 box_2d의 좌표 순서(세로 좌표가 먼저인지 가로 좌표가 먼저인지)를 명시하지 않으므로, 1주차 Pilot에서 위치를 알고 있는 Object로 순서를 확인한 뒤 Parser를 고정한다. 변환이 잘못되면 근거 대조 단계에서 모든 Box가 짝을 찾지 못한다.

채점기는 Class가 같고 IoU(두 Box의 겹친 면적을 합친 면적으로 나눈 값)가 0.5 이상인 예측과 정답만 짝으로 인정한다(V3). 관계의 근거 ID 일치(V4)는 이 짝짓기로 모델의 ID를 정답 ID로 바꾼 뒤 비교하므로, Box가 짝을 찾지 못하면 관계를 맞혀도 V4에서 실패한다.

6 모델과 자원

기본 모델은 Apache 2.0 라이선스로 공개된 Google Gemma 4 계열이며[2], VRAM 48GB GPU를 사용할 수 있다고 가정한다. 모델 크기는 1주차에 메모리와 처리 시간을 실측한 뒤 확정한다.

크기	파라미터	bf16 가중치	48GB 기준 학습 방식
E4B	Embedding 포함 약 8B	약 16GB	LoRA 학습 후보
12B	약 12B	약 24GB	LoRA 학습 후보
26B A4B	총 약 26B (MoE)	약 52GB	4-bit 양자화(QLoRA) 전제
31B	약 31B	약 62GB	4-bit 양자화(QLoRA) 전제

표의 메모리는 가중치만 산술로 추정한 값이며, 실제 학습에는 Activation과 Optimizer 메모리가 추가된다. 학습은 Transformers 통합을 통해 PEFT와 TRL을 사용할 수 있다[2]. Gemma 4는 모든 크기가 이미지와 Video 입력을 지원하지만 Video에 대해 별도의 사후 학습을 거치지 않은 것으로 공개되어 있으므로, Track 2·3의 Frame Sequence 입력 성능은 Pilot에서 확인한다. 과제 데이터는 외부 API로 전송하지 않으므로 추론과 학습은 확보한 GPU에서 수행한다.

7 데이터 사용 규칙

추가 학습에는 Train만, Prompt와 학습 설정의 선택에는 Dev만 사용하고, Test는 모든 설정을 고정한 뒤 마지막에 한 번만 채점한다.

Test 결과를 보고 Prompt나 설정을 고치면, Test에 맞춘 조정이 성능 향상처럼 나타나므로 Base와 Tuned의 비교를 해석할 수 없게 된다. 데이터는 같은 영상에서 나온 자료를 하나의 Source Group으로 묶어 한 Split에만 배정하므로, Dev에서 본 배경이 Test에 다시 나오지 않는다. Guideline 개정에 사용한 Pilot 장면도 Train/Dev에만 포함한다.

8 채점 방식

모델 성능은 대표 점수 두 개로 비교하고, 진단 점수로 어느 단계에서 틀렸는지 분석한다. 개선 여부는 같은 Test에서 구한 Base와 Tuned의 점수 차이의 95% 신뢰구간이 0보다 위일 때만 인정한다.

V5 Relation Macro-F1은 4관계 × 3상태(P/A/U) = 12칸마다 F1을 구해 같은 비중으로 평균한다. 특정 관계에서 A가 다수를 차지하면 항상 A만 답해도 정확도는 높게 나오지만, 칸별 평균에서는 P와 U 칸의 F1이 0이 되어 점수가 낮아진다.

$$\mathrm{V5} = \frac{1}{12} \sum_{h \in \{R1,\ldots,R4\}} \sum_{c \in \{P,A,U\}} F1_{h,c}, \qquad F1_{h,c} = \frac{2\,TP_{h,c}}{2\,TP_{h,c} + FP_{h,c} + FN_{h,c}} \tag{1}$$

V10 Action Pass Rate는 대응 규칙을 지킨 장면의 비율이다. 한 장면은 형식이 맞고, 필요 대응 묶음을 모두 충족하며, 금지 대응이나 등록되지 않은 대응이 없고, 모델 자신의 관계 판정과 모순되지 않을 때만 통과한다. V10은 관계와 대응 조건의 일관성을 평가하며, Box 위치와 근거 연결의 정확성은 V3·V4에서 별도로 측정한다.

진단 점수	모델 개선에 주는 정보
V1 / V2 형식 통과율	출력 형식이 채점을 막고 있는지 확인한다. Prompt와 디코딩 설정의 첫 점검 대상이다.
V3 Object F1, V4 Evidence ID Match	Box를 잘못 찾는지, 관계는 맞히되 근거 Object를 잘못 연결하는지 구분한다.

진단 점수	모델 개선에 주는 정보
V6 Recall for Present, V7 False Positive Rate	있는 위험을 놓치는지, 없는 위험을 있다고 하는지 구분한다.
V8 Recall for Unknown, V9 Over-abstention	판단할 수 없는 것을 단정하는지, 판단할 수 있는 것을 U로 피하는지 구분한다.
V11 Required Action Coverage, V12 Forbidden Action Rate	V10 실패의 원인이 필요 대응의 누락인지 금지 대응인지 구분한다.
V13 / V14 진술 오류율	설명 문장에서 근거 없이 단정한 진술의 비율과, 그런 진술이 있는 답의 비율을 측정한다.

9 실행 기록

모든 실행은 Run ID로 기록하며, 사용한 Prompt, 모델 Checkpoint, 디코딩 설정, Seed, 실행 환경, 데이터와 Label의 Version을 함께 저장한다.

같은 예측 결과를 같은 채점 Code로 다시 채점하면 같은 점수가 나와야 한다. 반면 생성형 모델에 다시 질의하는 재추론은 설정과 실행 환경에 따라 결과가 달라질 수 있으므로, 위 설정을 빠짐없이 기록하고 결과가 달라지면 실행 간 변동을 확인한다. 형식 오류나 Timeout이 난 응답도 원본 그대로 저장한다.

10 일정과 완료 기준

아래 표는 명세서 §5.1의 4주 일정 중 AI 모델 포지션이 맡는 작업과 완료 기준이다.

주차	AI 모델 포지션의 작업	완료 기준
1주차	GPU에서 Gemma 4 크기별 메모리와 장면당 처리 시간을 측정하고, Pilot 장면으로 `box_2d` 좌표 순서를 확인한다.	모델 크기 결정, Parser 고정
2주차	확정된 Schema에 맞는 출력을 만드는 Prompt와 추론 Code를 완성한다.	예제 장면의 출력이 채점기를 통과함
3주차	Base를 Zero-shot으로 평가하고 지표별로 오류를 분석한다. 분석 결과로 학습 데이터를 기획하고 LoRA 학습을 시작한다.	Dev 기준 오류 분석 Report
4주차	같은 Test에서 Base와 Tuned를 비교한다.	대표·진단 점수와 차이의 신뢰구간

LoRA 학습이 지연되어도 Base 모델의 결과와 오류 분석 Report는 산출물로 남긴다. 이때 Tuned 결과는 확보한 범위에서 Dev 결과로 명시하여 보고하고 Test 결과와 구분한다.

11 자주 받을 질문

Q. 최종 대응만 맞히면 되지 않는가?

A. 최종 대응은 사진을 보지 않고도 맞힐 수 있으므로, 근거 Object와 관계 판정까지 채점해야 모델이 장면을 보고 판단했는지 확인할 수 있다.

Q. 자신 없는 관계는 U로 답하면 안전하지 않은가?

A. 판정할 수 있는 장면에서 U로 답하면 Over-abstention(V9)이 오르고 V5의 P·A 칸 점수가 떨어진다. U는 입력에 정보가 없을 때만 정답이다.

Q. 관계를 맞혔는데 점수가 낮은 이유는 무엇인가?

A. Box가 정답과 IoU 0.5 이상으로 짝을 찾지 못했거나, 근거 ID를 다른 Object에 연결했을 수 있다. V3와 V4를 함께 확인한다.

Q. 어떤 Gemma 4 크기를 쓰는가?

A. 48GB 기준으로 E4B와 12B는 LoRA, 26B A4B와 31B는 QLoRA를 전제로 하며, 1주차 실측 결과로 확정한다.

명세서에서 함께 볼 곳

본 문서의 근거는 명세서 §2.4–2.5(대응 체계와 예시), §3(평가 및 진단 체계), §4.3(실행 관리), §4.5(모델과 기술 스펙), App. A(세부 지표 정의), App. B(대응 규칙 상세와 출력 예시)에 있다.

참고 문헌

[1] S. Xie et al. Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives. ICCV, 2025.

[2] Google. Gemma 4 model family, Apache 2.0. Hugging Face blog, “Welcome Gemma 4”, 2026. `https://huggingface.co/blog/gemma4`