포지션별 이해 자료: 백엔드 (Backend · MLOps)

국내 생활도로 VLM 평가 벤치마크 및 개발 명세서 기준 · 실전SW프로젝트 팀1

본 문서는 백엔드 포지션이 프로젝트를 이해하고 자기 파트의 배경, 설계 이유, 핵심 규칙을 설명할 수 있도록, 명세서에서 해당 포지션에 필요한 내용만 정리한다. 내용이 명세서와 다르면 명세서를 따른다.

1 프로젝트 한눈에 보기

본 프로젝트는 보도 없는 국내 생활도로의 전방 카메라 사진에서, VLM이 판단의 근거가 되는 Object를 찾고(①), 네 가지 위험 관계를 판정하고(②), 관계에 맞는 조건부 대응을 고르는지(③)를 단계마다 정답과 대조해 채점하는 Benchmark와, 이를 실행하고 결과를 확인하는 시스템을 만든다.

단계마다 채점하는 이유는 최종 답만으로는 모델이 장면을 보고 판단했는지 확인할 수 없기 때문이다. 기존 주행 VLM 평가에서는 사진을 넣지 않아도 점수가 비슷하거나 오히려 높게 나온 사례가 보고되었다 [1]. 따라서 본 Benchmark는 근거 Object, 관계 판정, 대응을 각각 사람이 작성한 정답과 대조한다.

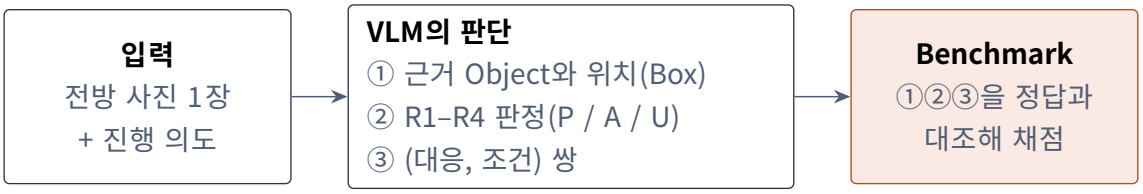


그림 1. 전체 구조. 정답을 기록하는 항목과 규칙이 Taxonomy이고, 채점 방법이 Metric이다.

평가는 세 Track으로 나누며, 첫 달에는 Track 1을 핵심 산출물로 완성한다. Track 2·3은 필요한 사건·시간·센서 정보의 검수 가능성을 확인한 뒤 핵심 일정에 영향을 주지 않는 범위에서 진행한다.

Track	무엇을 평가하는가	정답의 출처
Track 1 (Core) 현재 장면	사진 한 장에서 근거 Object, 위험 관계 R1–R4, 조건부 대응	사람이 입력만 보고 작성한 Annotation
Track 2 (Extension) 미래 사고	판단 시점까지의 영상으로 H 초 안에 자차와 충돌할 보행자	실제 사고 기록과 검수한 충돌 시점
Track 3 (Extension) 자차 움직임	관측 구간의 속도 변화와 회전 방향	영상과 동기화된 GNSS/INS 기록

1.1 공통 용어

아래 용어는 네 포지션이 같은 뜻으로 사용한다. 회의와 문서에서 다른 이름으로 바꾸어 부르지 않도록 통일한다.

용어	뜻
Driving Area (C)	진행 의도와 도로 구조만으로 정한 평가 영역(가상 주행 복도). 보행자나 장애물을 피해 그리지 않으며, 정답 작성과 채점에만 사용하고 모델에는 제공하지 않는다.
R1–R4	네 가지 위험 관계. R1 점유(C 안에 대상이 있는가), R2 출입구(C와 이어지는 출입구 주변에 보이는 Actor가 있는가), R3 시야 가림(필요한 영역이 가려졌는가), R4 통행 제한(통행 공간이 좁아졌는가).

용어	뜻
P / A / U	관계의 판정 값. P는 성립 근거가 있음, A는 충분히 확인했고 성립하지 않음, U는 입력만으로 판정할 수 없음을 의미한다. U는 모델의 자신감 부족이 아니라 정답의 하나다.
Actor / Obstacle	Actor는 보행자·이륜차·차량처럼 도로를 이용하는 주체, Obstacle은 스스로 움직이지 않는 장애물이다. 길가에 정렬되어 움직임의 근거가 없는 차량은 배치 속성을 Roadside Vehicle로 기록한다.
(대응, 조건) 쌍	대응은 단순 행동이 아니라 대응 Code와 조건 Code의 쌍으로 평가한다. 장면마다 필요(Required)·허용(Allowed)·금지(Forbidden) 대응을 정답으로 둔다.
Source Group	같은 영상·같은 촬영 구간에서 나온 자료의 묶음. 한 Group은 Train, Dev, Test 중 한 곳에만 배정한다.
Test freeze	모델 설정을 고르기 전에 Test의 입력·정답·채점 규칙을 고정하고, 마지막에 한 번만 채점하는 원칙.
V5 / V10	Track 1의 대표 점수. V5 Relation Macro-F1은 관계 판정, V10 Action Pass Rate는 대응 규칙 준수를 측정한다.

1.2 포지션 사이에서 주고받는 산출물

네 포지션은 아래 산출물로 연결된다. 자기 산출물의 형식이 바뀌면 그 산출물을 사용하는 포지션에 먼저 알린다.

산출물	작성	사용
Annotation Guideline, 정답(`references`), 장면 속성·근거(`annotations`)	데이터	AI 모델(학습), 백엔드(채점), 프론트엔드(정답 표시)
모델 출력(`predictions`), 실행 설정(`runs`)	AI 모델	백엔드(채점), 프론트엔드(예측 표시)
자동 채점 결과, Report API	백엔드	프론트엔드(화면), 팀 전체(비교 판단)
Web Viewer(F1–F5)	프론트엔드	모델 개발자, 운영·검증 담당자

2 백엔드 포지션의 역할

백엔드 포지션은 모델의 출력을 정답과 대조해 모든 점수를 자동으로 계산하는 채점기, 실행 결과를 다시 확인할 수 있게 하는 저장 구조, 그리고 결과를 화면에 전달하는 Report API를 만든다.

채점기는 Benchmark의 판정 규칙을 Code로 옮긴 것이므로, 규칙과 Code가 다르면 모든 모델 비교 결과가 틀어진다. 따라서 본 문서의 분모 규칙과 예외 처리를 그대로 구현하고, 예외 상황의 예제로 검증한다. 산출물은 네 가지다. 첫째, 저장 구조와 실행 기록 형식이다. 둘째, V1–V14, A1, A2, L1–L3를 계산하는 자동 채점기다. 셋째, Wilson 신뢰구간과 Group 단위 Paired Bootstrap을 계산하는 통계 모듈이다. 넷째, 프론트엔드가 사용하는 Report API다.

3 저장 구조와 재현성

저장 위치는 모델이 볼 수 있는 자료와 볼 수 없는 자료의 경계에 따라 나누고, 한 번의 실행에 사용한 모든 설정을 Run ID로 연결한다. 복잡한 MLOps 플랫폼 대신 이 구조를 쓰는 이유는 한 달 일정 안에서 실행 설정의 추적을 확실히 하기 위함이다.

저장 위치	담는 내용
`items`	모델 입력과 질문. 실행 전에 고정한다.
`annotations`	장면 속성, 근거, 작성·검수 상태. 모델 입력과 분리한다.
`references`	검수가 끝난 Task별 정답과 대응 규칙. Test 분은 고정한다.
`predictions`	모델의 원래 출력. 형식 오류와 Timeout도 삭제하지 않고 보존한다.
`runs`	Prompt, 모델 Checkpoint, 디코딩 설정, Seed, 실행 환경, 데이터·Label·Split Version, 채점 Code의 Git Commit Hash

재채점과 재추론은 구분하여 관리한다. 같은 예측 결과를 같은 채점 Code와 같은 정답 Version으로 다시 채점하면 같은 점수가 나와야 하며, 이는 채점기의 검증 기준이다. 반면 생성형 모델에 다시 질의하는 재추론은 설정과 실행 환경에 따라 결과가 달라질 수 있으므로, `runs`에 설정을 기록하고 결과가 달라지면 실행 간 변동을 보고한다. 평가 요청 목록은 실행 전에 고정하고, 실패한 요청은 실패 상태로 남겨 집계한다. 정상 응답만 남기면 실패율이 실제보다 낮게 집계되기 때문이다.

4 채점 Pipeline

채점은 형식 검사 → 근거 대조 → 관계·속성 판정 → 대응 판정 → 신뢰구간의 순서로 진행한다. 뒤 단계는 앞 단계의 결과(형식 통과 여부, Box 짝짓기)를 사용한다.



그림 2. 채점 Pipeline. 강조한 두 단계가 대표 점수 V5와 V10을 계산한다.

5 공통 규칙

분모와 예외 처리는 점수마다 다르다. 아래 규칙을 Code 수준에서 그대로 구현한다.

- **Valid의 정의.** JSON으로 읽히고, 필수 항목이 있으며, 허용된 값과 0–1 좌표 범위를 지키고, 참조한 ID가 같은 답 안에 선언된 답만 Valid다. V1은 Valid 비율, V2는 나머지(형식 오류와 Timeout) 비율이다.
- **Invalid의 반영.** 관계·속성 판정에서는 정답을 놓친 것(FN)으로 센다. 따라서 V6과 V8에서는 분모에만 남고, V7과 V9는 각각 "P로 단정함"과 "U로 피함"을 세는 점수이므로 Invalid를 분모에만 포함한다. V10과 V11은 Invalid를 실패로 세고, V12는 금지 쌍이 확인된 답만 세므로 Invalid를 분모에만 포함한다.
- **Missing과 N/A.** 정답이 Missing인 항목은 채점 전에 제외하고, Reviewed 상태인 정답만 사용한다. 분모가 0인 점수는 0이나 100%가 아니라 N/A로 보고한다.
- **방향 충돌 장면.** 정답 Direction Match가 Conflicting인 장면은 V10–V12의 분모에서 제외하고, V5–V9와 A1, A2에서는 계속 채점한다. 제외한 수와 이유를 Report에 포함한다.

6 지표 구현 명세

6.1 근거 대조 (V3, V4)

V3은 Class가 같고 IoU가 0.5 이상인 예측과 정답만 짝이 될 수 있으며, 한 예측과 한 정답은 최대 한 번만 짝짓는다. 짝의 수가 가장 많아지도록 고르고, 수가 같으면 IoU의 합이 큰 쪽을 고른다. 구현 예로, 조건을 만족하는 쌍에 가중치 $M + \mathrm{IoU}$(M은 짝 후보 수보다 큰 상수)를 주고 최대 가중치 이분 매칭(Hungarian Algorithm)을 풀면 두 조건을 함께 만족한다. 단순 Greedy 매칭은 짝의 수를 최대화하지 못할 수 있으므로 사용하지 않는다. Object와 Region은 종류별로 따로 짝짓고, IoU 0.3과 0.7에서도 함께 계산한다. Precision은 $TP/(TP+FP)$, Recall은 $TP/(TP+FN)$, F1은 $2TP/(2TP+FP+FN)$이다.

V4는 관계의 근거 ID 집합이 정답 집합과 정확히 같은지를 판정한다. 먼저 V3의 짝짓기로 모델 ID를 정답 ID로 바꾼 뒤 비교하며, 짝이 없는 ID를 근거로 댔거나 형식 오류인 답은 실패다. 분모는 정답이 P 또는 U이면서 근거 검수가 끝난 판정 항목이며, 근거가 될 수 있는 조합이 여럿이면 모두 정답으로 인정한다.

6.2 관계 판정 (V5–V9)

V5는 관계 h와 상태 $c \in \{P, A, U\}$마다 $F1_{h,c}$를 구해 12칸을 같은 비중으로 평균한다. 12칸 모두에 검수된 정답이 있을 때만 V5로 보고하고, 하나라도 비면 V5는 N/A로 두고 정답이 있는 칸만 평균한 값을 Supported-class Macro-F1이라는 다른 이름으로 보고한다.

$$\mathrm{V5} = \frac{1}{12} \sum_{h} \sum_{c \in \{P,A,U\}} \frac{2\,TP_{h,c}}{2\,TP_{h,c} + FP_{h,c} + FN_{h,c}} \tag{1}$$

점수	식	측정하는 오류
V6 Recall for Present	$\#(y{=}P, \hat{y}{=}P)$ / $\#(y{=}P)$	있는 관계를 놓침
V7 False Positive Rate	$\#(y{=}A, \hat{y}{=}P)$ / $\#(y{=}A)$	없는 관계를 있다고 함
V8 Recall for Unknown	$\#(y{=}U, \hat{y}{=}U)$ / $\#(y{=}U)$	판정할 수 없는 것을 단정함

점수	식	측정하는 오류
V9 Over-abstention	$\#(y{\in}\{P,A\}, \hat{y}{=}U) \,/\, \#(y{\in}\{P,A\})$	판정할 수 있는데 U로 피함

6.3 장면 속성 (A1, A2)

A1은 Sidewalk 좌·우, Traffic Direction, Direction Match의 Field별로 값마다 F1을 구해 평균하며, V5와 합산하지 않는다. Direction Match의 정답이 Not applicable인 장면은 A1의 분모에서 제외하고, 정답이 적용 가능한 값인데 모델이 Not applicable이라고 답하면 FN으로 센다. A2는 정답이 Not applicable인 장면 중 모델이 Consistent나 Conflicting이라고 답한 비율이다. Field별 Confusion Matrix와 값별 표본 수도 함께 반환한다.

6.4 대응 판정 (V10–V12)

장면 i의 허용 쌍 집합을 A_i, 금지 쌍 집합을 F_i, 필요 대응 묶음을 $G_{i1}, \ldots, G_{im_i}$, 모델이 답한 쌍의 집합을 S_i라 하면 다음과 같다.

$$\mathrm{AP}_i = \mathbf{1}\Big[V_i \wedge C_i \wedge S_i \subseteq A_i \wedge S_i \cap F_i = \varnothing \wedge \textstyle\bigwedge_j \left(S_i \cap G_{ij} \neq \varnothing\right)\Big], \qquad \mathrm{V10} = \tfrac{1}{N_A} \textstyle\sum_{i \in \mathcal{A}} \mathrm{AP}_i \tag{2}$$

V_i는 Valid 여부다. C_i는 두 가지 일관성 검사로, 답한 조건 Code가 요구하는 정답 판정이 실제로 있는지(정답과의 일관성)와, `based_on`이 필요한 관계를 가리키고 모델 자신의 관계 판정이 그 조건을 뒷받침하는지(답 내부의 일관성)를 모두 확인한다. 같은 조건의 보류와 진행처럼 적용 구간이 겹치면서 서로 모순되는 쌍을 함께 답해도 C_i에서 실패한다. C_i는 Box 위치와 근거 ID의 정확성을 검사하지 않으며, 이는 V3·V4에서 측정한다. 허용에도 금지에도 없는 쌍(Unsupported Pair)은 실패로 처리하고 그 수를 따로 집계한다. 분모 $\mathcal{A}$는 실행 전에 고정하여 모델의 예측 결과와 무관하게 유지한다.

V11은 전체 필요 대응 묶음 중 올바른 조건과 근거로 충족한 묶음의 비율($\sum_{i,j} r_{ij} / \sum_i m_i$)이고, V12는 금지 쌍이 하나라도 확인된 답의 비율($(1/N_A)\sum_i \mathbf{1}[S_i \cap F_i \neq \varnothing]$)이다.

6.5 진술 검수와 정답 품질 (V13, V14, L1–L3)

V13과 V14는 사람이 설명 문장을 최소 진술로 나누고 오류 여부를 표시한 결과를 입력으로 받는다. V13은 검수한 진술 중 오류 진술의 비율이고, V14는 오류 진술이 하나라도 있는 답의 비율이다. 설명을 요구한 요청 중 검수할 수 있는 설명을 낸 비율(Explanation Completion Rate)도 함께 계산한다. L1은 두 Annotator의 합의 전 일치 비율, L2는 Cohen's $\kappa = (p_o - p_e)/(1 - p_e)$이며 Field별로 계산한다. $p_e = 1$이면 κ는 N/A다. L3은 관계·상태별 문항 수와 서로 다른 Source Group 수다.

7 신뢰구간과 개선 판정

모든 점수에는 분모와 95% 신뢰구간을 함께 반환한다. Base 대비 Tuned의 개선은 같은 표본에서 구한 차이의 95% 구간 하한이 0보다 클 때만 "개선"으로 판정한다.

Wilson 구간은 서로 독립인 장면마다 성공·실패가 하나씩 나오는 비율 점수에 사용한다[2]. 성공 수 k, 분모 n, $\hat{p} = k/n$, $z = 1.96$일 때 다음과 같다. 예를 들어 40/50(80%)의 구간은 약 67.0%–88.8%다.

$$\mathrm{CI}_{95} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \tag{3}$$

Group 단위 Paired Bootstrap은 Wilson 구간을 쓸 수 없는 점수(V5, A1처럼 여러 F1을 평균한 점수, 같은 Group의 문항을 여러 개 세는 점수)와 두 모델의 차이에 사용한다[3]. 절차는 다음과 같다.

1. 서로 다른 Source Group G개에서 G개를 복원추출한다.

2. 뽑힌 Group의 문항을 모두 포함해 Base와 Tuned의 점수를 같은 표본으로 다시 계산하고, 차이 $\Delta^* = M^*_{\text{Tuned}} - M^*_{\text{Base}}$를 구한다.
3. 이를 2,000번 반복하고, 각 점수와 차이의 2.5번째·97.5번째 백분위수를 95% 구간으로 반환한다.

Group 단위로 뽑는 이유는 같은 영상의 문항들이 서로 유사하여, 문항을 독립 표본처럼 세면 구간이 실제보다 좁게 계산되기 때문이다. Source Group이 하나뿐이면 구간은 N/A다. 어떤 반복에서 특정 상태의 정답이 0개가 되어 V5를 정의할 수 없으면 그 비율을 기록하고 V5의 구간은 N/A로 표시한다.

조건별 점수(예: 야간 장면의 R1 Present Recall)는 사람의 Annotation으로 미리 정한 장면 집합에서 다시 계산하며, 모든 모델에 같은 집합을 사용한다. 모델의 예측으로 집합을 만들면 모델마다 평가 대상이 달라지기 때문이다. 분모가 작은 조건은 탐색적 결과로 표시한다.

8 누수 검사

채점 전에 두 가지를 자동으로 검사한다. 첫째, 같은 Source Group이 둘 이상의 Split에 배정되지 않았는지 확인한다. 둘째, 입력 Frame의 Timestamp가 판단 시점 이후가 아닌지 확인한다. 이 검사는 누수 위험을 줄이는 장치이며, 검사 범위 밖의 누수 가능성은 Report에 한계로 명시한다.

9 Report API

프론트엔드는 Report API로 대표 점수, 진단 점수, 신뢰구간, 개선 판정, 조건별 점수를 받는다. 아래 응답은 형식을 보이기 위한 예시이며, 수치는 실제 결과가 아니다.

```
GET /api/runs/{run_id}/report?base={base_run_id}
{
  "run_id": "RUN-TUNED-001", "base_run_id": "RUN-BASE-001",
  "commit_hash": "e3f19a0",
  "n_requests": 250, "n_groups": 41,
  "format": {"v1_valid": 0.984, "v2_invalid": 0.016},
  "core": {
    "v5": {"value": 0.742, "ci95": [0.701, 0.781]},
    "v10": {"value": 0.680, "ci95": [0.624, 0.735], "n": 238}
  },
  "comparison": {
    "v10_delta": 0.140, "v10_delta_ci95": [0.062, 0.218],
    "judgement": "improved"
  },
  "diagnostics": {"v3_f1": 0.812, "v4": 0.655, "v6": 0.840,
                  "v7": 0.125, "v8": 0.450, "v9": 0.082,
                  "v11": 0.810, "v12": 0.045},
  "excluded": {"direction_conflict": 12, "missing": 0}
}
```

`judgement`는 차이 구간의 하한이 0보다 크면 `improved`, 구간이 0을 포함하면 `not_confirmed`로 반환한다. Stack은 기획안 기준으로 FastAPI와 SQLite이며, 호환성을 확인한 뒤 Version을 고정한다.

10 일정과 완료 기준

아래 표는 명세서 §5.1의 4주 일정 중 백엔드 포지션이 맡는 작업과 완료 기준이다.

주차	백엔드 포지션의 작업	완료 기준
2주차	Track 1 출력 Schema를 확정하고, Invalid · Missing · U · Not applicable 처리를 반영한 자동 채점 Code를 구현한다.	데이터 포지션의 예외 예제가 예상대로 채점됨
3주차	Base 실행 결과를 저장하고 채점한다. 누수 검사를 통과한 Test를 고정한다.	Dev 기준 채점 결과, Test Version 고정
4주차	Base와 Tuned의 비교와 신뢰구간을 계산하고 Report API를 제공한다.	분모와 차이 구간을 포함한 비교 결과

11 자주 받을 질문

Q. 형식 오류가 난 응답을 분모에서 빼면 안 되는가?

A. 빼면 실패율이 낮게 집계되어 형식을 자주 깨는 모델이 유리해진다. 요청 목록은 실행 전에 고정하고, 형식 오류는 점수마다 정해진 방식으로 반영한다.

Q. 같은 Run ID로 다시 실행하면 같은 점수가 나오는가?

A. 저장된 예측을 다시 채점하면 같은 점수가 나와야 한다. 모델에 다시 질의하면 결과가 달라질 수 있으므로 설정을 기록하고 변동을 보고한다.

Q. Bootstrap을 문항이 아니라 Group 단위로 하는 이유는 무엇인가?

A. 같은 영상의 문항은 서로 비슷해서 독립 표본이 아니다. 문항 단위로 뽑으면 신뢰구간이 실제보다 좁게 나와 개선을 과대 판정하게 된다.

Q. V3를 Greedy로 구현하면 안 되는가?

A. Greedy는 짝의 수를 최대화하지 못할 수 있다. 명세는 짝의 수를 먼저 최대화하고, 같으면 IoU 합을 최대화하도록 정하고 있다.

명세서에서 함께 볼 곳

본 문서의 근거는 명세서 §3(평가 및 진단 체계), §4.2–4.3(분할과 실행 관리), App. A(세부 지표 정의), App. B.3(방향 충돌 장면의 처리)에 있다.

참고 문헌

[1] S. Xie et al. Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives. ICCV, 2025.

[2] NIST/SEMATECH. Confidence Limits for a Proportion. e-Handbook of Statistical Methods.

[3] R. Agarwal et al. Deep Reinforcement Learning at the Edge of the Statistical Precipice. NeurIPS, 2021.