포지션별 이해 자료: 프론트엔드 (Frontend · UI/UX)

국내 생활도로 VLM 평가 벤치마크 및 개발 명세서 기준 · 실전SW프로젝트 팀1

본 문서는 프론트엔드 포지션이 프로젝트를 이해하고 자기 파트의 배경, 설계 이유, 핵심 규칙을 설명할 수 있도록, 명세서에서 해당 포지션에 필요한 내용만 정리한다. 내용이 명세서와 다르면 명세서를 따른다.

1 프로젝트 한눈에 보기

본 프로젝트는 보도 없는 국내 생활도로의 전방 카메라 사진에서, VLM이 판단의 근거가 되는 Object를 찾고(①), 네 가지 위험 관계를 판정하고(②), 관계에 맞는 조건부 대응을 고르는지(③)를 단계마다 정답과 대조해 채점하는 Benchmark와, 이를 실행하고 결과를 확인하는 시스템을 만든다.

단계마다 채점하는 이유는 최종 답만으로는 모델이 장면을 보고 판단했는지 확인할 수 없기 때문이다. 기존 주행 VLM 평가에서는 사진을 넣지 않아도 점수가 비슷하거나 오히려 높게 나온 사례가 보고되었다 [1]. 따라서 본 Benchmark는 근거 Object, 관계 판정, 대응을 각각 사람이 작성한 정답과 대조한다.

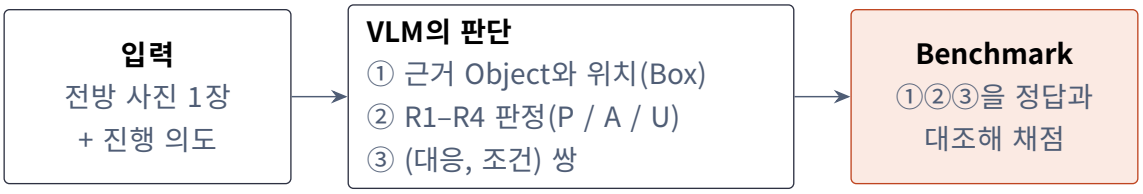


그림 1. 전체 구조. 정답을 기록하는 항목과 규칙이 Taxonomy이고, 채점 방법이 Metric이다.

평가는 세 Track으로 나누며, 첫 달에는 Track 1을 핵심 산출물로 완성한다. Track 2·3은 필요한 사건·시간·센서 정보의 검수 가능성을 확인한 뒤 핵심 일정에 영향을 주지 않는 범위에서 진행한다.

Track	무엇을 평가하는가	정답의 출처
Track 1 (Core) 현재 장면	사진 한 장에서 근거 Object, 위험 관계 R1–R4, 조건부 대응	사람이 입력만 보고 작성한 Annotation
Track 2 (Extension) 미래 사고	판단 시점까지의 영상으로 H 초 안에 자차와 충돌할 보행자	실제 사고 기록과 검수한 충돌 시점
Track 3 (Extension) 자차 움직임	관측 구간의 속도 변화와 회전 방향	영상과 동기화된 GNSS/INS 기록

1.1 공통 용어

아래 용어는 네 포지션이 같은 뜻으로 사용한다. 회의와 문서에서 다른 이름으로 바꾸어 부르지 않도록 통일한다.

용어	뜻
Driving Area (C)	진행 의도와 도로 구조만으로 정한 평가 영역(가상 주행 복도). 보행자나 장애물을 피해 그리지 않으며, 정답 작성과 채점에만 사용하고 모델에는 제공하지 않는다.
R1–R4	네 가지 위험 관계. R1 점유(C 안에 대상이 있는가), R2 출입구(C와 이어지는 출입구 주변에 보이는 Actor가 있는가), R3 시야 가림(필요한 영역이 가려졌는가), R4 통행 제한(통행 공간이 좁아졌는가).

용어	뜻
P / A / U	관계의 판정 값. P는 성립 근거가 있음, A는 충분히 확인했고 성립하지 않음, U는 입력만으로 판정할 수 없음을 의미한다. U는 모델의 자신감 부족이 아니라 정답의 하나다.
Actor / Obstacle	Actor는 보행자·이륜차·차량처럼 도로를 이용하는 주체, Obstacle은 스스로 움직이지 않는 장애물이다. 길가에 정렬되어 움직임의 근거가 없는 차량은 배치 속성을 Roadside Vehicle로 기록한다.
(대응, 조건) 쌍	대응은 단순 행동이 아니라 대응 Code와 조건 Code의 쌍으로 평가한다. 장면마다 필요(Required)·허용(Allowed)·금지(Forbidden) 대응을 정답으로 둔다.
Source Group	같은 영상·같은 촬영 구간에서 나온 자료의 묶음. 한 Group은 Train, Dev, Test 중 한 곳에만 배정한다.
Test freeze	모델 설정을 고르기 전에 Test의 입력·정답·채점 규칙을 고정하고, 마지막에 한 번만 채점하는 원칙.
V5 / V10	Track 1의 대표 점수. V5 Relation Macro-F1은 관계 판정, V10 Action Pass Rate는 대응 규칙 준수를 측정한다.

1.2 포지션 사이에서 주고받는 산출물

네 포지션은 아래 산출물로 연결된다. 자기 산출물의 형식이 바뀌면 그 산출물을 사용하는 포지션에 먼저 알린다.

산출물	작성	사용
Annotation Guideline, 정답(`references`), 장면 속성·근거(`annotations`)	데이터	AI 모델(학습), 백엔드(채점), 프론트엔드(정답 표시)
모델 출력(`predictions`), 실행 설정(`runs`)	AI 모델	백엔드(채점), 프론트엔드(예측 표시)
자동 채점 결과, Report API	백엔드	프론트엔드(화면), 팀 전체(비교 판단)
Web Viewer(F1–F5)	프론트엔드	모델 개발자, 운영·검증 담당자

2 프론트엔드 포지션의 역할

프론트엔드 포지션은 모델 개발자와 운영·검증 담당자가 "모델이 어디서, 왜 틀렸는가"를 찾을 수 있는 Web Viewer를 만든다. Viewer는 점수를 나열하는 화면이 아니라, 점수에서 실패 장면으로, 실패 장면에서 그 판단의 근거로 내려가는 흐름을 제공해야 한다.

모델의 출력 JSON을 그대로 보여 주면 사용자는 어떤 Object를 근거로 어떤 관계를 판정했고 그 관계에서 어떤 대응이 나왔는지 따라가기 어렵다. 따라서 Viewer는 정답과 예측을 구분해 보여 주고, 근거 Object → 관계 판정 → 대응의 연결을 시각적으로 따라갈 수 있게 한다. 산출물은 F1–F5 다섯 화면과 상태 화면이며, 데이터는 백엔드의 Report API와 정답·예측 파일에서 받는다.

3 사용자와 사용 시나리오

주 사용자는 자율주행 인지·판단 모델을 개발하는 엔지니어이고, 보조 사용자는 모델을 새 서비스 지역에 적용하기 전에 검증하는 운영·검증 담당자다.

시나리오	사용자와 계기	Viewer에서 하는 일	얻는 결과
1. 모델 버전 비교	개발자. 새 모델이나 추가 학습한 모델이 나왔다.	고정된 Test에서 Base와 새 모델을 실행하고 결과를 비교한다.	대표 점수, 분모, 차이의 신뢰구간으로 개선 여부를 판단한다.
2. 오류 원인 분석	개발자. 대표 점수가 기대보다 낮다.	진단 지표별로 실패 장면을 걸러 보고 장면 상세로 들어간다.	근거·관계·대응·설명 중 실패한 단계를 찾는다.
3. 조건별 취약점 확인	운영·검증 담당자. 적용 범위를 생활도로로 넓히기 전이다.	야간, 보도 없음, 일방통행 등 조건별 점수를 확인한다.	추가 검증이 필요한 조건을 정한다.

각 화면은 아래 사용자 스토리의 성공 기준을 충족해야 한다. 성공 기준은 모델 성능 목표가 아니라 기능의 구현 완료 여부를 판단하는 기준이다.

번호	사용자 스토리	우선순위	성공 기준
U1	모델을 고정된 Test에 실행하고 모든 결과를 저장하고 싶다.	Must	모든 요청의 응답과 실패 상태가 저장되고 V1·V2가 표시된다.
U2	두 모델의 대표 점수와 그 차이를 비교하고 싶다.	Must	V5·V10이 분모, 95% 신뢰구간과 함께 표시되고 차이의 구간과 개선 판정이 나온다.
U3	실패한 장면을 원인별로 모아 보고 싶다.	Must	진단 지표군별로 실패 장면을 걸러 볼 수 있고, 필요 대응 누락과 금지 대응을 구분해 보여 준다.
U4	한 장면에서 모델이 무엇을 근거로 판단했는지 보고 싶다.	Must	정답 Box와 예측 Box가 구분되어 표시되고, 근거 ID–관계–대응의 연결을 따라갈 수 있다.
U5	조건별 성능을 보고 싶다.	Must	조건별 점수가 분모, 신뢰구간과 함께 표시되고 분모가 작은 조건은 탐색적 결과로 표시된다.
U6	Track 2·3 결과도 같은 화면에서 보고 싶다.	Later	Track 1 완성 후 검수가 끝난 Track부터 추가한다.

4 화면 흐름

F1에서 평가를 실행하고 F2에서 결과를 요약해 본 뒤, F2에서 오류 목록(F3), 모델 비교(F4), 장면 상세(F5)로 이동한다. 각 화면은 하나의 질문에 답하도록 구성한다.

화면	답하는 질문	보여 주는 것
F1 평가 실행	어떤 모델과 Test Version으로 실행하는가?	모델·Test Version·입력 조건 선택, 진행률, 성공·실패 요청 수

화면	답하는 질문	보여 주는 것
F2 결과 Report	Base 대비 개선되었는가?	대표 점수와 신뢰구간, 차이 구간과 판정, 진단 지표군 요약, 조건별 점수
F3 오류 목록	어떤 장면에서 어떤 종류로 틀렸는가?	진단 지표군·관계·조건으로 걸러 낸 실패 장면과 실패 사유
F4 모델 비교	같은 장면에서 두 모델의 판단이 어떻게 다른가?	두 모델의 관계 판정과 대응을 나란히 비교
F5 장면 상세	이 판단의 근거는 무엇인가?	정답·예측 Box, C, 근거 ID–관계–대응의 연결, 정답의 출처와 검수 상태

5 정확히 표시해야 하는 개념

화면의 표기는 Benchmark의 판정 규칙과 같은 뜻이어야 한다. 아래 개념을 다르게 표시하면 사용자가 결과를 잘못 해석한다.

정답과 예측의 구분. 정답 Box와 C는 사람이 작성한 것이고, 예측 Box는 모델이 출력한 것이다. 두 Box는 선 모양과 범례로 구분하며, C는 정답 작성과 채점에만 쓰이고 모델에는 제공되지 않는다는 점을 범례에 명시한다.

P/A/U의 의미. P는 관계가 성립함, A는 충분히 확인했고 성립하지 않음, U는 입력만으로 판정할 수 없음을 의미한다. U는 오류나 빈칸이 아니라 정답의 하나이므로, 오류를 나타내는 색으로 표시하지 않는다.

빈 값의 구분. Invalid는 모델 출력의 형식 오류, Missing은 아직 검수하지 않은 정답, Not applicable은 해당 장면에 적용되지 않는 질문이다. 세 값은 서로 다른 표기로 보여 준다.

실패 사유. 장면이 대응 평가에서 실패한 사유는 형식 오류, 필요 대응 누락, 금지 대응, 등록되지 않은 대응, 관계 판정과의 모순 중 하나 이상이다. 사유는 색만으로 구분하지 않고 이름표를 함께 표시한다.

점수와 개선 판정. 모든 점수는 분모와 95% 신뢰구간을 함께 표시한다. 개선은 차이 구간의 하한이 0보다 클 때만 "개선"으로 표시하고, 구간이 0을 포함하면 "차이를 확인하지 못함"으로 표시한다. 분모가 작은 조건별 점수는 탐색적 결과임을 표시한다.

6 핵심 화면 Wireframe

아래 두 화면은 구성 요소의 배치를 정한 Wireframe이며, 수치는 형식을 보이기 위한 예시다. 색과 세부 스타일은 구현 단계에서 정한다.

7 받는 데이터와 상태 화면

화면에 필요한 데이터는 백엔드의 Report API와 장면별 정답·예측 파일에서 받는다. 데이터 형식은 2주차 Schema 확정 때 백엔드와 함께 고정한다.

F2는 Report API에서 대표 점수와 신뢰구간(`core`), 두 모델의 차이와 판정(`comparison`), 진단 점수(`diagnostics`), 제외 장면 수(`excluded`)를 받는다. F3–F5는 장면별 정답(`references`)과 모델 출력(`predictions`), 장면별 채점 결과(통과 여부, 실패 사유, Box 짝짓기 결과)를 받는다. 판정 문구는 API의 판정 값(`improved` 또는 `not_confirmed`)을 그대로 따르고, 화면에서 따로 계산하지 않는다.

상태 화면은 다섯 가지를 구분한다. 평가 전에는 F1로 이동하는 안내를, 실행 중에는 진행률과 남은 요청 수를, 실행 오류에는 실패한 요청 수와 재실행 기능을, 형식 오류로 채점할 수 없는 장면에는 Invalid 사유를, 필터 결과가 없을 때는 필터 초기화 기능을 보여 준다.

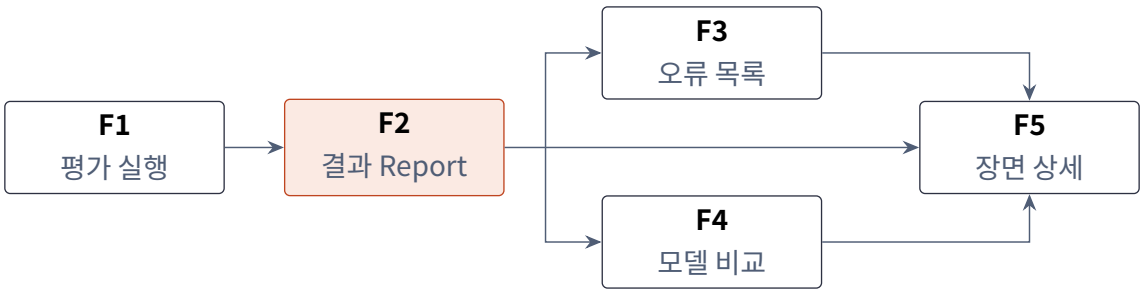


그림 2. 화면 흐름. F3·F4에서 장면을 고르면 F5로 이동한다.

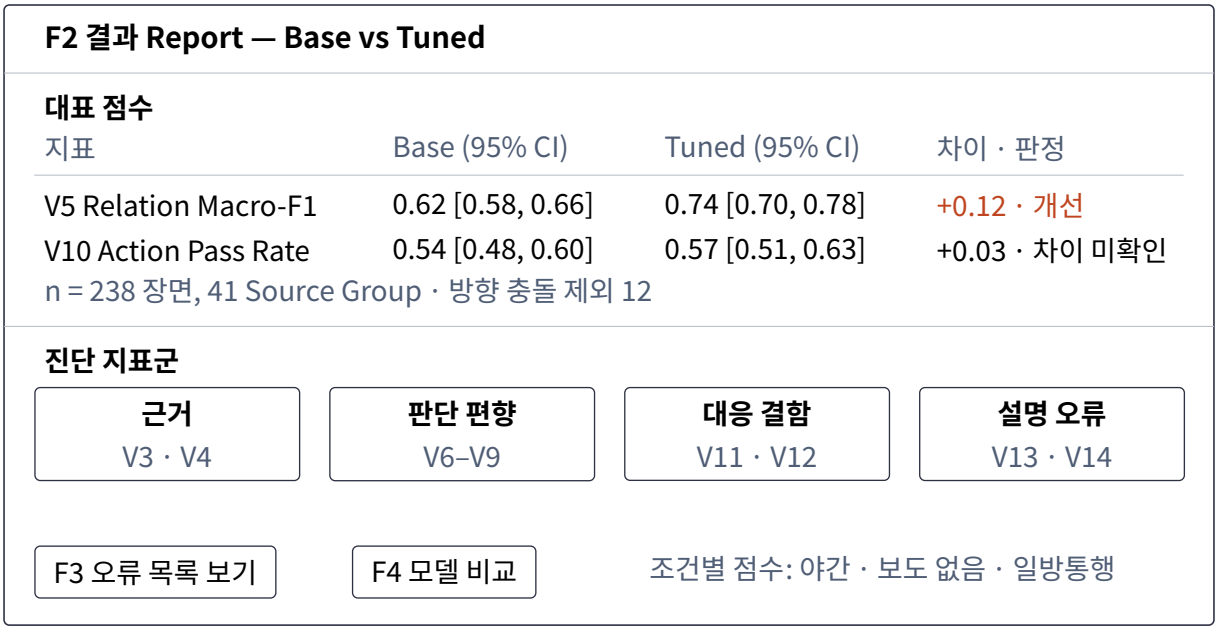


그림 3. F2 결과 Report. 개선 판정은 차이 구간의 하한이 0보다 클 때만 표시한다.

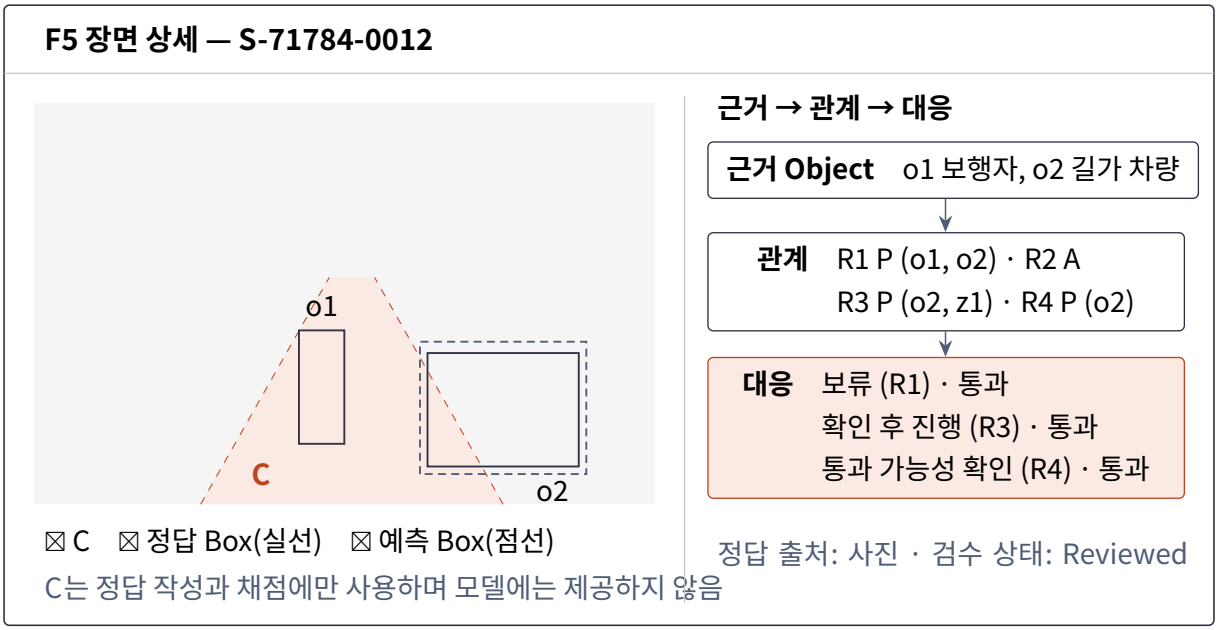


그림 4. F5 장면 상세. 왼쪽은 정답·예측 Box와 C, 오른쪽은 근거 ID에서 대응까지의 연결과 대응별 판정 결과다.

8 일정과 완료 기준

아래 표는 명세서 §5.1의 4주 일정 중 프론트엔드 포지션이 맡는 작업과 완료 기준이다.

주차	프론트엔드 포지션의 작업	완료 기준
2주차	백엔드와 함께 화면에 필요한 데이터 형식을 확정한다.	Report API와 장면별 결과의 필드 목록
3주차	확정된 형식의 예시 데이터로 F1–F5와 상태 화면을 구현한다.	예시 데이터로 모든 화면 이동이 동작함
4주차	실제 Base·Tuned 결과를 연결하여 Web Viewer를 완성한다.	정답·예측 Box와 근거–관계–대응 연결이 표시됨

명세서의 일정은 4주차 Web Viewer 완성을 목표로 하며, 2–3주차 작업은 그 목표를 위해 권장하는 순서다.

9 자주 받을 질문

Q. 모델 출력 JSON을 그대로 보여 주면 안 되는가?

A. JSON으로는 근거 Object와 관계, 대응의 연결을 따라가기 어렵다. 사용자가 실패 원인을 찾을 수 있도록 Box와 연결 구조로 보여 준다.

Q. U를 빨간색 같은 오류 색으로 표시하면 안 되는 이유는 무엇인가?

A. U는 입력에 정보가 없다는 정답이다. 오류 색으로 표시하면 사용자가 정답을 오류로 오해한다.

Q. Tuned 점수가 Base보다 높으면 "개선"으로 표시해도 되는가?

A. 차이 구간의 하한이 0보다 클 때만 "개선"으로 표시한다. 구간이 0을 포함하면 "차이를 확인하지 못함"으로 표시한다.

Q. C를 모델의 출력처럼 보여 줘도 되는가?

A. C는 사람이 작성한 정답이며 모델에는 제공되지 않는다. 정답 레이어로 표시하고 범례에 이를 명시한다.

명세서에서 함께 볼 곳

본 문서의 근거는 명세서 §1.4–1.5(사용자와 성공 기준), §3(평가 및 진단 체계), §4.4(결과 확인 화면의 흐름)에 있다.

참고 문헌

[1] S. Xie et al. Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives. ICCV, 2025.