국내 생활도로 VLM 평가 벤치마크 및 개발 명세서

실전SW프로젝트 팀1 · 카카오모빌리티 한국형 주행 VLM

1 개요 및 프로젝트 포지셔닝

본 문서는 국내 생활도로 전방 카메라 영상에 기반한 VLM의 공간 관계 이해 및 조건부 대응 능력을 정량 평가하는 Benchmark와, 이를 구현·운영하기 위한 개발 사항을 규정하는 명세서다. 핵심 구성은 세 가지다. 첫째, 모호한 "위험 상황"을 사진 위에서 검수할 수 있는 네 가지 공간 관계(R1–R4)와 조건부 대응으로 구체화하여 정답을 정의한다(§2). 둘째, 대표 점수 두 개로 모델 성능을 비교하고, 진단 점수로 오류 발생 단계를 분해한다(§3). 셋째, 데이터 분할과 실행 설정을 일관되게 관리하여 누수 위험을 줄이고 결과를 재확인할 수 있도록 한다(§4). 본문은 설계 논리와 구조를 기술하며, 상세 수식, Code 정의, 채점 절차는 부록에 명시한다.

1.1 배경: 객체 위치·궤적과 구분되는 생활도로 관계 해석

고속도로나 대로와 달리 국내 생활도로(골목길, 이면도로)에서는 보행자와 차량이 같은 노면을 함께 사용하고, 길가 주정차와 그로 인한 사각지대가 일상적이다. Detection과 Tracking은 객체의 위치와 궤적을 알려 준다. 그러나 그 배치가 자차의 진행 공간을 어떻게 제약하고 어디에 확인이 필요한 사각지대를 만드는지는 위치·궤적과 별도로 해석해야 하는 정보다. 과제 제공 기업과의 소통에서는 기업이 Frame 간 객체 Tracking을 활용하고 있으며, 시간 정보 모델링과 실험 관리 체계에도 관심이 있다는 점을 확인했다. 본 프로젝트는 Tracking 알고리즘 자체의 개발이 아니라, 생활도로에서 관측되는 객체 배치와 공간 관계, 그리고 이에 근거한 조건부 대응의 평가로 범위를 한정한다. 시간 정보를 사용하는 모델이 실패했을 때 공간 배치를 잘못 인지한 것인지 시간에 따른 변화를 잘못 예측한 것인지를 분리하여 진단할 수 있도록, 1단계로 단일 Frame 기반의 공간 관계 Grounding 평가 체계(Track 1)를 먼저 확립한다.

이 능력은 최종 답의 정답률만으로는 확인되지 않으므로, 판단의 중간 단계까지 별도로 평가해야 한다. 기존 주행 VLM 평가에서는 사진을 넣지 않아도 점수가 비슷하거나 오히려 높게 나온 사례가 보고되었다[1]. 최종 답만 채점하면 모델이 장면을 보고 맞혔는지 추측으로 맞혔는지 구별할 수 없으므로, 본 Benchmark는 근거 Object, 관계 판정, 대응을 각각 정답과 대조하도록 설계한다.

1.2 범위와 경계

구분	내용
In Scope	전방 카메라의 사진 한 장 또는 판단 시점까지의 Frame Sequence에 기반한 시각 추론을 평가한다. 도로 구조와 Object 배치에 따른 위험 공간 관계(R1–R4)를 판정하고, 관계에 근거한 조건부 대응(Action Code)을 검증한다. 추가 학습 전 모델(Base)과 후 모델(Tuned)의 차이를 신뢰구간으로 검정한다.
Out of Scope	차량의 저수준 제어값(가감속량, 조향각, 궤적 생성)은 평가 범위에서 제외하며, 공간 관계 해석과 대응 규칙의 일치도만을 평가 대상으로 한정한다. 사진 한 장에 기반한 물리적 충돌 확률의 예측도 범위에서 제외하며, 결과는 차량의 실제 안전성이 아니라 "본 문서가 정한 판단 규칙과의 일치도"로 한정하여 해석한다.

주 대상은 보도가 없는 구간으로 한정하되, 모델의 보도 유무 구분을 확인하기 위해 보도가 있는 비교 장면을 포함하고 별도로 기록한다.

1.3 3대 Track 구조와 단계적 실행 전략

평가는 세 Track으로 구분한다. 이는 같은 영상이라도 정답의 기준에 따라 평가하는 능력이 달라지는 데 기인한다. 세 점수를 합산하면 어느 능력이 개선되었는지 식별할 수 없으므로, 세 Track은 독립적으로 채점하고 별도로 보고한다. 한 달 안에 정답 정의부터 모델 비교까지 평가 흐름을 완성하기 위해 Track 1을 핵심 산출물로 지정한다. Track 2·3은 필요한 사건·시간·센서 정보의 검수 가능성을 확인한 뒤, 핵심 일정에 영향을 주지 않는 범위에서 진행한다.

Track	무엇을 평가하는가	정답의 출처
Core Track 1. Current Scene Understanding	사진 한 장으로 관측할 수 있는 근거 Object, 위험 관계 R1–R4, 조건부 대응. 첫 달의 1순위 산출물이다.	사람이 입력만 보고 정한 Annotation
Extension A Track 2. Future Event Prediction	판단 시점까지의 영상만 보고, 정해진 시간 안에 자차와 충돌할 보행자를 찾는가. AI Hub 597 사고 영상을 사용한다.	판단 시점 이후 실제로 일어난 사고 기록과 검수한 충돌 시점
Extension B Track 3. Ego Motion Perception	관측 구간에서 자차의 속도 변화와 회전 방향을 알아보는가. AI Hub 472 영상을 사용한다.	영상과 동기화된 GNSS/INS 기록

1.4 사용자와 사용 시나리오

본 Benchmark의 주 사용자는 자율주행 인지·판단 모델을 개발하는 엔지니어이고, 보조 사용자는 모델을 새 서비스 지역에 적용하기 전에 검증하는 운영·검증 담당자다. 대표 사용 시나리오는 다음 세 가지로 정의한다.

시나리오	사용자와 계기	Benchmark로 하는 일	얻는 결과
1. 모델 버전 비교	개발자. 새 모델 버전이나 추가 학습한 모델이 나왔다.	고정된 Test에서 Base와 새 모델을 같은 입력으로 실행한다.	대표 점수와 분모, 차이의 신뢰구간으로 개선 여부를 판단한다.
2. 오류 원인 분석	개발자. 대표 점수가 기대보다 낮다.	진단 지표와 오류 목록으로 실패한 장면을 단계별로 분류한다.	근거·관계·대응·설명 중 실패한 단계와, 보강할 데이터의 유형을 찾는다.
3. 조건별 취약점 확인	운영·검증 담당자. 적용 범위를 생활도로로 넓히기 전이다.	야간, 보도 없음, 일방통행처럼 조건별로 나눈 점수를 확인한다.	추가 검증이나 데이터 보강이 필요한 조건을 정한다. 분모가 작은 조건은 탐색적 결과로 취급한다.

1.5 사용자 스토리와 성공 기준

각 사용자 스토리의 성공 기준은 사용자가 본 Benchmark로 수행할 수 있어야 하는 일을 명시하며, 모델의 정량적 성능 목표치가 아니라 시스템 기능의 구현 및 인수 완료 여부(Acceptance Criteria)를 기준으로 정의한다. 팀의 주차별 구현 일정은 §5에 규정한다.

번호	사용자 스토리	우선순위	성공 기준
U1	개발자로서 모델을 고정된 Test에 실행하고 모든 결과를 저장하고 싶다.	Must	모든 평가 요청의 응답과 실패 상태(형식 오류, Timeout)가 빠짐없이 저장되고, V1·V2가 계산된다.
U2	개발자로서 두 모델의 대표 점수와 그 차이를 비교하고 싶다.	Must	V5·V10이 분모, 95% 신뢰구간과 함께 표시되고, 차이의 구간과 개선 판정 결과가 나온다.
U3	개발자로서 실패한 장면을 원인별로 모아 보고 싶다.	Must	진단 지표군별로 실패 장면을 걸러 볼 수 있고, 필요 대응의 누락과 금지 대응을 구분해 보여 준다.
U4	개발자로서 한 장면에서 모델이 무엇을 근거로 판단했는지 보고 싶다.	Must	정답 Box와 예측 Box가 구분되어 표시되고, 근거 ID–관계–대응의 연결을 따라갈 수 있다.
U5	운영·검증 담당자로서 조건별 성능을 보고 싶다.	Must	조건별 점수가 분모, 신뢰구간과 함께 표시되고, 분모가 작은 조건은 탐색적 결과로 표시된다.
U6	개발자로서 Track 2·3의 결과도 같은 화면에서 보고 싶다.	Later	Track 1을 완성한 뒤, 데이터 검수가 끝난 Track부터 추가한다.

2 Track 1 Core Taxonomy: 정답을 정의하는 기준

Track 1의 Taxonomy는 모호한 "위험 상황"을 사진 위에서 근거를 특정해 검수할 수 있는 공간 관계로 치환하여 정의한다. 모델은 제공된 입력으로부터 관측 근거를 식별하고, 이에 기반해 네 가지 관계(R1–R4)를 판정한 뒤, 관계별로 규정된 조건부 대응을 도출한다. 모든 관계는 Driving Area(C)를 기준으로 판정한다.

그림 1의 왼쪽은 사람이 장면마다 기록하는 **Scene Annotation**을 나타낸다. 이 중 **[출력]** 표시가 있는 항목은 모델이 예측하고 채점받으며, 회색 항목(시간대·조명·날씨 등)은 모델이 예측하지 않고 조건별로 결과를 나누어 볼 때만 쓰는 분석 전용 항목이다. 오른쪽은 모델의 판단 과정을 나타낸다. 본 장은 판단 과정의 핵심인 C, R1–R4, P/A/U, 조건부 대응을 규정하며, Scene Annotation의 전체 항목과 작성 기준은 App. E에 수록한다.

2.1 판단의 기준 영역: Driving Area (C)

C는 진행 의도와 도로 구조를 기준으로 정한 **평가 영역**으로 정의한다. Annotator는 보이는 도로 폭과 노면 경계, 도로가 이어지는 방향, 진행 의도 `follow_visible_road_forward`(보이는 도로를 따라 앞으로 진행하려 한다)만을 보고 사진 위에 다각형(Polygon)으로 그린다. 즉 C는 Object를 확인하기 전에 정하는 주행 가상 복도(Corridor)다.

C는 보행자나 장애물을 피해 실제로 지나갈 회피 경로와 구분하며, Object의 위치와 무관하게 도로 구조만으로 정한다. 보행자를 피하도록 C를 고쳐 그리면 그 보행자는 항상 C 밖에 있게 되어 "보행자가 진행 공간을 점유하는가"(R1)라는 질문이 무의미해지므로, 이를 방지하기 위함이다. C는 모델 입력에서 제외하며, 정답 작성과 채점 단계에서만 사용한다.

점유 여부는 대상의 **Footprint**, 즉 발·바퀴처럼 지면에 닿는 부분이 C와 겹치는지로 판정한다. 접지 부분이 가려지면 위치 판정이 불확실해진다. Box 아래쪽 가운데 점은 Footprint의 근사값으로 사용할 수 있으나, 그 경우에도 정답은 Footprint 기준으로 유지하며 근사값의 사용 여부는 Pilot에서 오차를 확인한 뒤 결정한다.

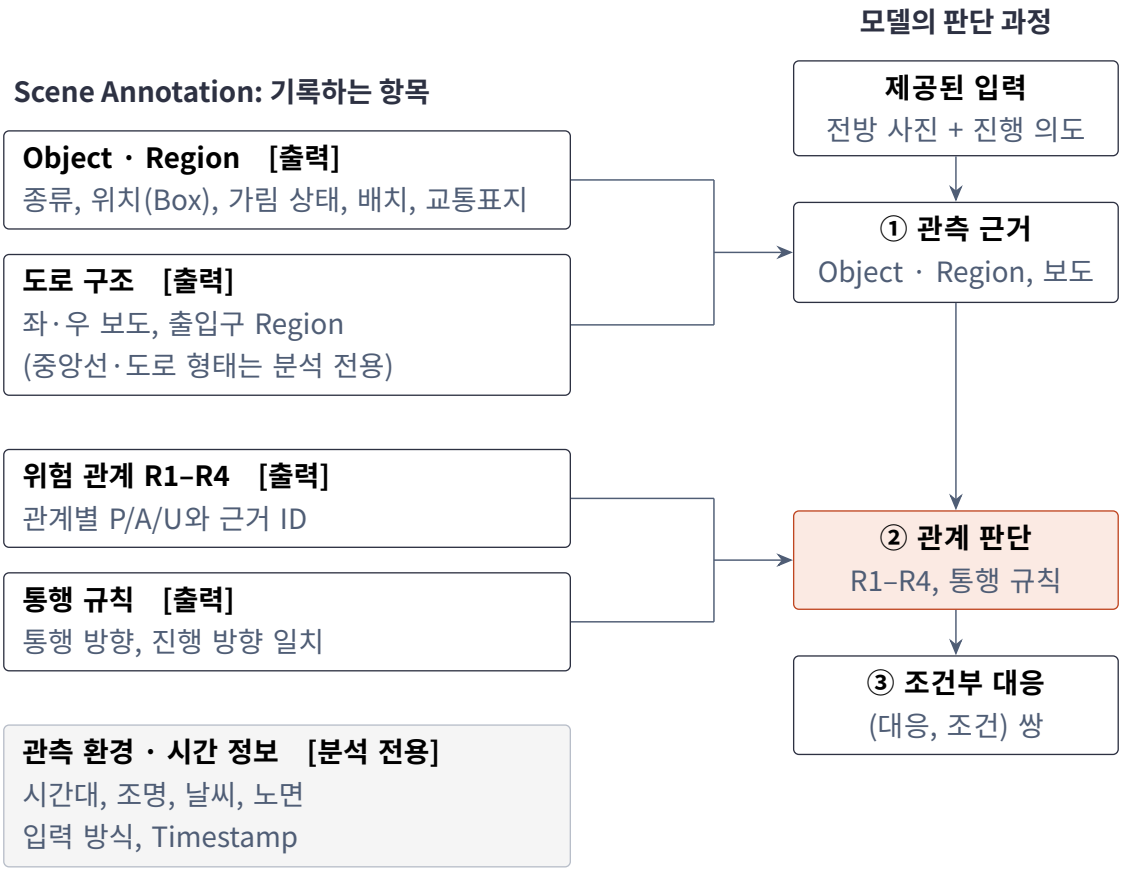


그림 1. Taxonomy의 두 구조. 왼쪽은 사람이 장면마다 기록하는 항목이며, [출력] 표시가 있는 항목만 모델이 예측하고 채점받는다. 회색 항목은 모델 출력에서 제외하고 Annotation과 조건별 성능 분석에만 사용한다. 오른쪽은 기록한 정답이 판단에 쓰이는 순서이며, ③의 정답은 ②의 정답으로부터 App. B의 규칙표로 작성한다.

2.2 판단을 결정짓는 네 가지 공간 관계 (R1–R4)

수십 가지 상황 이름을 나열하는 대신, 차량의 다음 행동을 직접 바꾸는 관계 네 가지로 압축하여 정의한다. 네 관계는 **사진 위에서 근거를 특정할 수 있고, 서로 다른 대응으로 이어진다**는 두 조건을 만족하도록 선정한다. 충돌 확률처럼 속도·거리·시간이 있어야 정할 수 있는 항목은 사진 한 장으로 검수할 수 없으므로 제외한다. 각 관계에는 대상의 ID와 판정 근거를 함께 기록한다.

관계	판정 질문	판정 기준
R1 점유 (Occupancy)	보이는 Actor 또는 Obstacle이 C를 점유하는가?	Footprint가 C와 명확히 겹치면 점유로 판정한다. 경계 오차에 따라 판단이 달라지면 U로 판정한다.
R2 출입구	C와 이어지는 골목·건물 출입구 주변에 보이는 Actor가 있는가?	Footprint가 출입구 Region 안에 있거나 경계에 닿으면 "주변"으로 판정한다. 현재 위치만 판정하며, 진입 여부의 예측은 대상에서 제외한다.
R3 시야 가림 (Occlusion)	진행 판단에 필요한 영역이 Object에 가려져 있는가?	가리는 Object와 가려진 Region을 함께 기록한다. 가려진 곳의 실제 Actor 존재 여부는 R3가 아니라 별도 주장으로 기록한다.

관계	판정 질문	판정 기준
R4 통행 제한 (Bottleneck)	길가 적치물이나 주차 차량 등의 배치가 C 구간의 통행 공간을 제한하는가?	정확한 폭을 측정하지 않고 제약의 유무만 판정한다. 실제 통과 가능성은 대응에서 다룬다.

R1과 R4는 동시에 P로 판정될 수 있다. 이는 R1이 진행 공간의 점유를, R4가 통행 공간의 축소를 각각 판정하는 데 기인한다. 특히 Obstacle이나 길가 차량의 Footprint가 C와 겹치면 그 대상이 통행 공간도 좁히므로, 같은 대상을 근거로 R4도 P로 판정한다. 반대로 R4=P가 통과 불가를 의미하지는 않으며, 통과 가능성을 확인하는 대응을 요구하는 근거로 사용한다.

R2는 숨은 Actor의 존재 여부가 아니라, 입력에서 보이는 Actor와 출입구 Region 사이의 위치 관계를 평가 대상으로 한다. 따라서 출입구의 일부가 가려져 있어도, 보이는 Actor 중 출입구 주변에 있는 대상이 없으면 R2는 A다. 완전히 가려진 Actor가 있을 가능성은 R3와 별도의 미확인 주장으로 분리하여 기록하고, R2는 보이는 Actor만으로 판정한다. 다만 보이는 Actor의 접지 위치나 출입구의 경계가 불명확해 관계를 판정할 수 없으면 U로 기록한다. 즉 "보이는 Actor와 출입구의 관계를 판정할 수 없음"은 R2의 U로, "가림 뒤 Actor의 존재를 알 수 없음"은 별도의 미확인 주장으로, "가림이 있음"은 R3의 P로 구분하여 기록한다.

2.3 3치 판정 원칙: Present / Absent / Unknown

각 관계는 다음 세 값 중 하나로 판정한다. **P**(Present)는 그 관계가 성립한다는 시각적 근거가 입력에 존재함을 의미한다. **A**(Absent)는 그 관계가 묻는 대상, 즉 보이는 Object와 관련 Region을 충분히 확인할 수 있어 관계가 **없다고** 판정할 수 있음을 의미한다. **U**(Unknown)는 입력의 정보만으로는 있다고도 없다고도 판정할 수 없음을 의미한다. U는 모델의 확신도 부족이 아니라 '제공된 입력 정보만으로는 판정 불가'를 의미하며, 사람이 입력만 보고 작성한 Annotation의 유효한 정답 중 하나로 채점한다.

보이는 것과 숨은 것의 분리 규칙. "가림 뒤에 사람이 있을 것 같다"는 추측은 정답에서 배제하고, 다음과 같이 분리하여 기록한다. 가림 자체는 R3=**P**로 기록해 확인 대응을 요구하고, R1·R2는 남은 **보이는** 대상만으로 판정하며, "가림 뒤 Actor 존재"라는 별도 주장은 **U**로 기록한다. 보이지 않는 대상에 대한 단정은 Object·근거 대조(V3, V4)와 진술 검수(V13, V14)에서 확인하며, 그 단정이 관계 Label까지 바꾼 경우에는 관계 점수에도 반영된다.

장면 단위 판정 규칙. 관련 대상이 여럿이면, 관계를 만족하는 대상이 하나라도 명확할 때 **P**, 명확한 **P**가 없고 판정이 풀리지 않은 대상이 남아 있을 때 **U**, 관련 대상을 모두 확인했고 모두 해당하지 않을 때 **A**로 정한다.

정답을 기록할 수 없는 경우는 U와 구분해 기록한다. **Missing**은 아직 작성하거나 검수하지 않은 항목으로 정의하며, 학습과 채점에서 제외하고 작성·검수가 끝난 뒤 반영한다. **Not applicable**은 그 장면에 해당하지 않는 질문으로 정의하며, 분모에서 제외한다(App. E.2).

2.4 근거 기반 조건부 대응 체계

모델의 대응은 단순한 행동이 아니라 **대응**과 **조건**의 쌍으로 평가한다. 이는 같은 "확인 후 진행"이라도 적용 상황이 다르면 다른 답으로 간주하기 위함이다. 예를 들어 "가려진 영역에 들어서기 전에 확인 후 진행"이라는 쌍은 R3=P일 때만 근거가 있다. 대응은 일곱 가지, 조건은 여섯 가지 Code로 규정하며, 각 조건 Code는 특정 관계의 정답이 있어야만 사용할 수 있으므로 "이 조건을 붙일 근거가 입력에 있는가"를 자동으로 검사할 수 있다.

정답에는 장면마다 세 집합을 미리 적는다. **필요 대응 묶음**(Required Group)은 반드시 충족해야 하는 요구사항이며, 한 요구사항을 충족하는 허용 대안이 여럿이면 그중 하나만 답해도 된다. **허용 대응**(Allowed)은 그 장면의 근거로 정당화되는 모든 쌍이고, **금지 대응**(Forbidden)은 근거와 충돌하는

쌍이다. 허용에도 금지에도 없는 쌍을 답하면 근거가 확인되지 않은 대응(Unsupported Pair)으로 분류하여 해당 장면을 실패로 처리한다. 여러 관계가 함께 성립하면 각 관계의 필요 대응 묶음을 모두 요구한다. 관계별 대표 대응은 다음과 같이 정의한다.

관계 정답	대표 필요 대응
R1 = **P** (움직일 수 있는 Actor의 점유)	점유가 유지되는 동안 양보 또는 진입 보류
R2 = **P**	출입구 주변에 Actor가 있는 동안 전방 관찰 또는 감속
R3 = **P**	가려진 영역에 들어서기 전에 확인 후 진행
R4 = **P** 또는 **U**	좁아진 구간을 지나기 전에 통과 가능성 확인
R1 · R2 · R3 중 **U**	판단할 수 없는 부분을 확인한 뒤 진행
R1–R4 모두 **A**	전방을 관찰하며 진행

대응 Code 7종과 조건 Code 6종의 전체 정의와 조합 규칙은 App. B.1에 수록한다.

대응은 대상이 비켜 줄 수 있는지에 따라 달라지므로 Object를 다음과 같이 구분한다. **Actor**는 보행자 · 자전거 · 이륜차 · 차량처럼 도로를 이용하는 주체로, **Obstacle**은 콘 · 적치물 · 공사 시설물처럼 스스로 움직이지 않는 장애물로 정의한다. 차량은 정차 여부와 관계없이 Actor로 분류한다. 이는 사진 한 장으로는 정차 여부를 확인할 수 없고, 정차한 차량도 다시 움직일 수 있다는 점에 기인한다. 다만 도로 가장자리에 정렬되어 있고 움직임의 근거가 보이지 않는 차량은 배치 속성을 **Roadside Vehicle**로 기록한다. Obstacle이나 Roadside Vehicle에 "해소될 때까지 보류"를 필수로 요구하면 영원히 진행할 수 없는 정답이 되므로, 이 대상이 C를 점유한 경우에는 같은 대상으로 성립하는 R4의 통과 가능성 확인을 필수로 두고, 보류는 허용으로 남긴다.

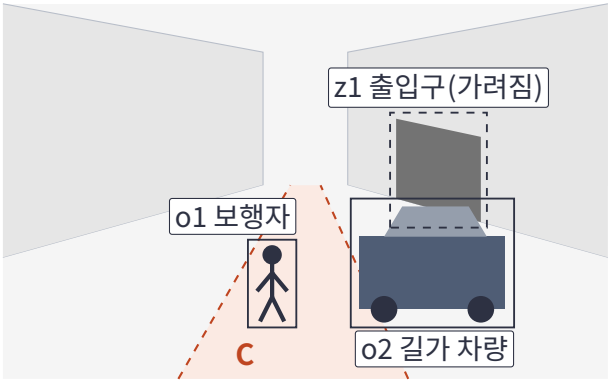
U에 확인 후 진행을 요구하는 것은, U를 위험이 있다고 단정하지도 없다고 무시하지도 않고 "판단할 수 없는 부분을 확인하라"고 요구하는 것이 입력으로 정당화되는 유일한 대응이라는 판단에 근거한다. 위험 요인이 없는 장면(R1–R4 모두 A)도 평가 데이터에 의도적으로 포함한다. 이는 모든 장면에 "정지하라"고 답하는 과도하게 보수적인 모델을 걸러내기 위함이다. 대응은 사진에서 판정한 R1–R4로만 정한다. 통행 방향이 Unknown이거나 야간이라는 사실은 대응 규칙에 반영하지 않고, 진술 검수와 조건별 분석에서 다룬다. 일방통행을 거꾸로 가는 장면은 맞는 대응이 존재하지 않으므로 대응 평가에서 제외한다. 전체 Code, 상세 대응표, 방향 충돌 장면의 처리는 App. B에 수록한다.

2.5 종합 설명 예시

그림 2은 위 규칙을 한 장면에 적용한 예시로, 실제 데이터가 아니라 설명을 위해 구성한 장면이다. 이면도로에서 보행자 o1이 C 안에 서 있고, 길가 차량 o2가 건물 출입구 z1을 가리며, o2의 바퀴도 C와 겹친다. o2는 도로 가장자리에 정렬되어 있고 움직임의 근거가 보이지 않으므로 Roadside Vehicle로 기록한다. 출입구 주변에는 보이는 Actor가 없고, 판독할 수 있는 통행 표지도 없다.

1. **관측 근거.** o1, o2의 Box와 출입구 z1의 Region을 찾고, 각 Footprint를 C와 대조한다. 보행자만이 아니라 차량까지 확인하므로 R1 = P이고 근거는 o1, o2다.
2. **관계.** o2가 z1을 가리므로 R3 = P(근거 o2, z1), o2가 통행 공간을 좁히므로 R4 = P(근거 o2)다. 출입구 주변에 보이는 Actor가 없으므로 R2 = A다.
3. **대응.** 필요 대응 묶음은 세 개다. 움직일 수 있는 Actor인 o1의 점유에는 양보 또는 보류, z1의 가림에는 확인 후 진행, o2로 좁아진 구간에는 통과 가능성 확인을 요구한다. o2의 점유는 Roadside Vehicle이므로 R4의 통과 가능성 확인으로 처리한다. 셋 중 하나라도 빠지면 V10에서 실패한다.

이 장면에 대한 모델 출력 예시(JSON)는 App. B.4에 수록한다.



관계 판정

R1 P o1과 o2의 Footprint가 C와 겹친다.

R2 A z1 주변에 보이는 Actor가 없다.

R3 P o2가 z1의 시야를 가린다.

R4 P o2가 이 구간의 통행 공간을 좁힌다.

모델이 출력하는 장면 속성	Sidewalk 좌·우 = **A** · **A**, Traffic Direction = **Unknown**(판독 가능한 표지 없음), Direction Match = **Unknown**
확인되지 않은 사항	가림 뒤 Actor의 존재, o2 옆의 실제 통과 가능성
필요한 대응	o1에 대한 양보 또는 보류, z1 앞에서 확인 후 진행, o2 옆 통과 가능성 확인

그림 2. 예시 장면과 정답(설명용). 그림의 Box와 C는 사람이 그린 정답이며, 모델에는 사진만 주어지고 모델은 자신의 Box를 별도로 출력한다. 확인되지 않은 사항은 R1·R3·R4의 P 판정에 영향을 주지 않는다.

3 평가 및 진단 체계 (Benchmark Metrics)

Track 1의 성능은 **Relation Macro-F1**(V5)과 **Action Pass Rate**(V10)를 대표 점수로 비교한다. 진단 점수는 대상 검출, 관계 판단, 대응, 설명 중 어느 단계에서 오류가 생겼는지 분석하는 데 사용한다. 모든 점수에는 분모와 95% 신뢰구간을 붙이고, Base 대비 Tuned의 개선은 같은 표본에서 구한 차이의 신뢰구간이 0보다 위일 때만 인정한다.

3.1 대표 점수 두 개

① **V5 Relation Macro-F1**은 관계 판정의 정확도를 측정한다. 네 관계와 세 상태(P/A/U)의 조합 12칸마다 F1을 구하고, 12칸을 똑같은 비중으로 평균한다. 단순 정확도 대신 이 평균을 채택하는 것은 클래스 불균형에 대응하기 위함이다. 특정 관계에서 Absent가 다수를 차지하면, 항상 Absent만 답하는 모델도 높은 정확도를 얻을 수 있다. 칸별로 평균하면 이런 모델은 P와 U 칸의 F1이 0이 되어 점수가 낮아진다. V5는 12칸 모두에 검수된 정답이 있을 때만 대표 점수로 보고한다.

② **V10 Action Pass Rate**는 대응 규칙을 지킨 장면의 비율로 정의한다. 통과 여부는 장면 단위로 판정한다. 한 장면은 형식이 맞고, 사전에 정의된 필요 대응 묶음을 모두 충족하며, 금지된 대응이나 근거가 확인되지 않은 대응을 하지 않고, 모델 자신의 관계 판정과 모순되지 않는 대응을 제시했을 때만 통과로 판정한다. 예를 들어 모델이 R3=A라고 출력하면서 가림을 근거로 대응하면, 정답 R3가 P라도 답안에서 모순되므로 실패다. V10은 관계 판정과 대응 조건의 일관성을 평가하며, 실제 Object·Region의 위치와 근거 연결의 정확성은 V3·V4로 별도 보고한다. 이렇게 나누면 대응이 틀린 원인이 근거를 잘못 찾은 데 있는지, 규칙을 잘못 적용한 데 있는지 구분할 수 있다. V10은 본 문서가 정한 대응 규칙과의 일치도로 정의하며, 차량 제어의 안전성이 아니라 규칙 준수 여부를 나타내는 점수로 해석한다.

모델 수준의 판정은 별도의 합격 기준점 없이, 대표 점수의 비교와 개선 여부로 한정한다. V5와 V10의 식과 분모 규칙은 App. A.1에 명시한다. Track 2의 대표 점수는 잔여 시간 구간별 대상 예측 정확도(TargetAcc), Track 3의 대표 점수는 속도 변화와 회전 방향을 함께 맞힌 비율(Joint Accuracy)이며, 정의는 App. D에 명시한다.

3.2 실패 원인 규명을 위한 네 가지 진단 지표군

대표 점수가 낮을 때 개선 지점을 특정할 수 있도록, 실패를 네 종류로 분해하여 측정한다.

진단 지표군	점수	답하는 질문
1. 근거 정합성	V3 Object F1 V4 Evidence ID Match	모델이 찾은 Box가 정답 Box와 같은 대상인가(IoU ≥ 0.5 일대일 짝짓기). 관계는 맞혔지만 엉뚱한 Object를 근거로 짚지 않았는가(Grounding Failure).
2. 판단 편향	V6 Recall for Present V7 False Positive Rate V8 Recall for Unknown V9 Over-abstention	있는 위험을 놓치는가(V6), 없는 위험을 있다고 하는가(V7), 판단할 수 없는 것을 단정하는가(V8), 판단할 수 있는데 "모름(U)"으로 피하는가(V9).
3. 대응 결함	V11 Required Action Coverage V12 Forbidden Action Rate	해야 할 대응을 빠뜨렸는가(V11), 하면 안 되는 대응을 했는가(V12). 둘을 함께 보면 V10이 낮은 원인이 누락인지 부적절한 대응인지 가를 수 있다.
4. 설명문 환각	V13 Statement Error Rate V14 Response Error Rate	모델의 설명을 참·거짓을 확인할 수 있는 최소 진술로 나누었을 때, 근거 없이 단정한 진술의 비율(V13)과 그런 진술이 하나라도 있는 답의 비율(V14).

이 밖에 출력이 채점할 수 있는 형식인지(V1, V2)와, 보도 유무·통행 방향 같은 장면 속성을 맞혔는지(A1, A2)를 함께 보고한다. 장면 속성은 V5와 분리하여 A1, A2로 별도 채점한다. 이는 관계 판정과 속성 판정의 성능이 한 숫자에 섞여 변화의 원인을 식별할 수 없게 되는 것을 방지하기 위함이다. 모든 점수의 식과 분모 규칙은 App. A에 명시한다.

3.3 신뢰구간 및 통계적 개선 판정 기준

점수는 장면 수가 적을수록 우연에 의한 변동이 커진다. 예를 들어 50장면 중 40장면을 맞힌 80%의 Wilson 95% 신뢰구간은 약 67.0%–88.8%로, 위아래로 10%p 안팎의 불확실성이 남는다[5]. 따라서 모든 점수에 분모와 95% 신뢰구간을 병기한다.

Base 대비 Tuned의 개선은 단순 점수 상승이 아니라 차이의 신뢰구간으로 판정한다. 두 모델은 동일 표본에서 비교하며, 점수 차이의 불확실성은 Source Group 단위로 표본을 재추출하는 Paired Bootstrap으로 산출한다[4]. Group 단위로 재추출하는 것은, 같은 영상에서 나온 문항들이 서로 유사하여 문항을 독립 표본처럼 세면 불확실성이 실제보다 작게 계산되는 것을 방지하기 위함이다. 차이의 95% 구간 하한이 0보다 클 때만 "개선"으로 판정하고, 구간이 0을 포함하면 "차이를 확인하지 못함"으로 기록한다. 판정은 Track마다 대표 점수로 따로 하며, 각 Track의 개선은 해당 Track의 결과로만 보고한다. 반복 횟수와 백분위수 계산 등의 절차는 App. A.10에 명시한다.

정답 자체의 품질로서, 두 Annotator가 서로 보지 않고 기록한 결과의 일치율(L1)과 Cohen's κ(L2), 관계·상태별 표본 수와 Source Group 수(L3)를 함께 보고한다. 이는 정답이 불안정한 항목에서는 모델 점수의 차이도 해석하기 어렵다는 점에 기인한다.

4 데이터·실행 체계와 시스템 구성

모델 비교 결과를 해석하고 다시 확인할 수 있도록, 데이터 분할·Test 고정·실행 설정·예측 결과를 일관되게 관리한다. 본 장은 데이터와 실행의 관리 구조, 결과 확인 화면의 흐름, 모델과 기술 스펙의 결정 상태를 규정한다.

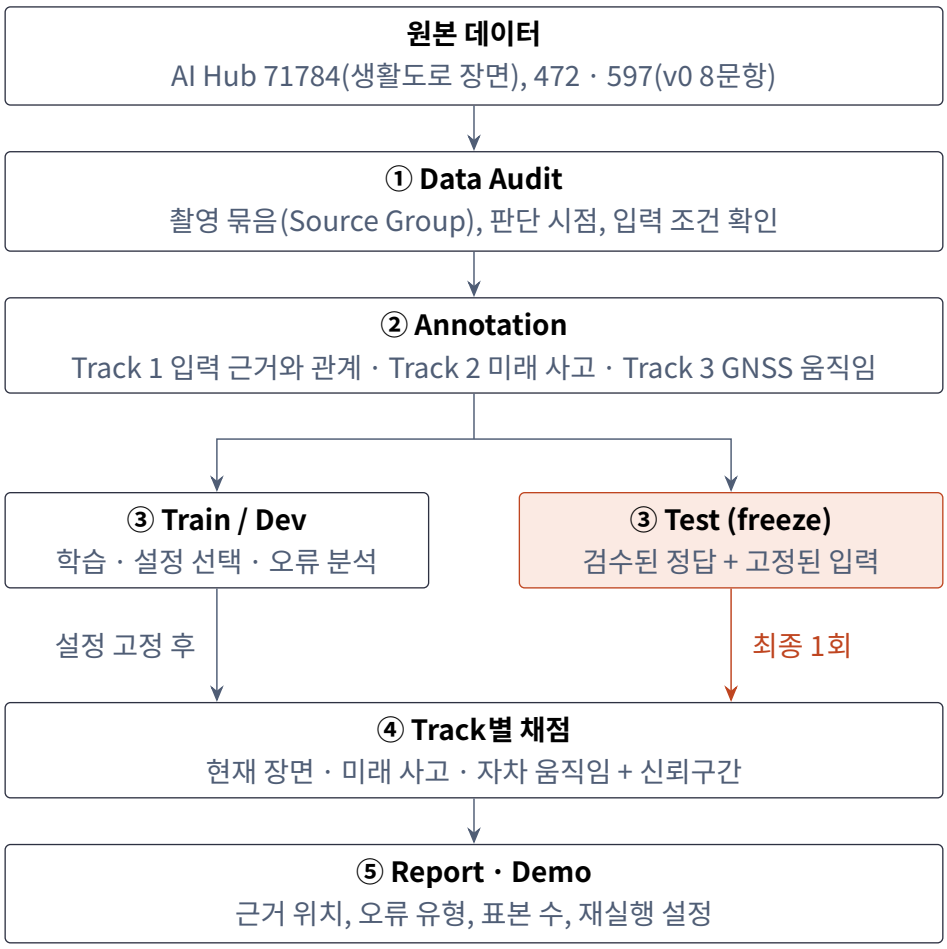


그림 3. 전체 흐름. 모델과 규칙은 Train·Dev만 보고 조정하고, Test는 모든 설정을 고정한 뒤 마지막에 한 번 채점한다.

4.1 데이터 소스와 대상 장면

주 데이터는 AI Hub 71784 "생활도로 객체인식 자율주행 데이터"[9]이며, 여기서 보도 없는 이면도로 장면과 비교용 보도 있는 장면을 선정하여 본 문서의 공통 Label을 새로 부여한다. 팀이 먼저 만든 Pilot Benchmark(이하 **v0**, 8문항)는 AI Hub 472 "융합센서 다중객체 추적 및 예측 데이터"[7]와 597 "교통사고 영상 데이터"[8]를 바탕으로 했으며, Pilot 결과와 Track 2·3의 시작 자료로 사용한다.

4.2 Data Leakage 위험을 줄이는 Source Group 분할

도로 영상에서는 같은 영상의 연속 Frame끼리 배경이 거의 동일하다. 같은 영상의 Frame이 학습용과 시험용에 나뉘면 익숙한 배경의 재인식이 성능 향상처럼 나타나므로, 이러한 누수 위험을 줄이기 위해 Frame 단위 무작위 분할을 금지하고, 같은 영상·같은 촬영 구간·사실상 같은 장면에서 나온 자료를 하나의 **Source Group**으로 묶어 Train, Dev, Test 중 한 곳에만 배정한다. 원본 ID가 달라도 같은 촬영으로 확인되면 하나의 Group으로 합친다.

Dev에서 관측한 오류는 Prompt와 학습 개선에만 사용하고, Test의 입력·정답·채점 규칙은 최종 비교 전에 Version으로 고정한다. Data Audit에서 작성한 Scene 목록과 입력 명세는 판단 시점 이후 Frame의 입력 혼입과 동일 Group의 Split 간 분산 여부를 자동 검사하는 데 사용한다. 같은 Group의 여러 문항은 서로 유사하므로, 표본 수와 함께 Source Group 수를 별도로 집계한다. 이 원칙과 자동 검사는 Source Group 중복과 미래 Frame 유입을 검사해 누수 위험을 줄이는 장치이며, 검사 범위 밖의 누수 가능성은 Report에 한계로 명시한다. Guideline 개정에 사용한 Pilot 장면은 규칙 조정 과정에서 반복 검토한 자료이므로 Train/Dev에 배정하고 Test에서 제외한다.

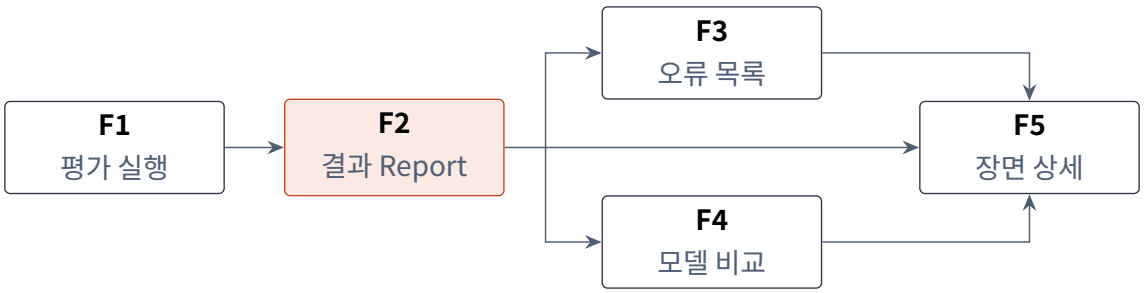


그림 4. 화면 흐름. F2에서 F3·F4·F5로 이동하고, F3·F4에서 장면을 고르면 F5로 이동한다.

4.3 재현성 중심의 MLOps 관리 구조

복잡한 플랫폼을 구축하는 대신, 저장 위치를 모델의 접근 가능 여부에 따라 분리하고 실행 식별자(Run ID)로 연결한다.

저장 위치	담는 내용
`items`	모델 입력과 질문. 실행 전에 고정한다.
`annotations`	장면 속성, 근거, 작성·검수 상태. 모델 입력과 분리하여 정답 작성과 분석에만 사용한다.
`references`	검수가 끝난 Task별 정답과 대응 규칙. Test 분은 고정한다.
`predictions`	모델의 원래 출력. 형식 오류와 Timeout도 지우지 않고 보존한다.
`runs`	사용한 Prompt, 모델 Checkpoint, 디코딩 설정, Seed, 실행 환경, 데이터·Label·Split Version, 채점 Code의 Git Commit Hash

Run ID는 한 번의 실행을 가리키는 식별자로, Hash는 파일 내용의 변경 여부를 확인하는 값으로 정의한다. 재채점과 재추론은 구분하여 관리한다. 같은 예측 결과를 같은 채점 Code와 정답 Version으로 다시 채점하면 같은 점수가 나와야 한다. 반면 생성형 모델에 다시 질의하는 재추론은 설정과 실행 환경에 따라 결과가 달라질 수 있으므로, 모델·Prompt·디코딩 설정·Seed·실행 환경을 기록하고 결과가 달라지면 실행 간 변동을 확인한다. 정답이나 규칙이 바뀌면 새 Version으로 기록한다. 평가 요청 목록도 실행 전에 고정하고, 실패한 요청은 결과에 실패 상태로 남겨 집계한다. 정상 응답만 남기면 실패율이 실제보다 낮게 집계되는 것을 방지하기 위함이다.

4.4 결과 확인 화면의 흐름

결과 확인용 Web Viewer는 사용자 스토리 U1–U5(§ 1.5)를 다섯 화면으로 구현한다. F1에서 평가를 실행하고 F2에서 결과를 요약해 본 뒤, F2에서 오류 목록(F3), 모델 비교(F4), 장면 상세(F5)로 이동한다.

화면	보여 주는 것	스토리
F1 평가 실행	모델, Test Version, 입력 조건을 고르고 실행한다. 진행률과 성공·실패 요청 수를 보여 준다.	U1
F2 결과 Report	대표 점수와 신뢰구간, 진단 지표군 요약, 조건별 점수, 두 모델의 차이 구간	U2, U5
F3 오류 목록	진단 지표군·관계·조건으로 걸러 낸 실패 장면과 오류 유형. 형식 오류와 Timeout은 별도 상태로 표시한다.	U3
F4 모델 비교	같은 장면에서 두 모델의 관계 판정과 대응을 나란히 비교한다.	U2
F5 장면 상세	정답 Box와 예측 Box, 근거 ID–관계–대응의 연결, 정답의 출처와 검수 상태	U4

4.5 모델과 기술 스펙의 결정 상태

모델 부분은 확정 사항, 선정 기준, 확인 예정 사항으로 구분하여 관리한다. 모델명이나 학습 방식이 변경되어도 평가 체계를 그대로 사용할 수 있도록 입력과 출력 형식을 먼저 고정한다.

구분	내용
확정	기본 모델은 Google의 Gemma 4 계열(Apache 2.0)로 한다[6]. 같은 입력 조건에서 Base와 Tuned를 비교한다. 추가 학습에는 Train만 사용하고, 설정 선택에는 Dev만 사용한다. 모든 모델의 출력 Schema를 통일한다.
추론 Interface	입력은 Track 1에서 사진 한 장과 진행 의도, Track 2·3에서 판단 시점까지의 Frame이다. 출력은 Object·Region Box(정규화 좌표), 장면 속성, R1–R4 판정과 근거 ID, (대응, 조건) 쌍, 설명 문장을 담은 JSON이다. 형식이 맞지 않는 출력도 원본을 저장한다.
선정 기준과 확인 결과	이미지와 Frame Sequence 입력 지원, Box 출력 가능성, 한국어 설명 품질, 라이선스와 이용 조건, 확보한 GPU에서의 학습·추론 가능성을 기준으로 한다. Gemma 4는 모든 크기가 이미지와 Video 입력을 지원하고, Object Detection 결과를 1000×1000 기준의 상대 좌표 Box(`box_2d`)로 출력하는 사례가 공개되어 있다[6]. 이 좌표는 본 문서의 정규화 좌표 $[x_1, y_1, x_2, y_2]$로 변환하여 채점하며, 변환 규칙은 1주차 Pilot에서 확인한다. 한국어 설명 품질은 Pilot에서 확인한다.
확인 예정	모델 크기(Gemma 4의 E2B·E4B·12B·26B A4B·31B 중에서 GPU 메모리와 장면당 처리 시간을 실측한 뒤 결정), 학습 방식(LoRA 또는 QLoRA, Transformers 통합을 통한 PEFT·TRL 사용), Frame Sequence 입력 성능. Gemma 4는 Video에 대해 별도의 사후 학습을 거치지 않은 것으로 공개되어 있으므로[6], Track 2·3의 입력 성능은 Pilot에서 확인한다.
학습 자원·Stack	VRAM 48GB GPU를 사용할 수 있다고 가정한다. 가중치 메모리만 산술로 추정하면 bf16 기준으로 E4B(Embedding 포함 약 8B)는 약 16GB, 12B는 약 24GB로 LoRA 학습 후보가 되고, 26B A4B(약 52GB)와 31B(약 62GB)는 가중치만으로 48GB를 넘으므로 4-bit 양자화(QLoRA)를 전제로 한다. Activation과 Optimizer 메모리는 1주차에 실측하여 크기를 확정한다. 기획안 기준으로 학습은 PyTorch·Transformers·PEFT, 서빙은 vLLM 우선, Viewer는 FastAPI·React·SQLite이며, 호환성을 확인한 뒤 Version을 고정한다.
데이터 이용 조건	AI Hub 데이터의 승인 상태, 외부 API 전송 가능 여부, 얼굴·번호판 비식별화 조건을 확인한 데이터만 사용한다.
학습이 지연될 경우	LoRA 학습이 지연되어도 평가 체계(Guideline, 검수된 Test, 자동 채점 Code, Viewer)와 Base 모델의 결과·오류 분석 Report는 산출물로 남긴다. 이때 Tuned 결과는 확보한 범위에서 Dev 결과로 명시하여 보고하고, Test 결과와 구분한다.

5 실행 계획 및 협의 사항

첫 달(4주) 동안 Track 1의 완성을 목표로, 주차별로 확인 가능한 산출물을 규정한다. Track 2·3은 Track 1의 일정에 영향을 주지 않는 범위에서, 데이터 정합성을 확인한 순서대로 진행한다.

5.1 4주 단계별 Milestone

주차	작업	완료 기준
1주차 Guideline 확정과 Pilot	두 Annotator가 서로 보지 않고 약 50장면을 기록한다. 장면은 각 관계의 P/A/U와 주요 도로 조건이 고루 포함되도록 고른다. C의 폭·깊이 작성 기준을 확정하고, 장면당 작업 시간을 재어 Test 표본 수를 정한다. Pilot 장면은 Train/Dev 자료로 배정한다.	단순 일치율 85% 미만 또는 κ 0.7 미만 항목의 Guideline 개정, Field별 일치도, 목표 표본 수
2주차 Schema 고정과 자동 채점기	Track 1 출력 Schema를 확정하고, Invalid·Missing·U·Not applicable 처리를 반영한 자동 채점 Code를 구현한다.	각 예외 상황의 예제가 예상대로 채점됨
3주차 Base 평가와 취약점 분석	Gemma 4 Base 모델을 Zero-shot으로 평가하고, 지표별로 오류를 분석한다(누락과 오탐, 환각 비율). 분석 결과로 Fine-tuning 데이터를 기획하고 LoRA 학습을 시작한다.	Dev 기준 오류 분석 Report. 데이터 확대와 중복 검사를 마친 뒤 Test 소속 Group과 입력·정답 고정
4주차 Tuned 비교와 Web Demo	같은 Test에서 Base와 Tuned를 비교하고, 정답 Box와 예측 Box, 근거–관계–대응의 연결을 나란히 보여 주는 Web Viewer를 완성한다.	대표 점수와 진단 점수, 분모, 차이의 신뢰구간을 담은 비교 Report. 학습이 지연되면 §4.5의 대안을 따른다.

모델·Prompt·학습 설정은 Train/Dev에서 선택하고, 최종 평가 전에 해당 설정과 채점 Code를 고정한다. 1주차의 85%와 κ 0.7은 정답 품질을 보장하는 일반적인 합격선이 아니라, Guideline 재검토를 개시하는 본 프로젝트의 운영 기준으로 정의한다.

5.2 실무진께 요청드리는 의사결정 안건

1. **R1(점유)과 R4(통행 제한)의 분리 기준.** 현재 규칙은 사진 한 장으로 정차 여부를 확정할 수 없다는 점을 고려해 차량을 모두 Actor로 분류하고, 길가에 정렬된 차량(Roadside Vehicle)이 C를 점유하면 R1과 R4를 함께 P로 판정한 뒤 대응은 R4의 통과 가능성 확인으로 대체한다(§2.4). 이 예외 규칙을 단순화하기 위해, R1은 보행자처럼 진행 공간에서 비켜 줄 수 있는 Actor로 한정하고 Roadside Vehicle과 Obstacle에 의한 점유는 R4로 일원화하는 방안에 대해 실무 관점의 의견을 요청드린다.
2. **Taxonomy.** 생활도로의 네 가지 관계(R1 점유, R2 출입구, R3 시야 가림, R4 통행 제한)가 실무 관점에서 골목길의 위험을 설명하기에 충분한지, 추가하거나 제외할 관계가 있는지 의견을 요청드린다.
3. **우선순위.** 일정 위험을 관리하기 위해 Track 1을 먼저 완성하고, Track 2·3은 데이터 정합성 확인에 따라 순차적으로 진행하는 전략에 동의하시는지 확인을 요청드린다.
4. **도메인 검수.** 1주차 Pilot 약 50장면의 관계와 대응 규칙 예시를 공유드릴 때, 실무진의 피드백을 받을 채널과 주기를 정하고자 한다.

부록: Technical Appendix

본문에서 생략한 수식, 세부 규칙, 근거 자료를 기술적 질의에 즉시 제시할 수 있도록 수록한다.

App. A. 세부 지표 정의

아래 식에서 $\#(\cdot)$은 괄호 안 조건을 만족하는 항목의 개수이고, $\mathbf{1}[\cdot]$은 조건이 참이면 1, 거짓이면 0이다.

App. A.1 대표 점수의 정의 (V5, V10)

V5 Relation Macro-F1. 관계 $h \in \{R1, \ldots, R4\}$와 상태 $c \in \{P, A, U\}$마다 F1을 구하고, 12개 칸을 똑같은 비중으로 평균한다.

$$F1_{h,c} = \frac{2\,TP_{h,c}}{2\,TP_{h,c} + FP_{h,c} + FN_{h,c}}, \qquad \mathrm{V5} = \frac{1}{12} \sum_{h} \sum_{c \in \{P,A,U\}} F1_{h,c}. \tag{1}$$

V10 Action Pass Rate. 대응 평가에 쓰는 장면의 집합 $\mathcal{A}$는 관계와 대응 정답의 검수가 끝났고, 정답 Direction Match가 Conflicting이 아닌 장면으로 미리 정한다. 통행 방향이 Unknown인 장면은 대응 평가에 포함한다. $N_A = |\mathcal{A}|$이며, 이 분모는 실행 전에 고정(freeze)하여 모델의 예측 결과나 실패 여부와 무관하게 유지한다. 장면 i의 허용 쌍 집합을 A_i, 금지 쌍 집합을 F_i, 필요 대응 묶음을 $G_{i1}, \ldots, G_{im_i}$, 모델이 답한 (대응, 조건) 쌍의 집합을 S_i라 하면

$$\mathrm{AP}_i = \mathbf{1}\Big[\, V_i \wedge C_i \wedge S_i \subseteq A_i \wedge S_i \cap F_i = \varnothing \wedge \textstyle\bigwedge_{j=1}^{m_i} \big(S_i \cap G_{ij} \neq \varnothing\big) \Big], \qquad \mathrm{V10} = \tfrac{1}{N_A} \textstyle\sum_{i \in \mathcal{A}} \mathrm{AP}_i. \tag{2}$$

- V_i: 형식이 Valid하다. Invalid인 답은 $\mathrm{AP}_i = 0$이다.
- C_i(일관성): 두 검사를 모두 통과한다. 첫째는 **정답과의 일관성**으로, 답한 각 쌍의 조건 Code가 요구하는 정답 판정이 실제로 있어야 한다. 둘째는 **답 내부의 일관성**으로, `based_on`이 그 조건에 필요한 관계를 가리키고, 모델 자신이 낸 관계 판정이 그 조건을 뒷받침해야 한다. 같은 조건의 보류와 진행처럼, 또는 조건 없는 진행과 점유 중 보류처럼 적용 구간이 겹치면서 서로 모순되는 쌍을 함께 답해도 실패다. C_i는 Box의 위치나 근거 ID의 정확성을 검사하지 않으며, 이는 V3·V4에서 측정한다.
- $S_i \subseteq A_i$: 허용된 쌍만 답했다. 허용에도 금지에도 없는 쌍(Unsupported Pair)을 답하면 실패이며, 그 수를 따로 보고한다.
- $S_i \cap F_i = \varnothing$: 금지된 쌍이 없다.
- 마지막 조건: 모든 필요 대응 묶음에서 하나 이상을 올바른 조건과 근거 연결로 답했다. U인 관계 여러 개를 확인 후 진행 하나로 다루려면 `based_on`에 그 관계를 모두 적어야 한다.

§2.5의 예시에서 확인 후 진행과 통과 가능성 확인만 답하면 o1의 점유에 대한 묶음을 놓쳐 실패한다.

App. A.2 공통 규칙: 형식 검사와 실패한 요청 (V1, V2)

평가 요청은 문항 하나를 모델에 넣어 답을 받는 한 번의 실행이다. V1은 JSON으로 읽히고, 필수 항목이 있으며, 허용된 값과 유효한 좌표 범위를 지키고, 참조한 ID가 같은 답 안에 실제로 선언된 답의 비율이고, V2는 그 나머지 비율이다. 형식 검사는 채점 가능한 구조인지만 판정한다. 실제로 없는 보행자를 `o1`로 선언한 답도 형식은 통과하므로, 내용과 사진의 일치 여부는 다음 단계에서 판정한다.

형식 오류(Invalid)가 반영되는 방식은 점수마다 다르다. 관계·속성 판정에서는 실제 정답을 놓친 것(FN)으로 세므로, V6과 V8에서는 분모에만 남는다. V7과 V9는 각각 "P로 단정함"과 "U로 피함"을 세는 점수이므로, Invalid는 분모에만 포함하고 분자에서 제외한다. V10과 V11은 Invalid를 실패로 세지만, V12는 금지 쌍이 **확인된** 답만 세므로 Invalid를 분모에만 포함한다. 그래서 V2는 항상 함께 보고한다. 정답이 Missing인 항목은 채점 전에 제외하고, 분모가 0인 점수는 0이나 100%가 아니라 N/A로 보고한다.

App. A.3 근거 대조 (V3, V4)

V3은 모델의 Box가 정답 Box와 같은 대상인지 판정한다. 두 Box가 겹친 면적을 합친 면적으로 나눈 값(IoU)이 0.5 이상이고 Class가 같은 쌍만 짝이 될 수 있으며, 한 예측과 한 정답은 최대 한 번만 짝짓는다. 짝의 수가 가장 많아지게 하고, 같으면 IoU의 합이 큰 쪽을 고른다. Object와 Region은 종류별로 따로 짝짓는다. 짝이 된 예측은 TP, 짝이 없는 예측은 FP, 짝이 없는 정답은 FN이고, Precision $= TP/(TP+FP)$, Recall $= TP/(TP+FN)$, F1 $= 2TP/(2TP+FP+FN)$이다. IoU 0.3과 0.7에서도 함께 계산해 기준에 따른 차이를 확인한다.

V4는 관계 판정의 근거로 연결한 ID 집합이 정답 집합과 정확히 일치하는지 판정한다. 모델이 붙인 ID 문자열은 정답의 ID와 같은 이름이어도 같은 대상이라는 보장이 없으므로, 먼저 V3의 짝짓기로 모델 ID를 정답 ID로 바꾼 뒤 비교한다. 짝이 없는 ID를 근거로 댔거나 형식 오류인 답은 실패다. 분모는 정답이 P 또는 U이면서 근거 검수가 끝난 판정 항목이며, 근거가 될 수 있는 조합이 여럿이면 모두 정답으로 등록한다. R1을 P로 맞혔지만 근거로 엉뚱한 차량을 댄 답은 관계 점수에서는 맞고 V4에서는 틀린다.

App. A.4 관계 판정 진단 (V6–V9)

아래에서 y는 정답, $\hat{y}$는 예측이다.

점수	식	잡아내는 오류
V6 Recall for Present	$\#(y{=}P, \hat{y}{=}P) \,/\, \#(y{=}P)$	있는 위험 관계를 놓침
V7 False Positive Rate	$\#(y{=}A, \hat{y}{=}P) \,/\, \#(y{=}A)$	없는 위험 관계를 있다고 함
V8 Recall for Unknown	$\#(y{=}U, \hat{y}{=}U) \,/\, \#(y{=}U)$	판단할 수 없는 것을 단정함
V9 Over-abstention	$\#(y{\in}\{P,A\}, \hat{y}{=}U) \,/\, \#(y{\in}\{P,A\})$	판단할 수 있는데 “모름” 으로 피함

예를 들어 정답이 P인 항목 50개에 모델이 P 35개, U 10개, Invalid 5개를 답했다면 V6은 $35/50 = 70\%$이다. V8과 V9는 반대 방향의 실패를 측정한다. 항상 U만 답하는 모델은 V8이 높지만 V9도 높게 나타나 식별되고, U를 전혀 사용하지 않는 모델은 V8이 0이 되어 식별된다. V5의 12개 칸 중 하나라도 정답이 없으면 V5는 N/A로 두고, 정답이 있는 칸만 평균한 값을 Supported-class Macro-F1이라는 다른 이름으로 따로 보고한다.

App. A.5 장면 속성 판정 (A1, A2)

A1 Attribute Macro-F1은 모델 출력 속성 Field f(Sidewalk 좌, Sidewalk 우, Traffic Direction, Direction Match)마다 $\mathrm{A1}_f = \sum_{c \in \mathcal{C}_f} F1_{f,c} \,/\, |\mathcal{C}_f|$로 계산한다. 값 집합 $\mathcal{C}_f$는 Sidewalk가 {Present, Absent, Unknown}, Traffic Direction이 {One-way, Two-way, Unknown}, Direction Match가 {Consistent, Conflicting, Unknown}이다. Direction Match의 정답이 Not applicable인 장면은 A1의 분모에서 빼고, 정답이 적용 가능한 값인데 모델이 Not applicable이라고 답하면 그 정답 Class를 놓친 것(FN)으로 센다. Field별 Confusion Matrix와 값별 표본 수를 함께 보고한다.

A1은 Not applicable 장면을 분모에서 빼므로, 실제로는 Two-way라서 비교가 적용되지 않는 장면에서 모델이 Consistent나 Conflicting이라고 답한 오류를 잡지 못한다. 이 오류는 A2 Direction Applicability Error로 별도 측정한다.

$$\mathrm{A2} = \frac{\#(y = \mathrm{N/A},\ \hat{y} \in \{\mathrm{Consistent}, \mathrm{Conflicting}\})}{\#(y = \mathrm{N/A})} \tag{3}$$

App. A.6 대응 진단 (V11, V12)

V11 Required Action Coverage는 전체 필요 대응 묶음 중 충족한 묶음의 비율($\sum_i \sum_j r_{ij} / \sum_i m_i$, r_{ij}는 묶음 j를 올바른 조건과 근거로 충족하면 1)이다. V12 Forbidden Action Rate는 금지 쌍이 하나

라도 확인된 답의 비율($(1/N_A)\sum_i \mathbf{1}[S_i \cap F_i \neq \varnothing]$)이다. 둘을 함께 보면 V10이 낮은 원인이 누락인지 부적절한 대응인지 가를 수 있다.

App. A.7 진술 검수 (V13, V14)와 설명 제출률

모델의 설명을 "보행자가 보인다"처럼 참·거짓을 따로 확인할 수 있는 최소 진술로 나누고, 사람이 입력과 대조한다. Object의 존재, 공간 관계, 움직임, 통행 규칙, 환경 상태를 근거 없이 단정한 진술을 오류로 기록한다. 설명이 있고 모든 진술의 검수가 끝난 답의 집합을 $\mathcal{R}$, 답 i의 진술 수를 K_i, 진술 k의 오류 여부를 $e_{ik} \in \{0,1\}$이라 하면, V13은 $\sum_{i,k} e_{ik} / \sum_i K_i$이고, V14는 오류 진술이 하나라도 있는 답의 비율이다. 통행 방향이 Unknown인 장면에서 모델이 규칙을 단정해 말하면 대응 오류가 아니라 진술 오류로 센다.

설명을 요구한 요청 중 검수할 수 있는 설명을 낸 요청의 비율(Explanation Completion Rate)도 따로 보고한다. 이는 설명을 제출하지 않은 답이 많으면, 오류율이 낮게 집계되더라도 실제로는 설명을 회피한 결과일 수 있다는 점에 기인한다. 다만 관계와 대응의 정오는 설명의 유무와 독립적으로 판정한다.

App. A.8 정답 품질과 표본 구성 (L1–L3)

두 Annotator가 서로 보지 않고 기록한 합의 전 결과를 Field별로 비교하며, 속성마다 일치도를 따로 계산한다.

$$L1 = p_o = \frac{n_{\text{agree}}}{n_{\text{double}}}, \qquad L2 = \kappa = \frac{p_o - p_e}{1 - p_e}, \qquad p_e = \sum_c p_{1c}\, p_{2c}.$$

p_{ac}는 Annotator a가 값 c를 고른 비율이고, κ는 우연히 같은 값을 고를 몫(p_e)을 뺀 일치도다. $p_e = 1$이면 κ는 N/A이며 L1과 값의 분포를 보고한다. L3은 관계 h·상태 c별 문항 수 n_{hc}와 그 값을 포함하는 서로 다른 Source Group 수 g_{hc}다.

App. A.9 조건별 분석

같은 점수를 장면 조건별로 다시 계산하면 모델이 약한 환경을 찾을 수 있다. 기본 조건은 Time of Day, 좌·우 Sidewalk 유무, Traffic Direction이다. 예를 들어 야간 장면에서 R1의 Present Recall은

$$\text{Recall}_{R1,P|\text{Night}} = \frac{\#\{\, i \in S_{\text{Night}} :\ y_{i,R1} = P,\ \hat{y}_{i,R1} = P \,\}}{\#\{\, i \in S_{\text{Night}} :\ y_{i,R1} = P \,\}} \tag{4}$$

이다. S_{Night}는 사람의 Annotation으로 미리 정한 야간 장면의 집합이며, 모든 모델에 같은 집합을 사용한다. 모델이 야간으로 예측한 장면으로 집합을 구성하면 모델마다 평가 대상이 달라지는 것을 방지하기 위함이다. 조건별로 나누면 분모가 작아지므로, 분모가 작은 조건의 결과는 탐색적 결과로만 다룬다.

App. A.10 신뢰구간의 계산

S1 Wilson 95% 신뢰구간은 서로 독립인 장면마다 성공·실패가 하나씩 나오는 비율 점수에 사용한다 [5]. 성공 수 k, 분모 n, $\hat{p} = k/n$, $z = 1.96$일 때

$$\text{CI}_{95} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \tag{5}$$

이다. S2 Group 단위 Bootstrap은 Wilson 구간을 사용할 수 없는 점수(V5, A1처럼 여러 F1을 평균한 점수, 같은 Group의 문항을 여러 개 세는 점수)와 두 모델의 점수 차이에 사용한다. 서로 다른 Source Group G개에서 G개를 복원추출하고, 뽑힌 Group의 문항을 모두 포함해 점수를 다시 계산하며, 매번 두 모델에 똑같이 뽑힌 표본을 적용한다. 2,000번 반복하면서 매번 각 모델의 점수 $M^*_{\text{Base}}, M^*_{\text{Tuned}}$와 차이 $\Delta^* = M^*_{\text{Tuned}} - M^*_{\text{Base}}$를 계산하고, 각각의 2.5번째와 97.5번째 백분위수를 그 모델의 점수 구간과 차이의 구간으로 보고한다[4]. Source Group이 하나뿐이면 구간은 N/A다. 어떤 반복에서 특정 상태의 정답이 0개가 되어 V5를 정의할 수 없으면, 그 반복을 버리지 않고 비율을 기록하며 V5의 구간은 N/A로 표시한다.

App. A.11 점수 전체 표

대표 점수는 굵게 표시했다.

ID	이름	식	분모와 뜻
정답 품질			
L1	Raw Agreement	$n_{\text{agree}}/n_{\text{double}}$	합의 전 두 Annotator의 일치 비율 (Field별)
L2	Cohen's κ	$(p_o - p_e)/(1 - p_e)$	우연히 일치할 몫을 뺀 일치도(Field별)
L3	Samples per Relation–State	n_{hc}, g_{hc}	관계·상태별 문항 수와 Source Group 수
공통			
V1 / V2	Valid / Invalid Output Rate	N_{valid}/N, $1 - \text{V1}$	형식이 맞는 답 / 형식 오류와 Timeout의 비율
Track 1			
V3	Object P / R / F1	$2TP/(2TP + FP + FN)$ 등	Class 일치·IoU≥0.5 일대일 짝짓기
V4	Evidence ID Exact Match	$(1/K)\sum \mathbf{1}[\text{Match}(\hat{E}_{ih}) \in E^*_{ih}]$	근거가 필요한 P/U 판정 K개 중 근거 ID 집합이 정확히 맞은 비율
V5	**Relation Macro-F1**	$(1/12)\sum_h \sum_c F1_{h,c}$	4관계 × 3상태 F1의 균등 평균
V6	Recall for Present	$\#(P \to P)/\#(y{=}P)$	있는 관계를 놓치지 않는 정도
V7	False Positive Rate	$\#(A \to P)/\#(y{=}A)$	없는 관계를 있다고 하는 정도
V8	Recall for Unknown	$\#(U \to U)/\#(y{=}U)$	판단할 수 없는 것을 모른다고 하는 정도
V9	Over-abstention	$\#(\{P, A\} \to U)/\#(y{\in}\{P, A\})$	판단할 수 있는데 피하는 정도
A1	Attribute Macro-F1	$\sum_c F1_{f,c}/\lvert\mathcal{C}_f\rvert$	장면 속성 Field별 F1 평균. V5와 별도 채점
A2	Direction Applicability Error	$\#(\text{N/A} \to \{\text{Cons.}, \text{Conf.}\})/\#(y{=}\text{N/A})$	비교가 적용되지 않는 장면에서 방향 일치를 판정한 비율
V10	**Action Pass Rate**	$(1/N_A)\sum_i \text{AP}_i$	대응 평가 장면 중 모든 조건을 통과한 비율
V11	Required Action Coverage	$\sum_{i,j} r_{ij}/\sum_i m_i$	필요 대응 묶음 중 충족한 비율
V12	Forbidden Action Rate	$(1/N_A)\sum_i \mathbf{1}[S_i \cap F_i \neq \varnothing]$	금지 쌍이 확인된 답의 비율
V13	Statement Error Rate	$\sum_{i,k} e_{ik}/\sum_i K_i$	검수한 최소 진술 중 오류 진술 비율
V14	Response Error Rate	$\#(\sum_k e_{ik} > 0)/\lvert\mathcal{R}\rvert$	오류 진술이 하나라도 있는 답의 비율
Track 2			

ID	이름	식	분모와 뜻
T2-1	**TargetAcc**	$n_2^{-1}\sum_i \mathbf{1}[\hat{y}_i \in Y_i]$	후보 중 사고 대상을 고른 비율(잔여 시간 구간별)
T2-2	mIoU / $\mathrm{Acc}_{.5}$	$n_3^{-1}\sum_i u_i$, $n_3^{-1}\sum_i \mathbf{1}[u_i \geq .5]$	사고 대상 Box 예측의 정확도
T2-3	Event P / R / F1, Completion	—	사고 발생 여부 예측(확장 평가)
T2-4	Lead Time	$t_c - t_{\text{confirm}}$	예측이 연속으로 확인된 시점부터 충돌까지의 시간
Track 3			
T3-1	Acc_s / Acc_d	$n_1^{-1}\sum_i \mathbf{1}[\hat{s}_i = s_i]$ 등	속도 변화 / 회전 방향을 맞힌 비율
T3-2	**Joint Accuracy**	$n_1^{-1}\sum_i \mathbf{1}[\hat{s}_i = s_i \wedge \hat{d}_i = d_i]$	둘을 함께 맞힌 비율
조건별 분석과 신뢰구간			
—	조건별 점수	$M \mid S_c$	점수 M을 Annotation으로 정한 조건 집합 S_c에서 다시 계산
S1	Wilson 95% CI	위 식	독립 장면의 성공/실패 비율
S2	Group Bootstrap CI	$Q_{.025}, Q_{.975}$ of M^*, Δ^*	각 모델 점수와 두 모델 차이의 구간 (2,000회)

App. B. Track 1 대응 규칙 상세와 출력 예시

App. B.1 대응 Code와 조건 Code

대응 Code는 다음 일곱 가지다.

대응 Code	뜻
`VERIFY_BEFORE_ADVANCE`	확인 후 진행
`REDUCE_SPEED_IF_MOVING`	이동 중이면 감속
`YIELD_IF_OCCUPIED`	점유 시 양보
`HOLD_UNTIL_CLEAR`	해소될 때까지 보류
`VERIFY_PASSAGE`	통과 가능성 확인
`MONITOR_AHEAD`	전방 관찰
`ADVANCE_WITH_MONITORING`	관찰하며 진행

모든 대응은 해당 영역이나 구간을 실제로 확인한 뒤 진행 여부를 정한다는 뜻으로 해석한다. 조건 Code는 그 대응을 어떤 관측 상황에서 하는지를 정한다.

조건 Code	뜻	사용할 수 있는 정답
`no_condition`	장면 전체에 그대로 적용한다.	제한 없음
`while_corridor_occupied`	C의 점유가 유지되는 동안 적용한다.	R1 = **P**

조건 Code	뜻	사용할 수 있는 정답
`while_actor_near_entrance`	출입구 주변에 Actor가 있는 동안 적용한다.	R2 = **P**
`before_entering_occluded_area`	가려진 영역 앞에 들어서기 전에 적용한다.	R3 = **P**
`before_passing_restricted_section`	좁아진 구간을 지나기 전에 적용한다.	R4 = **P** 또는 **U**
`before_resolving_uncertainty`	판정할 수 없는 관계를 확인하기 전에 적용한다.	R1 · R2 · R3 중 **U**

App. B.2 관계별 대응 규칙

필요 대응은 모두 허용 대응에 포함되고, 허용과 금지는 서로 배타적인 집합으로 정의한다. 여러 관계가 함께 성립하면 각 관계의 필요 대응 묶음을 모두 요구한다.

정답	필요 대응	조건
R1 = **P**, 움직일 수 있는 Actor의 점유 (Roadside Vehicle 제외)	양보(`YIELD_IF_OCCUPIED`) 또는 보류(`HOLD_UNTIL_CLEAR`). 이동 중 감속은 허용한다.	점유 동안
R1 = **P**, 점유 대상이 Obstacle 또는 Roadside Vehicle뿐	R1에 대한 요구는 R4 행으로 대체한다. 같은 대상으로 R4 = P가 되므로 R4 행의 통과 가능성 확인이 필요 대응이 되며, 보류는 허용 대응으로 지정한다.	(R4 행 적용)
R2 = **P**	전방 관찰(`MONITOR_AHEAD`) 또는 이동 중 감속	출입구 주변 Actor가 있는 동안
R3 = **P**	확인 후 진행(`VERIFY_BEFORE_ADVANCE`). 이동 중 감속은 허용한다.	가려진 영역 진입 전
R4 = **P** 또는 **U**	통과 가능성 확인(`VERIFY_PASSAGE`)	좁아진 구간 통과 전
R1 · R2 · R3 중 **U**가 있음	확인 후 진행. `based_on`에 U인 관계를 모두 적는다.	불확실성 확인 전
R1–R4 모두 **A**	전방 관찰 또는 관찰하며 진행(`ADVANCE_WITH_MONITORING`)	조건 없음

보행자처럼 움직일 수 있는 Actor가 Obstacle과 함께 점유하면, 그 Actor에 대한 양보 · 보류 요구도 함께 적용한다. 통행 방향이 Unknown인 장면에서 모델이 규칙을 단정해 말하면 대응 오류가 아니라 진술 오류(V13, V14)로 센다. 이 규칙들은 Pilot에서 각 장면의 규칙 조합에 통과할 수 있는 답이 실제로 존재하는지 확인한 뒤 고정한다.

App. B.3 방향 충돌 장면의 처리

일방통행을 거꾸로 가는 장면(정답 Direction Match = Conflicting, App. E.4)에는 위 대응 규칙 대신 아래의 제외 규칙을 적용한다. 이러한 장면에서는 R3=P여서 확인 후 진행이 필요하더라도, 그 방향으로의 진행 자체가 부적절해 같은 대응을 금지해야 하므로 맞는 답이 존재하지 않는다는 점에 기인한다. 그래서 방향 충돌 장면은 대응 평가(V10–V12)에서 제외하고, 관계 판정(V5–V9)과 장면 속성 판정(A1,

A2)에서는 계속 평가한다. 제외 여부는 사람이 정한 정답으로만 정하고, 제외한 수와 이유를 Report에 적는다.

App. B.4 출력 예시

§2.5의 장면에서 모든 판정을 맞힌 출력은 다음과 같다. 대응에서 HOLD_UNTIL_CLEAR 대신 YIELD_IF_OCCUPIED를 답해도 같은 필요 대응 묶음을 충족한다.

```
{
  "intent": "follow_visible_road_forward",
  "objects": [
    {"id": "o1", "class": "pedestrian",
     "bbox": [0.42, 0.56, 0.48, 0.82]},
    {"id": "o2", "class": "vehicle", "placement": "roadside",
     "bbox": [0.58, 0.52, 0.86, 0.86]}
  ],
  "regions": [
    {"id": "z1", "class": "occluded_entrance",
     "bbox": [0.63, 0.32, 0.78, 0.68]}
  ],
  "scene": {"sidewalk_left": "A", "sidewalk_right": "A",
            "traffic_direction": "Unknown",
            "direction_match": "Unknown"},
  "relations": [
    {"code": "R1", "state": "P", "evidence": ["o1", "o2"]},
    {"code": "R2", "state": "A", "evidence": []},
    {"code": "R3", "state": "P", "evidence": ["o2", "z1"]},
    {"code": "R4", "state": "P", "evidence": ["o2"]}
  ],
  "actions": [
    {"code": "HOLD_UNTIL_CLEAR",
     "condition": "while_corridor_occupied", "based_on": ["R1"]},
    {"code": "VERIFY_BEFORE_ADVANCE",
     "condition": "before_entering_occluded_area", "based_on": ["R3"]},
    {"code": "VERIFY_PASSAGE",
     "condition": "before_passing_restricted_section", "based_on": ["R4"]}
  ]
}
```

App. C. 학술적 참조 방법론

R1–R4, P/A/U, Direction Match, 대응 규칙과 대표 점수의 조합은 본 프로젝트의 고유 설계다. 아래 자료는 질문 구성, 시각 근거 검증, 오류 집계, 불확실성 보고의 원리를 참고한 것이며, 본 문서의 점수는 원 논문의 점수와 구분되는 별도의 이름으로 보고한다.

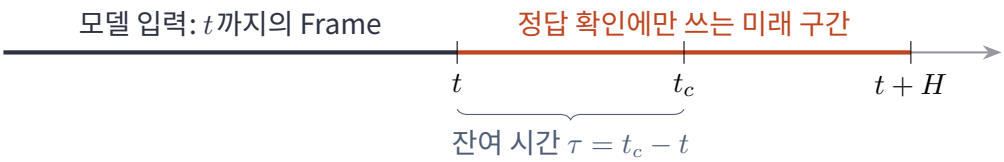


그림 5. Track 2의 시간 정의. 모델은 t까지의 Frame만 받고, t 이후 구간은 정답을 확인할 때만 사용한다.

자료	참고한 방법	본 문서에서의 적용·변형
DriveBench[1]	정상·손상·검은 사진 조건을 비교해 모델이 시각 입력에 의존하는지 진단	최종 답만으로는 근거를 보고 판단했는지 알 수 없다는 동기. Box·관계·근거를 따로 평가
POPE[2]	모든 사진에 같은 Object 존재 질문을 Yes/No 균형으로 던져, 있다고 답하는 쪽으로 쏠리는 편향을 드러내는 평가	네 공간 관계의 고정 질문과 P/A/U로 확장. 원래 POPE와 다른 점수
CHAIR[3]	Object 단위와 Caption 단위의 Hallucination 비율	사람이 검수한 최소 진술과 응답 단위로 확장. 움직임·통행 규칙 오류도 포함
Agarwal et al.[4]	점수와 불확실성을 함께 보고하는 Bootstrap 신뢰구간	촬영 Group 단위로 묶는 Paired Bootstrap으로 변경해 두 모델의 차이에 적용

App. D. Track 2 / Track 3 세부 명세

App. D.1 Track 2: 미래 사고 대상 예측

Track 2는 판단 시점까지의 영상만 보고, 앞으로 정해진 시간 안에 자차와 충돌할 보행자를 찾는지 평가한다. 첫 버전에서 사건은 자차와 보행자의 충돌(Ego–Pedestrian Collision)로 제한한다. 판단 시점을 t, 사람이 검수한 최초 접촉 시점을 t_c, 예측 기간(Prediction Horizon)을 H라 하고, 판단 시점부터 충돌까지 남은 시간 $\tau = t_c - t$를 **잔여 시간**이라 부른다. $0 < \tau \leq H$이면 **Positive**이고, $t+H$까지 관측을 마쳤는데 충돌이 없으면 **Negative**다. H는 2초를 Pilot 시작안으로 두고, 검수 후 Test 전에 고정한다. 질문도 "지금 가장 위험한 사람"이 아니라 "앞으로 H초 안에 내 차와 충돌할 보행자"로 명확히 한다.

정답 항목	작성 기준
Event Time	최초 접촉 Frame을 사람이 검수하고 원본 Timestamp와 연결한다. 정확히 정할 수 없으면 Missing으로 두고 시간별 평가에서 제외한다.
Future Event Label	t 이후 H초 안에 충돌이 있으면 Positive, $t+H$까지 관측을 마쳤고 충돌이 없으면 Negative다.
Target Identity	Positive 문항의 실제 사고 당사자 ID다. 사고 기록의 당사자 표시(`isObjectA`)를 근거로 한다. 첫 버전은 대상 보행자가 한 명인 문항만 사용한다.
Target Visibility	대상이 t에서 보이는지 기록한다. 완전히 가려진 대상은 기본 평가의 분모에서 분리한다.
Current Target Box	대상의 t 시점 Box다. 정답 위치는 t 시점으로 한정하며, 미래 Frame의 위치는 요구 대상에서 제외한다.

정답 항목	작성 기준
Observation Coverage	영상이 $t+H$ 전에 끝나면 Negative로 확정할 수 없으므로 불완전 관측(Missing)으로 기록한다.

평가 방식. Selection은 번호가 붙은 후보 보행자 중 대상을 고르는 방식이고, **Localization**은 대상의 Box를 직접 찾는 방식이다. 후보를 주면 문제가 쉬워지므로 두 방식은 따로 보고한다. 분모는 해당 Horizon의 Positive 중 대상이 판단 시점에 보이고 한 명뿐이며 검수가 끝난 문항이다. 허용 대상 ID 집합을 Y_i, 대상의 정답 Box를 B_i라 하면, Selection은 $\text{TargetAcc} = n_2^{-1}\sum_i \mathbf{1}[\hat{y}_i \in Y_i]$로, Localization은 $u_i = \text{IoU}(\hat{B}_i, B_i)$에 대해 $\text{mIoU} = n_3^{-1}\sum_i u_i$와 $\text{Acc}_{.5} = n_3^{-1}\sum_i \mathbf{1}[u_i \geq 0.5]$로 채점한다. Box를 읽을 수 없으면 $u_i = 0$이다. 점수는 미리 정한 판단 시점(Pilot 제안: 0.5초 간격)마다 계산하고, 잔여 시간 구간별로 보고하며, 같은 영상의 여러 판단 시점은 하나의 Source Group으로 묶는다.

사고 발생 여부 평가(확장). 관측을 마친 Negative를 확보한 뒤에는 "H초 안에 사고가 일어나는가"($\hat{z} \in \{0,1\}$)를 따로 채점한다. 출력에서 "사고가 일어나는가"(`event_prediction`)와 "누구와 일어나는가"(`target`)를 분리하며, `no_event_within_horizon`은 정해진 기간 안에 그 충돌이 없음을 의미하는 것으로 한정하여 해석하며, 장면 전체의 안전 판정과 구분한다. Valid한 1 예측 중 Positive는 TP, Negative는 FP이며, Positive에 0·응답 회피·Invalid로 답하면 FN이다. Precision, Recall, F1과 함께 응답을 피한 비율을 드러내는 $\text{Completion} = \#(\hat{z} \in \{0,1\} \wedge \text{Valid})/N$을 보고한다.

Lead Time. 같은 대상을 판단 시점마다 연결한 뒤, 0.5초 간격의 연속 세 시점에서 사건과 대상을 모두 맞혔을 때 세 번째 시점 t_{confirm}에서 예측이 확인되었다고 정한다. 처음 확인된 시점의 $t_c - t_{\text{confirm}}$을 **Lead Time**으로 보고하고, 확인에 성공한 사고의 비율도 함께 낸다. Lead Time은 판단 시점마다 정해지는 잔여 시간 τ와 달리, 예측이 연속으로 맞기 시작한 시점을 기준으로 한 값이다. 한 번 우연히 맞힌 가장 이른 시점을 고르지 않기 위해 연속 세 번을 요구하며, 실패한 사례도 분모에 포함한 확인 성공 비율과 함께 Lead Time을 보고한다. Negative에서 같은 대상에 대한 경보가 세 시점 연속 나온 비율은 False-alert Rate로 보고한다. 간격과 연속 횟수는 Pilot 제안이며 Test 전에 고정한다.

v0와의 관계. v0의 Track 2 문항(4문항)은 모두 사고 당사자가 있는 사례에서 대상을 고르는 문항이다. 정확한 t_c와 H가 검수되어 있지 않으므로, v0의 점수는 재현 자료로만 사용하고 잔여 시간별 평가는 t_c와 H를 검수한 문항으로 수행한다. 또한 4문항 모두 화면 가장 아래쪽 후보를 고르면 맞으므로, v0의 점수는 모델의 능력이 아니라 출력 형식과 채점 Code를 점검한 Pilot 결과로만 보고한다. v0의 `closest`, `random` 기준선은 정답 후보 Box를 받은 상태에서 고르는 방식이므로 Localization과 구분해 표시한다.

App. D.2 Track 3: 자차 움직임 인지

Track 3은 관측 구간의 Frame Sequence를 보고 자차의 속도 변화와 회전 방향을 맞히는지 평가한다. 정답은 AI Hub 472에 영상과 함께 제공되는 GNSS/INS 기록(100 Hz, 장면 원점 기준 상대 위치)[7]으로 정하므로, 영상에서 추정한 움직임을 외부 측정값으로 검증하는 방식이다. 속도 변화와 회전 방향은 입력 구간에서 실제로 일어난 관측값으로 한정하여 해석하며, "그렇게 했어야 한다"는 권장 행동이나 다음 운행 의도와 구분한다.

문항 i의 정답 속도 변화 Class를 s_i, 회전 방향 Class를 d_i라 하면 각각의 정확도와, 대표 점수인 둘을 함께 맞힌 비율은 다음과 같다.

$$\text{Acc}_s = \frac{1}{n_1}\sum_i \mathbf{1}[\hat{s}_i = s_i], \qquad \text{Acc}_d = \frac{1}{n_1}\sum_i \mathbf{1}[\hat{d}_i = d_i], \qquad \text{JointAcc} = \frac{1}{n_1}\sum_i \mathbf{1}[\hat{s}_i = s_i \wedge \hat{d}_i = d_i].$$

v0의 Track 3 문항은 최고 속도가 4 km/h 미만인 구간을 "멈춤"으로 정했다. 이 기준은 완전 정지가 아니라 정지 또는 저속 구간이라는 운영상 정의이므로, v0 점수를 재현할 때 Report에 그 뜻을 함께 적는다. 완전 정지(Standstill)로 기준을 바꾸려면 새 Label Version이 필요하다.

App. E. 입력·정답 기록 원칙과 Annotation 세부

App. E.1 사진 한 장 입력과 Frame Sequence 입력

모든 문항은 판단 시점(Decision Time)을 가지며, 입력은 판단 시점까지의 Frame으로 한정한다. Track 1의 기본 입력은 판단 시점 t의 전방 사진 한 장과 진행 의도 `follow_visible_road_forward`다. 진행 방향이 여러 갈래로 해석되는 갈림길은 진행 의도를 따로 명시하거나 기본 평가에서 제외한다. 같은 장면에서 사진 한 장 문항과 Frame Sequence 문항을 모두 만들 수 있지만, 입력이 다르면 알 수 있는 사실도 다르므로 정답은 각 문항에 실제로 준 입력을 기준으로 따로 검수한다. Frame 간격은 실제 Timestamp로 저장한다. 예를 들어 0.1초 간격의 20 Frame은 1.9초이므로, v0의 "2초"는 명목상의 구간 길이로만 사용한다.

진행 의도(Intent)는 앞으로 가려는 방향이고, 자차 움직임(Ego Motion)은 관측 구간에서 실제로 일어난 움직임이며, 통행 방향(Traffic Direction)은 그 도로에 적용되는 규칙이다. 자차가 좌회전했다는 사실만으로 다음 의도나 일방통행 여부를 알 수는 없으므로, 세 항목은 따로 기록한다.

App. E.2 값과 함께 그 값을 알게 된 근거를 기록한다

같은 장면이라도 "데이터셋이 알고 있는 사실"과 "모델이 받은 입력으로 알 수 있는 사실"이 다를 수 있다. 예를 들어 Metadata에는 일방통행으로 적혀 있지만 사진에는 판독할 수 있는 표지가 없다면, 데이터셋의 사실은 One-way로 기록해 조건별 분석에 사용하고, 사진만 받는 모델의 정답은 Unknown으로 기록한다. 이 장면에서 모델이 One-way라고 답하면 사실과는 맞더라도 사진에 근거가 없는 단정이므로 오답이다.

그래서 각 정답에는 Value(검수한 값), Source(확인에 쓴 자료: 사진, Frame Sequence, Dataset Metadata, GNSS), Evidence(근거가 된 Object·Region·Frame·Metadata 항목의 ID), Annotation Status(작성·검수 상태), Model Input 포함 여부(그 근거를 모델도 받았는지)를 함께 저장한다. 작성 상태는 Missing → Draft(초안) → Reviewed(검수 완료)로 관리하고, Reviewed인 항목만 채점한다. **Unknown**은 검수했지만 입력으로 판단할 수 없다는 정답이고, **Missing**은 아직 작성·검수하지 않은 항목이며, **Not applicable**은 해당하지 않는 질문이다. 특정 항목이 Unknown으로 판정되더라도 다른 항목으로 전파하지 않으며, 각 항목은 독립적으로 판정·기록한다.

App. E.3 Scene Annotation 전체 항목

한 장면에 여러 속성을 함께 기록한다. 예를 들어 "보도 없는 야간 일방통행 도로의 양측 길가 차량"은 좌·우 Sidewalk = Absent, Traffic Direction = One-way, Time of Day = Night, 도로 가장자리 Vehicle 배치 = 양측이라는 속성의 조합으로 나타낸다. 가림과 통행 제약은 장면 하나의 속성이 아니라 특정 Object와 영역 사이의 관계이므로, 이 표가 아니라 R3, R4에서 대상 ID와 함께 다룬다.

분류 항목	기록할 값	작성 기준	용도
Sidewalk	좌·우 각각 Present / Absent / Unknown	지정한 진행 구간에서 보도 유무를 확인한다. 한쪽이 가려지면 그쪽만 Unknown이다.	모델 출력
Centerline	Present / Absent / Unknown	중앙선의 존재를 기록한다. 일방통행 여부는 이 값이 아니라 Traffic Direction의 근거로 판정한다.	분석 전용
Road Alignment	Straight / Curved / Unknown	도로가 곧은지 굽었는지를 기록하며, C를 그릴 때 참고한다.	분석 전용

분류 항목	기록할 값	작성 기준	용도
Road Connections	옆 골목, 교차로, 차량 출입구, 건물 출입구	연결부마다 종류와 Region ID를 기록한다.	모델 출력 (Region)
Traffic Direction	One-way / Two-way / Unknown	진행하려는 도로 구간에 적용되는 규칙과 그 확인 근거(표지 Object ID 등)를 기록한다.	모델 출력
Direction Match	Consistent / Conflicting / Unknown / Not applicable	확인된 일방통행 방향과 진행 의도의 일치 여부다(App. E.4).	모델 출력
Time of Day	Day / Twilight / Night / Unknown	시간대를 기록한다. 정확한 촬영 시각은 Timestamp로 따로 저장한다.	분석 전용
Lighting	낮은 조도, 역광, 강한 눈부심 각각의 Present / Absent / Unknown	시간대와 별도로 기록한다.	분석 전용
Weather	비, 눈, 안개 각각의 Present / Absent / Unknown	강우 여부는 젖은 노면만으로 판정하지 않고, 강우를 직접 보여 주는 근거가 있을 때 Present로 기록한다.	분석 전용
Road Surface	건조, 젖음, 고인 물, 눈 덮임	상태가 다른 영역은 Region별로 기록한다. 기록은 시각적 노면 상태로 한정하며, 실제 마찰계수는 대상에서 제외한다.	분석 전용
Objects	종류, 위치(Box), 가림 상태, 배치(Roadside 여부)	보행자·차량·자전거/이륜차·장애물 외에 판단 근거로 쓰는 교통표지도 포함한다.	모델 출력
Temporal Information	입력 방식, Sequence ID, 판단 시점, Timestamp, Frame 간격	어떤 시간 근거가 제공되는지 기록하며, 입력 구성과 Split 관리에 사용한다.	분석 전용

모델 출력 항목은 다음 기준으로 골랐다. Traffic Direction과 Direction Match는 그 방향으로 진행해도 되는지를 바꾸므로 대응 평가와 직접 이어진다. Sidewalk는 본 프로젝트의 주 대상인 “보도 없는 도로”를 모델이 구분하는지 확인하기 위한 항목이며, 첫 달에는 대응 규칙과 분리하여 속성 판정(A1)으로만 평가한다. Objects와 Road Connections는 관계 판정의 근거가 되는 대상이므로 모델이 직접 찾아야 한다. 분석 전용 항목은 모델이 예측하지 않지만, 모델이 설명 문장에서 “비가 오고 있다”처럼 스스로 언급하면 그 진술이 사진과 맞는지는 검수한다(V13, V14).

이와 별도로 장면을 수집하고 묶기 위한 Tag를 붙인다. Tag는 혼재 통행(Mixed Traffic), 도로 가장자리 차량 주변(Roadside Vehicles), 출입구 주변(Entrances), 좁은 통행 공간(Narrow Passage), 이륜차 근접(Two-wheeler Nearby), 공사 구간(Construction)의 여섯 가지이며, 장면 수집과 묶음 관리에만 사용하고 채점 대상에서 제외한다. 예를 들어 공사 구간 Tag가 붙어도, 그로 인한 통행 제약은 실제 배치를 보고 R4로 판정한다.

App. E.4 Direction Match 판정 규칙

Traffic Direction이 Two-way이면 일방통행 비교가 적용되지 않으므로 **Not applicable**이다. One-way이고 일방통행 방향이 진행 의도와 같으면 **Consistent**, 반대면 **Conflicting**, 일방통행이라는 것은 확인되지만 방향을 판독할 수 없으면 **Unknown**이다. Traffic Direction 자체가 Unknown이면 Direction Match도 **Unknown**이다. 표지가 그 도로 구간에 실제로 적용되는지도 함께 확인하며, 중앙선이 없다거나 차들이 같은 방향을 향한다는 사실만으로는 One-way를 확정하지 않고, 판독 가능한 표지가 있을 때 확정한다.

App. E.5 Annotation 절차

정답은 네 단계로 만든다.

1. 정보 범위를 맞춘다. Track 1 Annotator는 사고 이후 Frame과 사고 당사자 Label을 확인하기 전에, 모델과 같은 입력만으로 먼저 정답을 작성한다. 이는 사진만으로는 알 수 없는 사실이 정답에 혼입되는 것을 방지하기 위함이다. 반대로 Track 2 검수자는 이후 Frame을 보고 사건 시각과 당사자를 확인하고, Track 3은 동기화된 GNSS/INS 기록으로 움직임을 정한다. 같은 장면의 Metadata를 공유하더라도 정답의 의미가 다른 항목은 Track별로 따로 검수하여 작성한다. 예를 들어 Track 2의 사고 당사자는 Track 1의 "지금 위험한 대상" 으로 전용하지 않고, Track 1의 정답은 입력만으로 따로 판정한다.

2. 근거를 먼저 기록하고 판단을 연결한다. Object와 Region에 ID를 붙이고 C를 그린 다음, R1–R4와 속성을 판정하고 대응 규칙을 작성한다. 근거에는 Object ID뿐 아니라 그 대상의 역할(가리는 대상, 점유한 Actor, 출입구 등)도 함께 적어, 잘못 연결한 근거를 구분할 수 있게 한다. 기존 Label은 초안으로 사용할 수 있지만, 새 관계·속성·대응 정답은 기존 Label의 자동 변환이 아니라 사람의 검수로 작성한다.

3. 합의 전 일치도를 측정한다. Pilot 약 50장면은 두 Annotator가 서로 보지 않고 기록하며, 합의 전 원기록도 보관한다. 이는 합의 후의 정답으로 일치도를 계산하면 판정 난이도가 은폐되는 것을 방지하기 위함이다. 판정 기준의 재검토 기준은 §5의 1주차 항목과 같다.

4. Source Group으로 나누고 고정한다. 같은 Group의 Task, Frame, 입력 조건, 편집본은 한 Split에만 두고, 검수를 마친 Test와 채점 Code는 고정한 뒤 최종 비교에 사용한다. v0의 `build_v0.py`는 출력 폴더를 다시 만들어 덮어쓰므로, 사람이 작성한 Annotation은 별도 위치에 보관한다.

App. E.6 v0와 기존 위험 항목의 이관

팀이 이전에 정한 위험 항목 F1–F5는 Track 1의 공통 Annotation으로 옮긴다. 공간 공유(F1)는 R1의 보행자 사례로, 가림(F2)은 R3로, 통행 공간 제한(F3)은 R4로, 횡단·합류 접점(F4)은 Road Connections와 R2로, 공사·적치물(F5)은 Object·Region·Tag로 기록하고 R1·R3·R4를 각각 판정한다. 기존의 Safe/Dangerous, Low/Medium/High 값은 경계가 정해지지 않은 임시 항목이므로 세 Track의 정답에서 제외하고 참고 자료로만 보관한다.

v0에서 유지하는 것은 8문항, 사고 당사자 정답, 원래 parser와 점수이며, 재현 자료로 보존한다. v0 parser가 내는 `unparsable`은 새 V2와 구분해 기록한다. 보행자 위치를 바꾸는 편집 실험은 Dev에서 관측한 오류를 진단하는 선택 실험으로 규정한다. 위치를 바꾸면 Footprint, R1·R2, 관련 대응을 다시 검수하고, 원본과 편집본은 같은 Source Group에 배정한다. Test용 편집은 모델의 답을 보기 전에 변환 규칙과 품질 기준을 고정하고, 학습용 편집은 Train Group에서만 만든다.

본 문서는 팀의 기획안 두 편과 v0 Benchmark(`feat/benchmark-v0`, Commit `aba16a3`)를 통합하여 작성한다. U일 때의 대응, Obstacle·Roadside Vehicle 점유의 처리, 근거 ID의 짝짓기, 설명 제출률, 잔여 시간과 Lead Time의 구분은 통합 과정에서 팀이 정한 규칙으로, 과제 제공 기업이 확정한 요구사항과 구분한다.

참고 문헌

[1] S. Xie et al. Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives. ICCV, 2025.

[2] Y. Li et al. Evaluating Object Hallucination in Large Vision-Language Models. EMNLP, 2023.

[3] A. Rohrbach et al. Object Hallucination in Image Captioning. EMNLP, 2018.

[4] R. Agarwal et al. Deep Reinforcement Learning at the Edge of the Statistical Precipice. NeurIPS, 2021.

[5] NIST/SEMATECH. Confidence Limits for a Proportion. e-Handbook of Statistical Methods.

[6] Google. Gemma 4 model family (E2B, E4B, 12B, 26B A4B, 31B), Apache 2.0. Hugging Face blog, "Welcome Gemma 4" , 2026. https://huggingface.co/blog/gemma4

[7] AI Hub. 융합센서 다중객체 추적 및 예측 데이터 (472). https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=472

[8] AI Hub. 교통사고 영상 데이터 (597). https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=597

[9] AI Hub. 생활도로 객체인식 자율주행 데이터 (71784). https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=71784

[10] C. Sima et al. DriveLM: Driving with Graph Visual Question Answering. ECCV, 2024.

[11] E. J. Hu et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022 (arXiv:2106.09685, 2021).

[12] T. Dettmers et al. QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS, 2023.

[13] S. Min et al. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. EMNLP, 2023.

[14] R. Artstein and M. Poesio. Inter-Coder Agreement for Computational Linguistics. Computational Linguistics, 34(4), 2008.